

第十一讲

王伟文 暨南大学

1 线性代数回顾

定理 1.1: 对称实矩阵谱分解

任意 n 阶实矩阵 A 可以表示为

$$A = \sum_{i=1}^n \lambda_i \mathbf{u}_i \mathbf{u}_i^T,$$

其中 $(\lambda_i, \mathbf{u}_i)$ 为矩阵 A 的特征值及相应的正交化单位特征向量, $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n$.

令 $U = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_r] \in \mathbb{R}^{n \times r}$, $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_r)$, 则

$$A = U \Lambda U^T.$$

从优化的视角看特征值

$$\lambda_1 = \langle A \mathbf{u}_1, \mathbf{u}_1 \rangle = \max_{\|\mathbf{x}\|=1} \mathbf{x}^T A \mathbf{x}, \quad \mathbf{u}_1 = \arg \max_{\|\mathbf{x}\|=1} \mathbf{x}^T A \mathbf{x}$$

$$\lambda_2 = \langle A \mathbf{u}_2, \mathbf{u}_2 \rangle = \max_{\substack{\mathbf{x} \perp \mathbf{u}_1 \\ \|\mathbf{x}\|=1}} \mathbf{x}^T A \mathbf{x}, \quad \mathbf{u}_2 = \arg \max_{\substack{\mathbf{x} \perp \mathbf{u}_1 \\ \|\mathbf{x}\|=1}} \mathbf{x}^T A \mathbf{x}$$

$$\lambda_3 = \langle A \mathbf{u}_3, \mathbf{u}_3 \rangle = \max_{\substack{\mathbf{x} \perp \{\mathbf{u}_1, \mathbf{u}_2\} \\ \|\mathbf{x}\|=1}} \mathbf{x}^T A \mathbf{x}, \quad \mathbf{u}_3 = \arg \max_{\substack{\mathbf{x} \perp \{\mathbf{u}_1, \mathbf{u}_2\} \\ \|\mathbf{x}\|=1}} \mathbf{x}^T A \mathbf{x}$$

...

$$\lambda_n = \langle A \mathbf{u}_n, \mathbf{u}_n \rangle = \min_{\|\mathbf{x}\|=1} \mathbf{x}^T A \mathbf{x}, \quad \mathbf{u}_n = \arg \min_{\|\mathbf{x}\|=1} \mathbf{x}^T A \mathbf{x}$$

命题 1.1

对任意 n -阶对称矩阵 A , 有

$$\lambda_1 = \langle A \mathbf{u}_1, \mathbf{u}_1 \rangle = \max_{\|\mathbf{x}\|=1} \mathbf{x}^T A \mathbf{x}, \quad \mathbf{u}_1 = \arg \max_{\|\mathbf{x}\|=1} \mathbf{x}^T A \mathbf{x}$$

$$\lambda_n = \langle A \mathbf{u}_n, \mathbf{u}_n \rangle = \min_{\|\mathbf{x}\|=1} \mathbf{x}^T A \mathbf{x}, \quad \mathbf{u}_n = \arg \min_{\|\mathbf{x}\|=1} \mathbf{x}^T A \mathbf{x}$$

证明. 由定理 1.1 知, 矩阵 \mathbf{A} 可表示谱分解的形式 $\mathbf{A} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^T$, 故

$$\begin{aligned}\max_{\|\mathbf{x}\|=1} \mathbf{x}^T \mathbf{A} \mathbf{x} &= \max_{\|\mathbf{x}\|=1} \mathbf{x}^T \mathbf{U} \mathbf{\Lambda} \mathbf{U}^T \mathbf{x} \\ &= \max_{\|\mathbf{y}\|^2=1} \mathbf{y}^T \mathbf{\Lambda} \mathbf{y} = \max_{\|\mathbf{y}\|^2=1} \sum_{i=1}^n y_i^2 \lambda_i \quad (\mathbf{y} = \mathbf{U}^T \mathbf{x}) \\ &= \max_{\xi \in \Delta_n} \sum_{i=1}^n \xi_i \lambda_i = \lambda_1 \quad (y_i^2 = \xi_i)\end{aligned}$$

余下结论显然成立. □

定理 1.2: 奇异值分解 (Singular Value Decomposition)

$\forall \mathbf{A} \in \mathbb{R}^{m \times n}$, 可以表示为

$$\mathbf{A} = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{v}_i^T$$

其中 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ 为奇异值, \mathbf{u}_i 为左奇异向量, \mathbf{v}_i 为右奇异向量, 满足

$$\sigma_i = \sqrt{\lambda_i(\mathbf{A}\mathbf{A}^T)} = \sqrt{\lambda_i(\mathbf{A}^T\mathbf{A})};$$

$\{\mathbf{u}_i\}$ 为矩阵 $\mathbf{A}\mathbf{A}^T$ 的正交化特征向量;

$\{\mathbf{v}_i\}$ 为矩阵 $\mathbf{A}^T\mathbf{A}$ 的正交化特征向量.

且 $r = \text{rank}(\mathbf{A})$.

奇异值分解的矩阵形式

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T,$$

其中 $\mathbf{U} \in \mathbb{R}^{m \times n}$, $\mathbf{V} \in \mathbb{R}^{n \times n}$ 为正交矩阵, 分别为矩阵 $\mathbf{A}\mathbf{A}^T$ 和 $\mathbf{A}^T\mathbf{A}$ 的正交化特征向量构成的列矩阵, $\mathbf{\Sigma} \in \mathbb{R}^{m \times n}$ 的对角元为奇异值 $(\sigma_1, \sigma_2, \dots, \sigma_r)$, 其他位置为 0.

紧凑形式

$$\mathbf{A} = \mathbf{U}_r \mathbf{\Sigma}_r \mathbf{V}_r^T,$$

其中 $\mathbf{U}_r \in \mathbb{R}^{m \times r}$ 和 $\mathbf{V}_r \in \mathbb{R}^{n \times r}$ 分别为 \mathbf{U} 和 \mathbf{V} 的前 r 列, 满足 $\mathbf{U}_r^T \mathbf{U}_r = \mathbf{V}_r^T \mathbf{V}_r = \mathbf{I}_r$, $\mathbf{\Sigma}_r = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$.

从优化的视角看奇异值

$$\begin{aligned}\sigma_1 &= \max_{\|x\|=1} \|Ax\|_2, & v_1 &= \arg \max_{\|x\|=1} \|Ax\|_2 \\ \sigma_2 &= \max_{\substack{x \perp v_1 \\ \|x\|=1}} \|Ax\|_2, & v_2 &= \arg \max_{\substack{x \perp v_1 \\ \|x\|=1}} \|Ax\|_2 \\ \sigma_3 &= \max_{\substack{x \perp \{v_1, v_2\} \\ \|x\|=1}} \|Ax\|_2, & v_3 &= \arg \max_{\substack{x \perp \{v_1, v_2\} \\ \|x\|=1}} \|Ax\|_2 \\ &\dots \\ \sigma_n &= \min_{\|x\|=1} \|Ax\|_2, & v_n &= \arg \min_{\|x\|=1} \|Ax\|_2\end{aligned}$$

命题 1.2

设 A 为 n -阶对称实矩阵, 则有

$$\sigma_1(A) = \max_{\|x\|=1} |x^T A x| = \max_{i \in [n]} |\lambda_i(A)|.$$

2 矩阵范数

考虑矩阵 $A \in \mathbb{R}^{m \times n}$, Frobenius 范数

$$\|A\|_F = \sqrt{\sum_{i,j} A_{i,j}^2}$$

矩阵内积

$$\langle A, B \rangle = \text{trace}(B^T A)$$

$$\|A\|_F^2 = \langle A, A \rangle$$

命题 2.1: $\|\cdot\|_F$ 的正交不变性

对任意正交矩阵 $U \in \mathbb{R}^{m \times m}$ 或 $V \in \mathbb{R}^{n \times n}$, 有

$$\|UA\|_F = \|AV\|_F = \|A\|_F$$

证明. $\|UA\|_F = \sqrt{\langle UA, UA \rangle} = \sqrt{\text{trace}(A^T U^T U A)} = \sqrt{\text{trace}(A^T A)} = \|A\|_F$. \square

命题 2.2

$$\|A\|_F^2 = \sum \sigma_i^2(A).$$

证明. 将矩阵 \mathbf{A} 表示为 SVD 分解的形式, $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$.

$$\|\mathbf{A}\|_F^2 = \|\mathbf{U}\mathbf{\Sigma}\mathbf{V}^T\|^2 \stackrel{(i)}{=} \|\mathbf{\Sigma}\|_F^2 = \text{trace}(\mathbf{\Sigma}^T \mathbf{\Sigma}) = \sum \sigma_i^2(\mathbf{A}),$$

其中 (i) 由 Frobenius 范数的正交不变性得到. □

定义 2.1: 矩阵谱范数

$$\|\mathbf{A}\| = \max_{\|\mathbf{x}\|_2=1} \|\mathbf{A}\mathbf{x}\|_2 = \max_{\|\mathbf{x}\|_2 \leq 1} \|\mathbf{A}\mathbf{x}\|_2 = \max_{\mathbf{x}} \frac{\|\mathbf{A}\mathbf{x}\|_2}{\|\mathbf{x}\|_2}$$

关于矩阵谱范数有

- (a) 对任意正交矩阵 $\mathbf{U} \in \mathbb{R}^{m \times m}$ 或 $\mathbf{V} \in \mathbb{R}^{n \times n}$, $\|\mathbf{U}\mathbf{A}\| = \|\mathbf{A}\mathbf{V}\| = \|\mathbf{A}\|$;
- (b) 若矩阵 \mathbf{A} 可逆, $\|\mathbf{A}^{-1}\| = \frac{1}{\sigma_n(\mathbf{A})}$
- (c) $\|\mathbf{A} + \mathbf{B}\| \leq \|\mathbf{A}\| + \|\mathbf{B}\|$
- (d) $\|\mathbf{A}\mathbf{B}\| \leq \|\mathbf{A}\| \|\mathbf{B}\|$ ($\|\mathbf{A}\mathbf{B}\mathbf{x}\|_2 \leq \|\mathbf{A}\| \|\mathbf{B}\mathbf{x}\|_2 \leq \|\mathbf{A}\| \|\mathbf{B}\|$)
- (e) $\|\mathbf{A}\| \leq \|\mathbf{A}\|_F \leq \sqrt{r} \|\mathbf{A}\|$ ($\|\mathbf{A}\| = \sigma_1(\mathbf{A}) \leq \sqrt{\sum_{i=1}^r \sigma_i^2(\mathbf{A})} = \|\mathbf{A}\|_F \leq \sqrt{r \sigma_1^2(\mathbf{A})} = \sqrt{r} \|\mathbf{A}\|$)
这里 $r = \text{rank}(\mathbf{A})$.

- (f) $\|\mathbf{A}\| = \max_{\|\mathbf{x}\|=1 \text{ 且 } \|\mathbf{y}\|=1} \mathbf{y}^T \mathbf{A} \mathbf{x}$
 $(\|\mathbf{z}\|_2 = \max_{\|\mathbf{y}\|_2=1} \mathbf{y}^T \mathbf{z}, \max_{\|\mathbf{x}\|=1 \text{ 且 } \|\mathbf{y}\|=1} \mathbf{y}^T \mathbf{A} \mathbf{x} = \max_{\|\mathbf{x}\|=1} \max_{\|\mathbf{y}\|_2=1} \mathbf{y}^T \mathbf{A} \mathbf{x} = \max_{\|\mathbf{x}\|_2=1} \|\mathbf{A}\mathbf{x}\|_2 = \sigma_1(\mathbf{A}) = \|\mathbf{A}\|)$

3 随机向量

设 X 为一个 d -维随机向量, 其均值为 $\mathbb{E}X = \boldsymbol{\mu}$.

协方差矩阵为

$$\text{cov}(X) = \mathbb{E}(X - \boldsymbol{\mu})(X - \boldsymbol{\mu})^T = \mathbb{E}[X X^T] - \boldsymbol{\mu} \boldsymbol{\mu}^T$$

- $(\text{cov}(X))_{i,j} = \mathbb{E}(X_i - \mu_i)(X_j - \mu_j) = \text{cov}(X_i, X_j)$
- $(\text{cov}(X))_{i,i} = \text{var}(X_i)$

命题 3.1

$\text{cov}(X)$ 是一个正半定矩阵.

4 主成分分析 (Principal Component Analysis, PCA)

设 $X \in \mathbb{R}^d$ 是以 0 为均值的随机向量, 协方法为 $\text{cov}(X) = \Sigma$. 要找一个单位向量将 X 投影到 1 维空间中, 并使得方差最大, 即

$$\max_{\|v\|_2=1} \mathbb{E}[(\langle X, v \rangle)^2] = \max_{\|v\|_2=1} v^T \Sigma v$$

由矩阵特征值性质知, 最优的投影变换为 Σ 的最大特征对应的单位化特征向量 $v_1(\Sigma)$, 此时

$$\lambda_1(\Sigma) = \max_{\|v\|_2=1} v^T \Sigma v.$$

接下来寻找第二个“最佳投影方向”, 满足

$$\max_{\substack{v \perp v_1 \\ \|v\|_2=1}} v^T \Sigma v.$$

得到最优的投影变换为 Σ 的最二大特征对应的单位化特征向量 $v_2(\Sigma)$, 此时

$$\lambda_2(\Sigma) = \max_{\substack{v \perp v_1 \\ \|v\|_2=1}} v^T \Sigma v.$$

依次类推, 协方差 Σ 的前 k 个特征值对应的单位正交化特征向量构成主成分分析的“主成分”, 即随机变量 X 投影到 k -为空间的线性变换.

称比率

$$\frac{\sum_{i=1}^k \lambda_i(\Sigma)}{\sum_{j=1}^d \lambda_j(\Sigma)}$$

为这 k 个主成分的累积解释度.

然而在实践中, 随机变量 $X \in \mathbb{R}^d$ 的协方差往往是未知的. 给定 n 个来自与 X 同一总体的样本 X_1, X_2, \dots, X_n , 样本协方差为

$$\Sigma_n = \frac{1}{n} \sum_{i=1}^n X_i X_i^T.$$

此时, 主成分分析建立在 Σ_n 上.

一个自然的问题是, $PCA(\Sigma_n)$ 在多大程度上近似 $PCA(\Sigma)$, 即能否确保

$$\lambda_i(\Sigma_n) \approx \lambda_i(\Sigma) \quad \text{且} \quad v_i(\Sigma_n) \approx v_i(\Sigma),$$

相应的样本量应该是多少?

我们首先来看看能否在谱范数的度量下控制 Σ 与 Σ_n 的差别. 由谱范数性质

$$\begin{aligned}\|\Sigma_n - \Sigma\| &= \max_{\mathbf{v} \in \mathcal{S}^{d-1}} |\mathbf{v}^T (\Sigma_n - \Sigma) \mathbf{v}| \\ &= \max_{\mathbf{v} \in \mathcal{S}^{d-1}} |\mathbf{v}^T \Sigma_n \mathbf{v} - \mathbf{v}^T \Sigma \mathbf{v}| \\ &= \max_{\mathbf{v} \in \mathcal{S}^{d-1}} \left| \frac{1}{n} \sum_{i=1}^n \langle X_i, \mathbf{v} \rangle^2 - \mathbb{E}[\langle X, \mathbf{v} \rangle^2] \right|\end{aligned}$$

其中 $\mathcal{S}^{d-1} \triangleq \{\mathbf{x} \in \mathbb{R}^d : \|\mathbf{x}\|_2 = 1\}$

定义随机变量

$$Z(\mathbf{v}) = \frac{1}{n} \sum_{i=1}^n \langle X_i, \mathbf{v} \rangle^2 - \mathbb{E}[\langle X, \mathbf{v} \rangle^2],$$

此时

$$\|\Sigma_n - \Sigma\| = \max_{\mathbf{v} \in \mathcal{S}^{d-1}} |Z(\mathbf{v})|$$

命题 4.1: 谱范数与球面上的 ϵ -覆盖

对于矩阵 $\mathbf{A} \in \mathbb{R}^{m \times n}$, 设 \mathcal{N} 为单位球面 \mathcal{S}^{n-1} 的一个 ϵ -覆盖, 则

$$\|\mathbf{A}\| \leq \frac{1}{1 - \epsilon} \max_{\mathbf{x} \in \mathcal{N}} \|\mathbf{A}\mathbf{x}\|$$

证明. 由 ϵ -覆盖定义, $\forall \mathbf{v} \in \mathcal{S}^{n-1}$, $\exists \mathbf{x} \in \mathcal{N}$, 满足

$$\|\mathbf{v} - \mathbf{x}\|_2 \leq \epsilon$$

由三角不等式及谱范数定义

$$\|\mathbf{A}\mathbf{v}\|_2 - \|\mathbf{A}\mathbf{x}\|_2 \leq \|\mathbf{A}\mathbf{v} - \mathbf{A}\mathbf{x}\|_2 \leq \|\mathbf{A}\| \|\mathbf{v} - \mathbf{x}\|_2 \leq \|\mathbf{A}\| \epsilon$$

即对任意 $\mathbf{v} \in \mathcal{S}^{d-1}$, 存在 $\mathbf{x} \in \mathcal{N}$, 使得

$$\|\mathbf{A}\mathbf{v}\|_2 \leq \|\mathbf{A}\| \epsilon + \|\mathbf{A}\mathbf{x}\|_2$$

因此

$$\max_{\mathbf{v} \in \mathcal{S}^{n-1}} \|\mathbf{A}\mathbf{v}\|_2 \leq \|\mathbf{A}\| \epsilon + \max_{\mathbf{x} \in \mathcal{N}} \|\mathbf{A}\mathbf{x}\|_2$$

即

$$\|\mathbf{A}\| \leq \epsilon \|\mathbf{A}\| + \max_{\mathbf{x} \in \mathcal{N}} \|\mathbf{A}\mathbf{x}\|_2$$

移项得到

$$\|\mathbf{A}\| \leq \frac{1}{1 - \epsilon} \max_{\mathbf{x} \in \mathcal{N}} \|\mathbf{A}\mathbf{x}\|$$

□