Lecture 1

Unexpected behaviors of high-dimensional spaces and introductory

Counter-intuition of high dimensional data

Vastness of hypersphere. Consider an inscribed hypersphere with radius r to a hypercube with edges of length $2r$ in d-dimensional Euclidean space,

$$V_{\text{hypersphere}} = \frac{2r^d \pi^{d/2}}{d\Gamma(d/2)}, \quad V_{\text{hypercube}} = (2r)^d,$$

where Γ is the gamma function. Then

$$\lim_{d\to\infty} \frac{V_{\text{hypersphere}}}{V_{\text{hypercube}}} = \frac{\pi^{d/2}}{d2^{d-1}\Gamma(d/2)} = 0, \tag{1.1}$$

which implies that *data points uniformly generated in a high-dimensional hypercube are concentrated in the corners.*

Concentration effect of L_p norms. For any fixed n, the difference between the minimum and that maximum distance under L_p norm between a random reference point Q and a list of n random data points $P_1, \ldots, P_n$ become indiscernible compared to the minimum distance as

$$\lim_{d\to\infty} \mathbb{E}\left(\frac{\text{dist}_{\max}(d) - \text{dist}_{\min}(d)}{\text{dist}_{\min}(d)}\right) = 0, \tag{1.2}$$

where $\text{dist}_{\max}(d)$ and $\text{dist}_{\min}(d)$ denote the maximum and the minimum distance the reference point Q and n points $\{P_i\}_{i=1}^n$, respectively, in a d-dimensional space.

Concentration of Gaussian distribution. Let Z be a random vector in $\mathbb{R}^d$ with independent $\mathcal{N}(0,1)$ coordinates. Then

$$P(|\|Z\|_2 - \sqrt{d}| \geq t) \leq 2\exp(-ct^2), \tag{1.3}$$

where $c > 0$ is a constant, $t \geq 0$ and $\|\cdot\|$ is the Euclidean vector norm.

Almost orthogonality of independent vectors. Let $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^d$ be drawn at random with respect to the spherical Gaussian distribution with zero mean and unit variance. Then for every $\epsilon > 0$ and for all $d \geq 1$ the estimate

$$P\left[\left|\langle \frac{\boldsymbol{x}}{\|\boldsymbol{x}\|}, \frac{\boldsymbol{y}}{\|\boldsymbol{y}\|} \rangle\right| \geq \epsilon\right] \leq \frac{2/\epsilon + 7}{\sqrt{d}}$$

holds.

From inside out

Non-asymptotic analysis

To illustrate the difference between asymptotic and non-asymptotic analysis, we recall the statement of the weak law of large numbers

Theorem 1.0.1: Weak law of large numbers (WLLN)

Let X be a real random variable with expectation $\mathbb{E}X = p$. Consider an iid sequence $(X_i : i \in \mathbb{N})$ of copies of X. From the running averages:

$$\bar{X}_n := \frac{1}{n}\sum_{i=1}^{n} X_i \quad \text{for } n \in \mathbb{N}.$$

Then, for each $t > 0$, we have the limit

$$\mathbb{P}\{|\bar{X}_n - p| \geq t\} \to 0 \quad \text{as } n \to \infty.$$

The Weak Law of Large Numbers (WLLN) demonstrates that the sample average converges to the expectation of a random variable as the sample size increases, providing an asymptotic result. However, it does not address the question of how close the sample average is to the expectation for a fixed sample size n. That is precisely the focus of non-asymptotic analysis.

Goals of this course

Concentration Consider a fixed-size sample $(X_1, X_2, \ldots, X_n)$ generated from a distribution. For a measurable function $f : \mathbb{R}^n \to \mathbb{R}$, we define a random variable.

$$Z = f(X_1, X_2, \ldots, X_n).$$

Concentration inequalities provide an upper bound on the probability that the random variable Z deviates from its median $\mathbb{M}Z$ or expectation $\mathbb{E}Z$ by more than a given tolerance $t > 0$. These inequalities are in the forms of

$$\mathbb{P}\{|Z - \mathbb{E}Z| \geq t\} \leq \square,$$
$$\mathbb{P}\{|Z - \mathbb{M}Z| \geq t\} \leq \triangle.$$

We immediately recognize concentration inequalities tell stories in a non-asymptotic way.

For example, let f be the average function $Z = \frac{1}{n}\sum_{i=1}^{n} X_i$, the concentration inequality can tell us about the probability of the derivation of sample average from its expectation controlled by a given tolerance t, i.e.,

$$\mathbb{P}\{|Z - \mathbb{E}Z| \leq t\} = 1 - \mathbb{P}\{|Z - \mathbb{E}Z| \geq t\} \geq 1 - \square,$$

with fixed sample size.

Suprema The concentration inequalities do not offer any information on the value of $\mathbb{E}f(X_1, X_2, \ldots, X_n)$.. The estimation of this value depends on f. Here we analysis a specific but useful type of f, i.e., the max function.

Specifically, let

$$Z = \sup_{t \in T} X_t,$$

Z is defined as the supremum of a random process $\{X_t\}_{t\in T}$, a family of random variables indexed by a set T. For example, let $X_i \sim \mathcal{N}(0, \sigma^2)$, given an indexed set $T = \{1, 2, \ldots, N\}$,

$$Z = \max_{i=1,2,\ldots,N} X_i.$$

The reason that suprema plays an important role in high-dimensional problem arises in twofold. First, a family of random variables may be interdependent and taking the supreme controls all of them simultaneously. Second, some quantities are naturally mathematically presented in suprema.

Example (Random matrices) Let $\boldsymbol{A} = (A_{ij})$ be a n-by-n random matrix with each of its element is an iid Gaussian random variable. Suppose we want to estimate the largest singular value of $\boldsymbol{A}$, i.e., the spectral norm of $\boldsymbol{A}$, which is mathematically defined as

$$\|\boldsymbol{A}\| = \sup_{\boldsymbol{u},\boldsymbol{v}\in\mathcal{B}} \langle \boldsymbol{u}, \boldsymbol{A}\boldsymbol{v}\rangle,$$

where $\mathcal{B}$ denotes the Euclidean unit ball. Let $X_{\boldsymbol{u},\boldsymbol{v}} := \langle \boldsymbol{u}, \boldsymbol{A}\boldsymbol{v}\rangle$, $\|\boldsymbol{A}\|$ is the supreme of the random process $\{X_{\boldsymbol{u},\boldsymbol{v}}\}_{(\boldsymbol{u},\boldsymbol{v})\in\mathcal{B}\times\mathcal{B}}$.

Example (Empirical risk minimization) The core issue in machine learning is computing

$$\arg\min_{\boldsymbol{\theta}\in\boldsymbol{\Theta}} \underbrace{\mathbb{E}[\ell(\boldsymbol{\theta}, X)]}_{\text{generalization error}}.$$

In practice, the distribution of X is unknown, and alternatively we collect an iid sample $(X_1, X_2, \ldots, X_n)$ from the distribution and minimize the empirical risk solving

$$\arg\min_{\boldsymbol{\theta}\in\boldsymbol{\Theta}} \underbrace{\frac{1}{n}\sum_{i=1}^{n} \ell(\boldsymbol{\theta}, X_i)}_{\text{empirical risk}},$$

with the hope that

$$\mathbb{E}[\ell(\boldsymbol{\theta}, X)] \approx \frac{1}{n}\sum_{i=1}^{n} \ell(\boldsymbol{\theta}, X_i).$$

Measuring how close is the empirical risk to the generalization error over the the param-

eter space $\boldsymbol{\Theta}$ leads the investigate the uniform derivation

$$\sup_{\boldsymbol{\theta}\in\boldsymbol{\Theta}} \left| \frac{1}{n}\sum_{i=1}^{n} \ell(\boldsymbol{\theta}, X_i) - \mathbb{E}[\ell(\boldsymbol{\theta}, X)] \right|.$$

We will not talk about **Universality** and **Phase transitions**, which you can learn from APC 550 Lecture Notes[1]

Review of Expectation and Variance

Expectation of a random variable X with density $p(x)$ is defined as

$$\mathbb{E}X = \int_{-\infty}^{\infty} xp(x)dx.$$

Generally,

$$\mathbb{E}f(X) = \int_{-\infty}^{\infty} f(x)p(x)dx.$$

If X is a random variable in $\mathbb{R}^n$,

$$\mathbb{E}f(X) = \int_{\mathbb{R}^n} f(\boldsymbol{x})p(\boldsymbol{x})d\boldsymbol{x}.$$

Variance of a random variable is defined as

$$\mathrm{Var}(X) = \mathbb{E}(X - \mathbb{E}X)^2.$$

Properties of expectation and variance

- *Linearity of Expectation* Suppose there are a sequence of random variables $X_1, X_2, \cdots, X_n$, we have
$$\mathbb{E}(X_1 + X_2 + \cdots + X_n) = \mathbb{E}X_1 + \mathbb{E}X_2 + \cdots + \mathbb{E}X_n$$
- *Association of Expectation of Independent Random Variable* If X_1 and X_2 are independent,
$$\mathbb{E}\left[X_1X_2\right] = \mathbb{E}X_1 \cdot \mathbb{E}X_2.$$
- *Linearity of Variance for Independent Random Variables* If $X_1, X_2, \cdots, X_n$ are independent,
$$\mathrm{Var}(X_1 + X_2 + \cdots + X_n) = \mathrm{Var}(X_1) + \mathrm{Var}(X_2) + \cdots + \mathrm{Var}(X_n).$$

Lemma 1.0.2

Let X be a random variable and X' is an independent copy of X, i.e., X and X' are iid. Then we have

$$\mathrm{Var}(X) = \frac{1}{2}\mathbb{E}(X - X')^2.$$

[1] Ramon van Handel. Probability in High Dimension. https://web.math.princeton.edu/ rvan/APC550.pdf

Some classical inequalities

Jensen's inequality For any random variable and a convex function $\phi : \mathbb{R} \to \mathbb{R}$, we have

$$\varphi(\mathbb{E}X) \leq \mathbb{E}\varphi(X).$$

Lemma 1.0.3: Integral identity

Let X be a non-negative random variable, then

$$\mathbb{E}X = \int_0^\infty P\{X > t\}dt.$$

Proof. Any non-negative real number x can be expressed as

$$x = \int_0^x 1dt = \int_0^\infty \mathbf{1}_{\{x>t\}}dt.$$

By the definition of expectation

$$\begin{aligned}
\mathbb{E}X &= \int_0^\infty \int_0^\infty p(x)\mathbf{1}_{\{x>t\}}dtdx \\
&= \int_0^\infty \int_0^\infty p(x)\mathbf{1}_{\{x>t\}}dxdt \\
&= \int_0^\infty \int_t^\infty p(x)dxdt \\
&= \int_0^\infty P\{X \geq t\}dx.
\end{aligned}$$

□

Theorem 1.0.4: Markov's inequality

For any non-negative random variable X and $t > 0$, we have

$$\mathbb{P}\{X \geq t\} \leq \frac{\mathbb{E}X}{t}.$$

Proof.

$$\begin{aligned}
\mathbb{E}X &= \int_0^\infty xp(x)dx = \int_0^t xp(x)dx + \int_t^\infty xp(x)dx \\
&\overset{x\geq 0}{\geq} \int_t^\infty xp(x)dx \overset{x\geq t}{\geq} t\int_t^\infty p(x)dx = t\mathbb{P}\{X \geq t\}.
\end{aligned}$$

□

Theorem 1.0.5: Chebyshev's inequality

Let X be a random variable with mean μ and variance σ^2. Then, for any $t > 0$, we have

$$\mathbb{P}\{|X - \mu| \geq t\} \leq \frac{\sigma^2}{t}.$$

Proof. Denote $Z := (X - \mu)^2$. Since $Z \geq t$ is equivalent to $|X - \mu| \geq t$, we have

$$\mathbb{P}\{|X - \mu| \geq t\} = \mathbb{P}\{Z \geq t\} \leq \frac{\mathbb{E}Z}{t}.$$

The last inequality is a result of Markov's inequality.

Note that $\mathbb{E}Z = \mathbb{E}(X - \mathbb{E}X)^2 = \sigma^2$, we finish the proof. □

Lemma 1.0.6: Tower rule

Let X and Y be two random variables with distributions p_X and p_Y, respectively. Then, we have

$$\mathbb{E}_X[X] = \mathbb{E}_Y\left[\mathbb{E}_X[X|Y]\right].$$

Proof.

$$\begin{aligned}
\mathbb{E}_Y\left[\mathbb{E}_X[X|Y]\right] &= \int_Y p(y)\left[\int_X xp(x|y)\right]dxdy \\
&= \int_X x\left[\int_Y p(y)p(x|y)dy\right]dx \\
&= \int_X xp(x)dx = \mathbb{E}_X[X]
\end{aligned}$$

□

Integration in high-dimensional spaces

For simplicity, we take a bounded function $f : [0,1]^d \to \mathbb{R}$ as an example to calculate the integral

$$\int_{[0,1]^d} f(\boldsymbol{x})d\boldsymbol{x}.$$

Given resolution at $\epsilon > 0$, the grid method takes $(1/\epsilon)^d$ points over the d-dimensional space $[0,1]^d$, which suffers in high dimensionality.

Monte-Carlo's Method. Alternatively, we solve this problem in a probabilistic way. Define a random variable X over the d- dimensional space $[0,1]^d$, with density

$$p(\boldsymbol{x}) = \begin{cases} 1, \boldsymbol{x} \in [0,1]^d \\ 0, \boldsymbol{x} \notin [0,1]^d \end{cases}$$

Obviously, we have

$$\int_{[0,1]^d} f(\boldsymbol{x})d\boldsymbol{x} = \mathbb{E}f(X).$$

Draw a sequence of iid random variables $(X_1, X_2, \ldots, X_n)$ from p with sample size n, and take the sample average as

$$\frac{1}{n}\sum_{i=1}^{n} f(X_i).$$

Hopefully, we want

$$\int_{[0,1]^d} f(\boldsymbol{x})d\boldsymbol{x} = \mathbb{E}f(X) \approx \frac{1}{n}\sum_{i=1}^{n} f(X_i).$$

Is it a good estimator? We measure the error by

$$\mathbb{E}\left(\frac{1}{n}\sum_{i=1}^{n} f(X_i) - \mathbb{E}f(X)\right)^2 \text{ (Q: why do we take the expectation?)}$$

$$\begin{aligned}
&\mathbb{E}\left(\frac{1}{n}\sum_{i=1}^{n} f(X_i) - \mathbb{E}f(X)\right)^2 \\
=&\mathbb{E}\left(\frac{1}{n}\sum_{i=1}^{n} (f(X_i) - \mathbb{E}f(X))\right)^2 \\
=&\mathrm{Var}\left(\frac{1}{n}\sum_{i=1}^{n} f(X_i)\right) \quad \text{(def. of var.)} \\
=&\frac{1}{n^2}\sum_{i=1}^{n} \mathrm{Var}(f(X_i)) \quad \text{(iid of } X_i\text{)} \\
=&\frac{1}{n}\mathrm{Var}(f(X)) \\
=&\frac{1}{n}\mathbb{E}\left(f(X) - \mathbb{E}f(X)\right)^2 \le \frac{1}{n}2M^2 \quad \text{(suppose } |f| \le M\text{)}
\end{aligned}$$

By concavity of $\sqrt{\cdot}$ and Jensen' inequality, we have

$$\mathbb{E}\left|\frac{1}{n}\sum_{i=1}^{n} f(X_i) - \mathbb{E}f(X)\right| \le \sqrt{\mathbb{E}\left(\frac{1}{n}\sum_{i=1}^{n} f(X_i) - \mathbb{E}f(X)\right)^2} \le M\sqrt{\frac{2}{n}}.$$

Hence,

$$\mathbb{E}\left|\frac{1}{n}\sum_{i=1}^{n} f(X_i) - \mathbb{E}f(X)\right| \lesssim \frac{1}{\sqrt{n}},$$

where we use the symbol "$\lesssim$" to hide to quantities independent of n.

The error is **INDEPENDENT OF DIMENSION**. The result is not obtained for free. We have made compromises to derive an upper bound for the error, **ON AVERAGE**.

Lecture 2

Approximate Caratheodory's Theorem

Convex sets and convex hulls

Definition 2.0.1: Convex sets

Let $\mathcal{S} \subseteq \mathbb{R}^d$. $\mathcal{S}$ is a **convex set** if

$$\lambda \boldsymbol{x} + (1-\lambda)\boldsymbol{y} \in \mathcal{S},$$

for any $\boldsymbol{x}, \boldsymbol{y} \in \mathcal{S}$ and $\lambda \in [0,1]$.

We call $\boldsymbol{z}$ is a **convex combination** of $\{\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_n\}$ if there exists $\boldsymbol{\lambda} = (\lambda_i) \in \mathbb{R}^n$ such that

$$\boldsymbol{z} = \sum_{i=1}^{n} \lambda_i \boldsymbol{x}_i$$

satisfying $\sum\limits_{i=1}^{n} \lambda_i = 1$ and $\lambda_i \geq 0$ for all i.

Definition 2.0.2: Convex hulls

Let $\mathcal{S} \subseteq \mathbb{R}^d$. We call a set **convex hull** of $\mathcal{S}$, denoted by $\mathrm{conv}(\mathcal{S})$ if any element of this set, can be expressed as a convex combination of points from $\mathcal{S}$. Mathematically, for any $\boldsymbol{z} \in \mathrm{conv}(\mathcal{S})$, there exists a sequence $\{\boldsymbol{x}_i\}_{i=1}^n \subseteq \mathcal{S}$ for $n \in \mathbb{N}$ such that

$$\boldsymbol{z} = \sum_{i=1}^{n} \lambda_i \boldsymbol{x}_i$$

satisfying $\sum\limits_{i=1}^{n} \lambda_i = 1$ and $\lambda_i \geq 0$ for all i.

Remark.

The convex hull $\mathrm{conv}(\mathcal{S})$ is the smallest convex set that contains $\mathcal{S}$, in the sense that $\mathrm{conv}(\mathcal{S})$ is a subset of any convex set that contains $\mathcal{S}$.

Caratheodory's theorem and approximated Caratheodory's theorem

Theorem 2.0.3: Caratheodory's theorem

Every point in the convex hull of a set $\mathcal{S} \subseteq \mathbb{R}^d$ can be expressed as a convex combination of at most $d+1$ points from $\mathcal{S}$.

Caratheodory's theorem tells us the worst-case number of points needed to represent an element of a convex hull. Such worst-case number is dimensional-dependent and apparently cannot be improved.

What if we approximate $\boldsymbol{z} \in \mathrm{conv}(\mathcal{S})$ rather than exactly represent it as a convex combination of points from $\mathcal{S}$. We show that such approximation lead to the number of points needed for representation does not depend not the dimension d.

Theorem 2.0.4: Approximate Caratheodory's theorem

Consider a bounded set $\mathcal{S} \subset \mathbb{R}^d$, i.e., there exists $r > 0$ for any $\boldsymbol{z} \in \mathcal{S}$, $\|\boldsymbol{z}\| \leq r$. For every point $\boldsymbol{x} \in \mathrm{conv}(\mathcal{S})$ and every integer k, there exists a sequence of points $(\boldsymbol{x}_j)_{j=1}^k \subset \mathcal{S}$ such that

$$\left\| \boldsymbol{x} - \frac{1}{k} \sum_{j=1}^{k} \boldsymbol{x}_j \right\|_2 \leq \frac{r}{\sqrt{k}}.$$

Proof. Without loss of generality we assume that $\|\boldsymbol{z}\| \leq 1$ for any $\boldsymbol{z} \in \mathcal{S}$.

Let $\boldsymbol{x} \in \mathrm{conv}(\mathcal{S})$, then there exists a sequence of points $(\boldsymbol{z}_i)_{i=1}^n$ for $n \in \mathbb{N}$ and $n \leq d+1$ such that

$$\boldsymbol{x} = \sum_{i=1}^{n} \lambda_i \boldsymbol{z}_i$$

satisfying $\sum_{i=1}^{n} \lambda_i = 1$ and $\lambda_i \geq 0$.

Since $\boldsymbol{\lambda} = (\lambda_i)$ belongs to the probability simplex, we define a discrete probability distribution of a random variable Z as follows

$$\mathbb{P}\{Z = \boldsymbol{z}_i\} = \lambda_i,$$

with expectation $\mathbb{E}Z = \boldsymbol{x}$.

Generating a family of iid random variables from this distribution $(Z_1, Z_2, \ldots, Z_k)$ for

$k \in \mathbb{N}$, we obtain their sample average as

$$\frac{1}{k}\sum_{i=1}^{k} Z_i,$$

and

$$\mathbb{E}\left[\frac{1}{k}\sum_{i=1}^{k} Z_i\right] = \boldsymbol{x}.$$

We measure the derivation of the sample average from its expectation by

$$\mathbb{E}\left\|\frac{1}{k}\sum_{i=1}^{k} Z_i - \boldsymbol{x}\right\|_2^2$$

Since Z_i are iid and deriving from the inequality $\mathbb{E}\|Z - \mathbb{E}Z\|_2^2 \leq \mathbb{E}\|Z\|_2^2$ (Check by Yourself) for a d-dimensional random variable, we have

$$\begin{aligned}
\mathbb{E}\left\|\frac{1}{k}\sum_{i=1}^{k} Z_i - \boldsymbol{x}\right\|_2^2 &= \mathbb{E}\left\|\frac{1}{k}\sum_{i=1}^{k}(Z_i - \boldsymbol{x})\right\|_2^2 \\
&= \frac{1}{k^2}\mathbb{E}\left\|\sum_{i=1}^{k}(Z_i - \boldsymbol{x})\right\|_2^2 \\
&= \frac{1}{k^2}\sum_{i=1}^{k}\mathbb{E}\|Z_i - \boldsymbol{x}\|_2^2 \\
&\leq \frac{1}{k^2}\sum_{i=1}^{k}\mathbb{E}\|Z_i\|_2^2 \\
&\leq \frac{1}{k} \qquad (\|Z_i\|_2 \leq 1)
\end{aligned}$$

By concavity of $\sqrt{\cdot}$ and Jensen's inequality, we obtain

$$\mathbb{E}\left\|\frac{1}{k}\sum_{i=1}^{k} Z_i - \boldsymbol{x}\right\|_2 \leq \sqrt{\mathbb{E}\left\|\frac{1}{k}\sum_{i=1}^{k} Z_i - \boldsymbol{x}\right\|_2^2} \leq \frac{1}{\sqrt{k}}.$$

Here there exists a realization of $(Z_1, Z_2, \ldots, Z_k)$ denotes as $(\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_k)$ such that

$$\left\|\frac{1}{k}\sum_{i=1}^{k} \boldsymbol{x}_i - \boldsymbol{x}\right\|_2 \leq \frac{1}{\sqrt{k}}.$$

□

Remark.

> Such realization is built from components of a convex combination of $\boldsymbol{x}$ and repetitions are allowed.

An application of approximated Caratheodory's theorem

Definition 2.0.5: Covering numbers

The covering number of a set $\mathcal{T} \subset \mathbb{R}^d$ is the smallest number of Euclidean balls of radius ϵ needed to cover $\mathcal{T}$, denoted by $N(\mathcal{T}, \epsilon)$.

Remark.

- Covering numbers measure the complexity of $\mathcal{T}$.
- They suffer from the dimension d.
- Let the centers of a set of Euclidean balls with radius ϵ be $\{\boldsymbol{c}_i\}$. Mathematically, we say these Euclidean balls cover $\mathcal{T}$, if for any $x \in \mathcal{T}$, there exists $\boldsymbol{c}_k \in \{\boldsymbol{c}_i\}$ such that
$$\|\boldsymbol{x} - \boldsymbol{c}_k\| \leq \epsilon.$$

Proposition 2.0.6

Let $\mathcal{B} := \{\boldsymbol{x} \in \mathbb{R}^d : \|\boldsymbol{x}\|_2 \leq 1\}$ be a unit Euclidean ball, for any $0 < \epsilon < 1$ we have
$$N(\mathcal{B}, \epsilon) \geq \left(\frac{1}{\epsilon}\right)^d.$$

Proof. Let $\mathrm{vol}(\mathcal{B})$ denote the volume of $\mathcal{B}$ and $\mathrm{vol}(\epsilon\mathcal{B})$ denote the volume Euclidean ball of radius ϵ.

By the definition of covering numbers, we have
$$\mathrm{vol}(\mathcal{B}) \leq N(\mathcal{B}, \epsilon) \cdot \mathrm{vol}(\epsilon\mathcal{B}) = N(\mathcal{B}, \epsilon) \cdot \epsilon^d \cdot \mathrm{vol}(\mathcal{B}).$$

Hence, $N(\mathcal{B}, \epsilon) \geq \left(\frac{1}{\epsilon}\right)^d$. □

The proposition shows that the covering numbers of the unit Euclidean ball grows exponentially in dimensionality. Is there any set whose covering number is dimension-free?

Theorem 2.0.7: Covering numbers of Polytopes

Let $\mathcal{P} \subset \mathbb{R}^d$ be a polytope with m vertices and $\mathrm{diam}(\mathcal{P}) \leq r$.[a] Then $\mathcal{P}$ can be covered by *at most* $m^{\lceil \frac{r^2}{\epsilon^2} \rceil}$ Euclidean balls of radius $\epsilon > 0$, i.e.,
$$N(\mathcal{P}, \epsilon) \leq m^{\lceil \frac{r^2}{\epsilon^2} \rceil}.$$

[a] $\mathrm{diam}(\mathcal{P}) = \sup_{\boldsymbol{x}, \boldsymbol{y} \in \mathcal{P}} \|\boldsymbol{x} - \boldsymbol{y}\|_2$

Proof. Without loss of generality we assume that $\mathrm{diam}(\mathcal{P}) \leq 1$ and $\mathbf{0}$ belongs to the inside of $\mathcal{P}$.

Let $\mathcal{T} = (\boldsymbol{z}_i)_{i=1}^m$ be the vertices of $\mathcal{P}$. Note that $\mathcal{P}$ is a subset of $\mathrm{conv}(\mathcal{T})$ and $\mathcal{T}$ is bounded by 1.

By the approximate Caratheodory's theorem, for any $\boldsymbol{x} \in \mathrm{conv}(\mathcal{T})$, there exists a sequence of vertices $(\boldsymbol{z}_{i_j})_{j=1}^k$ and $\boldsymbol{z}_{i_j} \in \mathcal{T}$, such that

$$\|\boldsymbol{x} - \frac{1}{k}\sum_{j=1}^{k} \boldsymbol{z}_{i_j}\|_2 \leq \frac{1}{\sqrt{k}}, \quad \text{for any } k \in \mathbb{N}. \tag{ACT}$$

Let $\frac{1}{\sqrt{k}} \leq \epsilon$, $k \geq \frac{1}{\epsilon^2}$, and take $K = \lceil \frac{1}{\epsilon^2} \rceil$.

Denote $\mathcal{N} = \left\{ \frac{1}{K} \sum_{j=1}^{K} \boldsymbol{z}_{i_j} : \boldsymbol{z}_{i_j} \in \mathcal{T} \right\}$. The cardinality of $\mathcal{N}$ takes $|\mathcal{N}| = m^K$.

Let all elements of $\mathcal{N}$ be the centers of Euclidean balls with radius of ϵ. By (ACT), the union of these balls covers $\mathrm{conv}(\mathcal{T})$, and hence $\mathcal{P}$.

Therefore the smallest number of Euclidean balls with radius ϵ needed to cover $\mathcal{P}$ is less than m^K.

In summary $N(\mathcal{P}, \epsilon) \leq m^K = m^{\lceil \frac{1}{\epsilon^2} \rceil}$. □

The following theorem shows an application of the above reslut.

Theorem 2.0.8: Volume of Polytopes

Let $\mathcal{B} \subset \mathbb{R}^d$ be the unit Euclidean ball , and $\mathcal{P} \subset \mathcal{B}$ be a polytope with m vertices. Then

$$\frac{\mathrm{vol}(\mathcal{P})}{\mathrm{vol}(\mathcal{B})} \leq \left(4\sqrt{\frac{\log m}{d}}\right)^d.$$

Proof. Let $\epsilon\mathcal{B}$ denote the Euclidean ball with radius $\epsilon > 0$. By the definition of covering numbers, we have

$$\mathrm{vol}(\mathcal{P}) \leq N(\mathcal{P}, \epsilon) \cdot \mathrm{vol}(\epsilon\mathcal{B}) \overset{\text{cov. \# of poly.}}{=} \leq m^{\lceil \frac{1}{\epsilon^2} \rceil} \cdot \epsilon^d \cdot \mathrm{vol}(\mathcal{B}).$$

Hence

$$\frac{\mathrm{vol}(\mathcal{P})}{\mathrm{vol}(\mathcal{B})} \leq m^{\lceil \frac{1}{\epsilon^2} \rceil} \cdot \epsilon^d \leq m^{\frac{2}{\epsilon^2}} \cdot \epsilon^d$$

Minimizing the right hand side w.r.t. ϵ gives

$$\frac{\mathrm{vol}(\mathcal{P})}{\mathrm{vol}(\mathcal{B})} \leq e^{\frac{d}{2}} \left(\sqrt{\frac{4\log m}{d}}\right)^d \leq \left(4\sqrt{\frac{\log m}{d}}\right)^d.$$

□

Remark.

> Let $\delta = 4\sqrt{\frac{\log m}{d}}$, then $\mathrm{vol}(\mathcal{P}) \leq \delta^d \cdot \mathrm{vol}(\mathcal{B}) = \mathrm{vol}(\delta\mathcal{B})$. If the dimensionality d is sufficiently large, the volume of a convex polytope with its vertices on the surface of a unit Euclidean is smaller that a tiny ball $\delta\mathcal{B}$.

第三讲

1 Gaussian 尾界

集中不等式关心随机变量 X 偏离其期望 $\mathbb{E}(X)$ 的概率，各位熟悉 3σ 准则则是其中一种。

引理 1.1: 3σ 准则

设 $X \sim \mathcal{N}(\mu, \sigma^2)$, 则

$$P\{|X-\mu| \le 3\sigma\} \approx 0.9973.$$

下面我们将 3σ 准则推广至一般的情形。

引理 1.2: Gaussian 尾界

设 $X \sim \mathcal{N}(0,1)$, 则对任意 $t > 0$

$$P\{X \ge t\} \le \frac{1}{t\sqrt{2\pi}} \exp(-t^2/2).$$

证明. 已知

$$P\{X \ge t\} = \int_t^\infty \frac{1}{\sqrt{2\pi}} \exp(-x^2/2)\mathrm{d}x.$$

令 $x = t + y$, 其中 $y \ge 0$. 上式可以改写为

$$\begin{aligned}
P\{X \ge t\} &= \int_t^\infty \frac{1}{\sqrt{2\pi}} \exp(-x^2/2)\mathrm{d}x \\
&= \int_0^\infty \frac{1}{\sqrt{2\pi}} \exp\{-(t+y)^2/2\}\mathrm{d}y \\
&= \frac{1}{\sqrt{2\pi}} \int_0^\infty \exp\left(-\frac{t^2}{2}\right) \cdot \exp\left(-\frac{ty}{2}\right) \cdot \exp\left(-\frac{y^2}{2}\right) \mathrm{d}y \\
&\le \frac{1}{\sqrt{2\pi}} \int_0^\infty \exp\left(-\frac{t^2}{2}\right) \cdot \exp\left(-\frac{ty}{2}\right) \mathrm{d}y \\
&= \frac{1}{t\sqrt{2\pi}} \exp\left(-\frac{t^2}{2}\right).
\end{aligned}$$

□

2 概率估计间隙的一个例子

在给出例子之前, 先回忆一些概率论的基本概念和结论.

定理 2.1: Lindeberg-Lévy 中心极限定理

设 $X_1, X_2, \cdots$ 为一组独立同分布的随机变量序列, 对应的分布期望为 μ, 方差为 σ^2. 记它们的和为

$$S_N := X_1 + X_2 + \cdots + X_N,$$

并将其标准化为均值为 0, 方差为 1 的随机变量

$$Z_n = \frac{S_N - \mathbb{E}S_N}{\sqrt{Var(S_N)}} = \frac{1}{\sigma\sqrt{N}}\sum_{i=1}^{N}(X_i - \mu).$$

当 $N \to \infty$, Z_N依分布收敛于标准正态分布 $\mathcal{N}(0,1)$.

评论. *设 $X \sim \mathcal{N}(0,1)$, 上述定理的依分布分布收敛意味着,*

$$\lim_{N\to\infty} P\{S_n \geq t\} = P\{X \geq t\} \quad 对任意 t \in \mathbb{R}.$$

若 Lindeberg-Lévy 中心极限定理中随机变量序列的元素服从伯努利分布 $Ber(p)$, 即

$$P\{X_i = 1\} = p, P\{X_i = 0\} = 1 - p,$$

则有 $\mathbb{E}X_i = p$, $\mathrm{Var}(X_i) = p(1-p)$.

其 N 项和 S_N 服从二项分布 $Binom(N,p)$, 有 $\mathbb{E}S_N = Np$, $\mathrm{Var}(S_N) = Np(1-p)$.

由 Lindeberg-Lévy 中心极限定理知, 当 $N \to \infty$

$$\frac{S_N - Np}{\sqrt{Np(1-p)}} 依分布收敛于 \mathcal{N}(0,1).$$

中心极限定理只提供了一个收敛结局, 但没有关于其收敛快慢的分析. Berry-Esseen 中心极限定理作为其补充.

定理 2.2: Berry-Esseen 中心极限定理

在 Lindeberg-Lévy 中心极限定理的条件下, 对任意 $N \in \mathbb{N}$ 及任意 $t \in \mathbb{R}$,

$$|P\{Z_N \geq t\} - P\{X \geq t\}| \leq \frac{\rho}{\sqrt{N}},$$

其中 $\rho = \mathbb{E}|X_1 - \mu|^3/\sigma^3$, $X \sim \mathcal{N}(0,1)$.

概率估计. 投掷一枚均匀硬币 N, 至少有 $\frac{3}{4}N$ 次头像向上的概率是多少?

设投掷该硬币 N 次, 头像朝上的总次数为随机变量 $S_N \sim Binom(N, \frac{1}{2})$,

$$\mathbb{E}S_N = \frac{N}{2}, \quad \mathrm{Var}(S_N) = \frac{N}{4}.$$

由 Chebyshev 不等式,

$$P\{S_N \geq \frac{3}{4}N\} \leq P\{|S_N - \frac{N}{2}| \geq \frac{N}{4}\} \leq \frac{(N/4)}{(N/4)^2} = \frac{4}{N}.$$

此概率上界线性依赖于样本容量 N: N 增加一个尺度, 概率上界下降一个尺度.

另一方面, 我们从中心极限定理出发估计此概率上界. 当 $N \to \infty$,

$$\frac{S_N - N/2}{\sqrt{N/4}} \text{依分布收敛于} \mathcal{N}(0,1).$$

由 Gaussian 尾界

$$\begin{aligned} P\left\{S_N \geq \frac{3}{4}N\right\} &= P\left\{\frac{S_N - N/2}{\sqrt{N/4}} \geq \frac{\sqrt{N}}{2}\right\} \\ &\leq \frac{1}{\sqrt{2\pi}\sqrt{N/4}} \exp\left(-\frac{N}{8}\right) \\ &\leq \exp\left(-\frac{N}{8}\right) \quad \left(\frac{2}{\sqrt{2\pi N}} \leq 1\right) \end{aligned}$$

此概率上界随着样本容量 N 增加指数下降: N 增加一个尺度, 概率上界下降数倍尺度.

在上述例子中，取 $N = 80$,

$$\text{(Chebyshev 不等式估计)} \quad P\{S_N \geq 60\} \leq \frac{4}{80} = 0.05$$

$$\text{(Gaussian 尾界估计)} \quad P\{S_N \geq 60\} \leq \exp(-10) \approx 0.000045.$$

这是否意味着 Gaussian 尾界估计更准确? 事实并非如此, 在 Gaussian 尾界估计中, 我们假设了 $\frac{S_N - N/2}{\sqrt{N/4}}$ 近似服从标准正态分布, 此近似的误差依赖于 Lindeberg-Lévy 中心极限定理的收敛速度, 即 Berry-Esseen 中心极限定理的结论. 因此 Gaussian 尾界估计还依赖于 $\mathcal{O}(1/\sqrt{N})$, 其上界为

$$\mathcal{O}\left(1/\sqrt{N} + \exp(-N/8)\right) = \mathcal{O}(1/\sqrt{N}).$$

在这个例子中, 从中心极限定理出发能否得到一个比 $\mathcal{O}(1/\sqrt{N})$ 更好的上界估计? 答案是否定的. 考虑如下概率

$$P\{S_N = \frac{N}{2}\} = 2^{-N}\begin{pmatrix} N \\ N/2 \end{pmatrix} \asymp \frac{1}{\sqrt{N}} \quad \text{(Stirling 公式)},$$

由中心极限定理

$$P\{Z_N = 0\} \asymp \frac{1}{\sqrt{N}}$$

另一方面 $P\{X = 0\} = 0$, 若 $X \sim \mathcal{N}(0,1)$. 故

$$|P\{Z_N = 0\} - P\{X = 0\}| \asymp \frac{1}{\sqrt{N}}.$$

这说明在 Berry-Esseen 中心极限定理中, Z_n 的累积概率密度函数近似标准正态分布的累积概率密度函数估计误差 $\mathcal{O}(1/\sqrt{N})$ 不可避免.

为了获得更优的概率上界估计, 在下一讲中我们将绕开中心极限定理, 采用一种更直接的概率上界估计方法.

第四讲

1 Chernoff 技巧

若存在 $b > 0$ 使得对任意 $|\lambda| \leq b$ 函数 $\psi(\lambda) = \mathbb{E}\left[e^{\lambda(X-\mu)}\right]$ 存在, 则对任意 $\lambda \in [0, b]$, 由 Markov 不等式, 有

$$\mathbb{P}\left[X - \mu \geq t\right] = \mathbb{P}\left[e^{\lambda(X-\mu)} \geq e^{\lambda t}\right] \leq \frac{\mathbb{E}\left[e^{\lambda(X-\mu)}\right]}{e^{\lambda t}}. \tag{1}$$

上述不等式关于 λ 最小化得到此项的最小上界, 即

$$\mathbb{P}\left[X - \mu \geq t\right] \leq \inf_{\lambda \in [0,b]} \frac{\mathbb{E}\left[e^{\lambda(X-\mu)}\right]}{e^{\lambda t}}.$$

命题 1.1

设 $X \sim \mathcal{N}(\mu, \sigma^2)$, 则 $\mathbb{P}\left[X - \mu \geq t\right] \leq e^{-\frac{t^2}{2\sigma^2}}, \quad \forall t \geq 0.$

证明. 由直接计算可得, 对任意 $\lambda \in \mathbb{R}$,

$$\mathbb{E}\left[e^{\lambda X}\right] = e^{\mu\lambda + \frac{\sigma^2\lambda^2}{2}}$$

由 Chernoff 技巧, 对任意 $t \geq 0$

$$\begin{aligned}\mathbb{P}\left[X - \mu \geq t\right] &\leq \inf_{\lambda \in [0,+\infty)} \frac{\mathbb{E}\left[e^{\lambda(X-\mu)}\right]}{e^{\lambda t}}. \\ &= \inf_{\lambda \in [0,+\infty)} e^{-\lambda t + \frac{\sigma^2\lambda^2}{2}}\end{aligned}$$

求 $e^{-\lambda t + \frac{\sigma^2\lambda^2}{2}}$ 的最小值点等价求 $\log e^{-\lambda t + \frac{\sigma^2\lambda^2}{2}}$ 的最小值点, 后者的最小值点为 $\frac{t}{\sigma^2}$.

因此,

$$\begin{aligned}\mathbb{P}\left[X - \mu \geq t\right] &\leq \inf_{\lambda \in [0,+\infty)} e^{-\lambda t + \frac{\sigma^2\lambda^2}{2}} \\ &= e^{-\frac{t}{\sigma^2}t + \frac{\sigma^2}{2}(\frac{t}{\sigma^2})^2} = e^{-\frac{t^2}{2\sigma^2}}.\end{aligned}$$

□

2 Sub-Gaussain 变量

定义 2.1: Sub-Gaussain 变量

设有随机变量 X, 其期望 $\mathbb{E}[X]=\mu$, 若存在正数 $\sigma>0$ 使得

$$\mathbb{E}[e^{\lambda(X-\mu)}]\le e^{\frac{\sigma^2\lambda^2}{2}},\ \ \forall\lambda\in\mathbb{R}$$

则称 X 为 *sub-Gaussian* 随机变量, 称 σ 为 *sub-Gaussian* 参数.

评论. X 为 sub-Gaussian 当且仅当 $-X$ 为 sub-Gaussian.

由 Chernoff 技巧, 若 X 为 sub-Gaussian 随机变量, 对任意 $t\ge 0$

$$\mathbb{P}\left[X-\mu\ge t\right]\le e^{-\frac{t^2}{2\sigma^2}},$$

$-X$ 也为 sub-Gaussian 随机变量, 同理

$$\mathbb{P}\left[-X+\mu\ge t\right]=\mathbb{P}\left[X-\mu\le -t\right]\le e^{-\frac{t^2}{2\sigma^2}}.$$

因此, 参数为 σ 的 sub-Gaussian 随机变量 X 有尾界

$$\mathbb{P}\left[|X-\mu|\ge t\right]=\mathbb{P}\left[X-\mu\ge t\right]+\mathbb{P}\left[X-\mu\le -t\right]\le 2e^{-\frac{t^2}{2\sigma^2}}.$$

Rademacher 变量 Rademacher 随机变量 ϵ 等概率取 $+1$ 或 -1, 为参数 $\sigma=1$ 的 sub-Gaussian 变量.

显然 $\mathbb{E}[\epsilon]=0$, 对任意 $\lambda\in\mathbb{R}$,

$$\begin{aligned}\mathbb{E}[e^{\lambda\epsilon}]&=\frac{1}{2}e^{-\lambda}+\frac{1}{2}e^{\lambda}\\&=\frac{1}{2}\left\{\sum_{k=0}^{\infty}\frac{(-\lambda)^k}{k!}+\sum_{k=0}^{\infty}\frac{\lambda^k}{k!}\right\}\\&=\sum_{k=0}^{\infty}\frac{\lambda^{2k}}{(2k)!}\\&\le\sum_{k=0}^{\infty}\frac{\lambda^{2k}}{2^k k!}=e^{\frac{\lambda^2}{2}}.\end{aligned}$$

引理 2.1

设 X 为有界随机变量, 其支撑集为 $[a,b]$, 则随机变量 X 是以 $\sigma=b-a$ 为参数的 *sub-Gaussian* 随机变量.

证明. 不失一般性设 $\mathbb{E}X=0$.

设 X' 为独立于 X 的来自同一分布的随机变量, ϵ 为 Rademacher 随机变量.

对任意 $\lambda \in \mathbb{R}$,

$$\mathbb{E}_X[e^{\lambda X}] = \mathbb{E}_X[e^{\lambda(X-\mathbb{E}_{X'}[X'])}] = \mathbb{E}_X[e^{\mathbb{E}_{X'}[\lambda(X-X')]}] \le \mathbb{E}_{X,X'}[e^{\lambda(X-X')}].$$

最后的不等号源自 Jensen 不等式.

注意到 $\mathbb{E}_{X,X'}[e^{\lambda(X-X')}] = \mathbb{E}_{X,X'}[e^{\lambda(X'-X)}]$, 因此

$$\mathbb{E}_{X,X'}[e^{\lambda(X-X')}] = \mathbb{E}_{X,X'}\left[\mathbb{E}_\epsilon e^{\lambda(X-X')\epsilon}\right] \le \mathbb{E}_{X,X'}\left[e^{\frac{\lambda^2(X-X')^2}{2}}\right] \le e^{\frac{\lambda^2(b-a)^2}{2}}.$$

其中第一个不等号利用 Rademacher 随机变量的性质, 第二个不等号源自随机变量的有界性. □

评论. 上述证明过程通过引入同一分布的独立随机变量 X' 和 Rademacher 变量实现, 这种方法称为对称化技巧.

引理 2.2

设 X_1, X_2 分别为独立的, 以 σ_1, σ_2 为参数的 *sub-Gaussian* 随机变量, 则 $X_1 + X_2$ 为以 $\sqrt{\sigma_1^2 + \sigma_2^2}$ 为参数的 *sub-Gaussian* 随机变量.

3 Hoeffding 界

综合上述结论, 可以得到以下定理.

定理 3.1: Hoeffding 界

设以 σ_i 为参数的 *sub-Gaussian* 随机变量 $X_i, i = 1, \ldots, n$ 相互独立, 且 $\mathbb{E}[X_i] = \mu_i$, 则对任意 $t \ge 0$, 有

$$\mathbb{P}\left[\sum_{i=1}^n (X_i - \mu_i) \ge t\right] \le \exp\left\{-\frac{t^2}{2\sum\limits_{i=1}^n \sigma_i^2}\right\}$$

证明. 对任意 $\lambda \ge 0$

$$\begin{aligned}
\mathbb{P}\left[\sum_{i=1}^n (X_i - \mu_i) \ge t\right] &= \mathbb{P}\left[\exp\left(\lambda \sum_{i=1}^n (X_i - \mu_i)\right) \ge e^{\lambda t}\right] \\
&\le e^{-\lambda t}\mathbb{E}\left[\exp\left(\lambda \sum_{i=1}^n (X_i - \mu_i)\right)\right] \\
&= e^{-\lambda t}\mathbb{E}\left[\prod_{i=1}^n e^{\lambda(X_i - \mu_i)}\right] \\
&= e^{-\lambda t}\prod_{i=1}^n \mathbb{E}e^{\lambda(X_i-\mu_i)} \le e^{-\lambda t} + \prod_{i=1}^n e^{\frac{\lambda^2\sigma_i^2}{2}}.
\end{aligned}$$

不等式右端关于 λ 最小化即完成证明. $\square$

投硬币回顾 设 X_i 为 Bernoulli 变量, Z_i 为 Rademacher 变量, 则有 $Z_i = 2X_i - 1$, 已知 Z_i 是参数为 1 的 sub-Gaussian 变量, 应用 Hoeffding 不等式, 有

$$\mathbb{P}\left[\sum_{i=1}^{n} Z_i \geq t\right] \leq \exp\left(-\frac{t^2}{2n}\right), \quad \forall t \geq 0.$$

回顾第三讲中投掷硬币的例子

$$\mathbb{P}\left[\sum_{i=1}^{n} X_i \geq \frac{3}{4}n\right] = \mathbb{P}\left[\sum_{i=1}^{n} Z_i \geq \frac{1}{2}n\right] \leq \exp\left(-\frac{n}{8}\right).$$

由此得到比应用中心极限定理及 Markov 不等式更为准确的估计.

4 Chernoff 不等式及其在随机图上的应用

定理 4.1: Chernorff 不等式

设 X_i 为独立的, 以 p_i 为参数的伯努利随机变量, 其 N 项和 $S_N = \sum_{i=1}^{N} X_i$, 记 $\mathbb{E}S_N = \sum_{i=1}^{N} p_i = \mu$, 则对于任意 $t > \mu$, 有

$$\mathbb{P}\left[S_N \geq t\right] \leq e^{-\mu}\left(\frac{e\mu}{t}\right)^t.$$

证明. 类似 Hoeffding 不等式证明, 这里使用 Chernoff 技巧, 取 $\lambda \geq 0$.

$$\mathbb{P}\left[S_N \geq t\right] = \mathbb{P}\left[e^{\lambda S_N} \geq e^{\lambda t}\right] \leq e^{-\lambda t}\mathbb{E}\left[e^{\lambda S_N}\right] = e^{-\lambda t}\prod_{i=1}^{N}\mathbb{E}e^{\lambda X_i}.$$

由于

$$\mathbb{E}e^{\lambda X_i} = (1-p_i)e^{\lambda \cdot 0} + p_i e^{\lambda} = 1 - p_i + p_i e^{\lambda} \leq \exp((e^{\lambda}-1)p_i),$$

其中不等号源于不等式 $1 + x \leq e^x$.

故

$$\begin{aligned}
\mathbb{P}\left[S_N \geq t\right] &\leq e^{-\lambda t}\prod_{i=1}^{N}\exp((e^{\lambda}-1)p_i) \\
&= e^{-\lambda t}\exp\left((e^{\lambda}-1)\sum_{i=1}^{N} p_i\right) \\
&= e^{-\lambda t}\exp\left((e^{\lambda}-1)\mu\right)
\end{aligned}$$

不等式右端关于 λ 最小化, 取 $\lambda = \ln\frac{t}{\mu}$, 代入上述不等式, 即有

$$\mathbb{P}\left[S_N \geq t\right] \leq e^{-\mu}\left(\frac{e\mu}{t}\right)^t.$$

□

类似地, 可以得到以下定理

定理 4.2: Chernorff 不等式下界

设 X_i 为独立的, 以 p_i 为参数的伯努利随机变量, 其 N 项和 $S_N = \sum_{i=1}^{N} X_i$, 记 $\mathbb{E}S_N = \sum_{i=1}^{N} p_i = \mu$, 则对于任意 $0 < t < \mu$, 有

$$\mathbb{P}\left[S_N \leq t\right] \leq e^{-\mu}\left(\frac{e\mu}{t}\right)^t.$$

证明. 对任意 $\lambda \leq 0$,

$$\mathbb{P}[S_N \leq t] = \mathbb{P}[\lambda S_N \geq \lambda t] = \mathbb{P}\left[e^{\lambda S_N} \geq e^{\lambda t}\right],$$

证明余下部分与定理 4.2 证明相同. □

综合定理 4.1 和定理 4.2, 可以得到以下不等式尾界

引理 4.1

对任意 $x \in [0,1]$, 有不等式

$$x - (1+x)\log(1+x) \leq -\frac{x^2}{6}.$$

定理 4.3: Chernoff 不等式尾界

在定理 4.1 条件下, 对任意 $\delta \in (0,1]$,

$$\mathbb{P}\left[|S_N - \mu| \geq \delta\mu\right] \leq 2e^{-\mu\delta^2/6}.$$

证明. 若取 $t = (1+\delta)\mu > \mu$, 由定理 4.1,

$$\begin{aligned}
\mathbb{P}\left[S_N \geq (1+\delta)\mu\right] &\leq e^{-\mu}\left(\frac{e\mu}{(1+\delta)\mu}\right)^{(1+\delta)\mu} = e^{\delta\mu}\left(\frac{1}{1+\delta}\right)^{(1+\delta)\mu} \\
&= \exp\left\{\mu\left(\delta - (1+\delta)\log(1+\delta)\right)\right\} \\
&\leq e^{-\mu\delta^2/6}.
\end{aligned}$$

最后一个不等号取自引理 4.1.

若取 $t=(1-\delta)\mu<\mu$, 由定理 4.2,

$$\begin{aligned}\mathbb{P}\left[S_N \leq (1-\delta)\mu\right] &\leq e^{-\mu}\left(\frac{e\mu}{(1-\delta)\mu}\right)^{(1-\delta)\mu} = e^{-\delta\mu}\left(\frac{1}{1-\delta}\right)^{(1-\delta)\mu} \\ &= \exp\left\{\mu\left(-\delta-(1-\delta)\log(1-\delta)\right)\right\} \\ &\leq e^{-\mu\delta^2/6}.\end{aligned}$$

综上, 有

$$\mathbb{P}\left[|S_N-\mu|\geq\delta\mu\right]=\mathbb{P}\left[S_N\geq(1+\delta)\mu\right]+\mathbb{P}\left[S_N\leq(1-\delta)\mu\right]\leq 2e^{-\mu\delta^2/6}.$$

□

定义 4.1: Eröds-Rényi 模型

给定 n 个节点, 节点间连边相互独立且服从以 p 为参数的伯努利分布, 记此随机图为 $\mathcal{G}(n,p)$.

在 Eröds-Rényi 模型中, 随机图每一个节点度的期望为 $(n-1)p$. 由 Chernoff 尾界, 当随机图的节点度期望足够大时, 每一节点度几乎是相同的.

命题 4.1

考虑随机图 $G\sim\mathcal{G}(n,p)$, 对任意 $\delta\in(0,1)$, 若 $d:=(n-1)p\geq\frac{6}{\delta^2}\log\frac{2n}{\delta}$, 则有

$$\mathbb{P}\left[\forall i, |d_i-d|\leq\delta d\right]\geq 1-\delta$$

其中 d_i 为节点 i 的度.

证明. 固定任意节点 i, 由 Chernoff 不等式尾界,

$$\mathbb{P}[|d_i-d|\geq\delta d]\leq 2e^{-d\delta^2/6}$$

由事件联合界

$$\mathbb{P}[\exists i, |d_i-d|\geq\delta d]\leq\sum_{i=1}^{n}\mathbb{P}[|d_i-d|\geq\delta d]\leq 2ne^{-d\delta^2/6}.$$

令 $\delta\geq 2ne^{-d\delta^2/6}$, 解得

$$d\geq\frac{6}{\delta^2}\log\frac{2n}{\delta}.$$

此时

$$\mathbb{P}\left[\forall i, |d_i-d|\leq\delta d\right]=1-\mathbb{P}[\exists i, |d_i-d|\geq\delta d]\geq 1-\delta.$$

□

第五讲

王伟文　暨南大学

图 1: 课程网页二维码

1 Sub-exponential 变量

定义 1.1: Sub-exponential 变量

设随机变量 X 的期望为 $\mathbb{E}X = \mu$, 若存在非负参数 (ν, α) 满足

$$\mathbb{E}\left[e^{\lambda(X-\mu)}\right] \leq e^{\frac{\nu^2\lambda^2}{2}} \quad \forall |\lambda| < \frac{1}{\alpha}.$$

则称 X 为 *sub-exponential* 变量.

评论. Sub-Gaussian 变量一定是 sub-exponential 变量, 反之不成立.

例 设 $Z \sim \mathcal{N}(0,1)$, $X = Z^2$, $\mathbb{E}X = \mathbb{E}Z^2 = 1$.

$$\mathbb{E}\left[e^{\lambda(X-1)}\right] = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{+\infty} e^{\lambda(z^2-1)} e^{-z^2/2} dz = \frac{e^{-\lambda}}{\sqrt{1-2\lambda}}$$

若 $\lambda \geq \frac{1}{2}$, 矩母函数不存在, 这表明 X 不是 sub-Gaussian 变量.

另一方面, 利用 $\ln(1-x)$ 的泰勒级数展开, 可证明

$$\frac{e^{-\lambda}}{\sqrt{1-2\lambda}} \leq e^{2\lambda^2} = e^{4\lambda^2/2}, \quad \forall\, |\lambda| < \frac{1}{4}.$$

故 X 是以 $(2,4)$ 为参数的 sub-exponential 变量.

引理 1.1

设 $X_i, i=1,2,\ldots,n$ 为相互独立的、以 (ν_i,α_i) 为参数的 *sub-exponential* 随机变量, $\mathbb{E}X_i=\mu_i$, 则 $\sum\limits_{i=1}^{n}(X_i-\mu_i)$ 是以 $(\tilde{\nu},\tilde{\alpha})$ 为参数的 *sub-exponential* 随机变量, 其中 $\tilde{\alpha}=\max\limits_{i=1,\ldots,n}\alpha_i, \tilde{\nu}=\sqrt{\sum\limits_{i=1}^{n}\nu_i^2}$.

证明. 结论直接由定义得到. □

2 Sub-exponential 变量尾界

命题 2.1: Sub-exponential 变量尾界

设 X 是以 (ν,α) 为参数的 *sub-exponential* 变量, 则

$$\mathbb{P}\left[X-\mu\geq t\right]\leq\begin{cases}e^{-\frac{t^2}{2\nu^2}}, & 0\leq t\leq\dfrac{\nu^2}{\alpha},\\ e^{-\frac{t}{2\alpha}}, & t\geq\dfrac{\nu^2}{\alpha}.\end{cases}$$

证明. 不失一般性假设 $\mu=0$. 由 Chernoff 技巧, $\forall\lambda\in(0,\frac{1}{\alpha})$ 有

$$\mathbb{P}\left[X\geq t\right]\leq e^{-\lambda t}\leq\exp\left(-\lambda t+\frac{\nu^2\lambda^2}{2}\right).$$

记 $h(\lambda)=-\lambda t+\frac{\nu^2\lambda^2}{2}$. 当 $\lambda=\frac{t}{\nu^2}$ 时, $g(\lambda)$ 取得最小值 $g(\frac{t}{\nu^2})=-\frac{t^2}{2\nu^2}$.

故若 $0\leq\frac{t}{\nu^2}\leq\frac{1}{\alpha}$, 即 $0\leq t\leq\frac{\nu^2}{\alpha}$,

$$\mathbb{P}\left[X\geq t\right]\leq e^{-\frac{t^2}{2\nu^2}}.$$

若 $\frac{t}{\nu^2}>\frac{1}{\alpha}$, 即 $t>\frac{\nu^2}{\alpha}$,

$$\inf_{\lambda\in(0,\frac{1}{\alpha})}g(\lambda)=g(\frac{1}{\alpha})=-\frac{t}{\alpha}+\frac{\nu^2}{2\alpha^2}\leq-\frac{t}{\alpha}+\frac{t}{2\alpha}=-\frac{t}{2\alpha}.$$

此时

$$\mathbb{P}\left[X\geq t\right]\leq e^{-\frac{t}{2\alpha}}.$$

□

设 $X_i, i=1,2,\ldots,n$ 为相互独立的、以 (ν_i,α_i) 为参数的 sub-exponential 随机变量, $\mathbb{E}X_i=\mu_i$,

由命题 2.1 有

$$\mathbb{P}\left[\frac{1}{n}\sum(X_i-\mu_i)\geq t\right]\leq\begin{cases}e^{-\frac{nt^2}{2(\tilde{\nu}^2/n)}}, & 0\leq t\leq\dfrac{\tilde{\nu}^2}{n\tilde{\alpha}},\\ e^{-\frac{nt}{2\tilde{\alpha}}}, & t\geq\dfrac{\tilde{\nu}^2}{n\tilde{\alpha}}.\end{cases}$$

3 Bernstein 型尾界

定义 3.1: Bernstein 条件

给定随机变量 X, 期望 $\mathbb{E}X=\mu$, 方差 $\sigma^2=\mathbb{E}X^2-\mu^2$, 称 X 以 $b(>0)$ 为参数满足 *Bernstein* 条件, 若

$$\left|\mathbb{E}\left[(X-\mu)^k\right]\right|\leq\frac{1}{2}k!\sigma^2b^{k-2}$$

关于 $k=2,3,4,\ldots$ 成立.

命题 3.1

若 X 满足以 b 为参数的 *Bernstein* 条件, 则 X 是以 $(\sqrt{2}\sigma,2b)$ 为参数的 *sub-exponential* 变量.

证明.

$$\begin{aligned}\mathbb{E}\left[e^{\lambda(X-\mu)}\right]&=\mathbb{E}\left[\sum_{k=0}^{\infty}\frac{\lambda^k(X-\mu)^k}{k!}\right]\\&=1+\frac{\lambda^2\sigma^2}{2}+\sum_{k=3}^{\infty}\frac{\lambda^k\mathbb{E}(X-\mu)^k}{k!}\\&\overset{(i)}{\leq}1+\frac{\lambda^2\sigma^2}{2}+\sum_{k=3}^{\infty}\frac{\lambda^k\sigma^2b^{k-2}}{2}\\&\leq 1+\frac{\lambda^2\sigma^2}{2}\left(1+\sum_{k=3}^{\infty}(|\lambda|b)^{k-2}\right)\\&\overset{(ii)}{=}1+\frac{\lambda^2\sigma^2}{2}\cdot\frac{1}{1-|\lambda|b}\end{aligned}$$

其中利用 Bernstein 条件, 有不等式 (i) 成立; 若 $|\lambda|b<1$ 即 $|\lambda|<\frac{1}{b}$, 由 $\frac{1}{1-x}$ 的泰勒级数展开得到等式 (ii).

又因为 $1+x\leq e^x$ 对任意 $x\in\mathbb{R}$ 成立, 故

$$\begin{aligned}\mathbb{E}\left[e^{\lambda(X-\mu)}\right]&\leq 1+\frac{\lambda^2\sigma^2}{2}\cdot\frac{1}{1-|\lambda|b}\leq\exp\left(\frac{\lambda^2\sigma^2}{2-2|\lambda|b}\right)\\&\overset{(iii)}{\leq}\exp\left(\lambda^2(\sqrt{2}\sigma)^2/2\right).\end{aligned}$$

其中不等式 (iii) 成立若 $|\lambda|\leq\frac{1}{2b}$. □

评论. 上述证明过程表明, 命题 3.1 中的 sub-exponential 参数不唯一.

由命题 3.1 结合 Chernoff 技巧, 有如下结论.

定理 3.1: Bernstein 型尾界

对任意满足以 b 为参数的 Bernstein 条件的随机变量 X, 有

$$\mathbb{E}\left[e^{\lambda(X-\mu)}\right] \le \exp\left(\frac{\lambda^2\sigma^2}{2-2|\lambda|b}\right) \quad \forall|\lambda| < \frac{1}{b}$$

且满足集中不等式

$$\mathbb{P}\left[|X-\mu| \ge t\right] \le e^{-\frac{t^2}{2(\sigma^2+bt)}} \quad \forall t \ge 0.$$

证明. 1. 定理中的第一个不等式由命题 3.1 的证明过程得到.

2. 从 Chernoff 技巧出发, 由第一个不等式取 $\lambda = \frac{t}{bt+\sigma^2} \in [0, \frac{1}{b})$ 得证. □

评论. *对于有界随机变量即满足 $|X-\mu| \le b$, 可以证明 $X-\mu$ 是以 b 为参数的 sub-Gaussian 随机变量, 从而得到 Hoeffding 型尾界. 另一方面, X 满足 Bernstein 条件, 从而有 Bernstein 型尾界. 由有界性, $\sigma^2 = \mathbb{E}(X-\mu)^2 \le b^2$. 若 t 很小, 在忽略 bt 影响的情形下, Bernstein 型尾界是比 Hoeffding 型尾界更好的估计, 尤其是在 $\sigma^2 \ll b^2$ 的情形下.*

4 应用

χ^2 变量. 设 $Z_k \sim \mathcal{N}(0,1)$, 则 $Y = \sum_{k=1}^{n} Z_k^2$ 为自由度是 n 的 χ^2 随机变量. 第一节中的例子表明 Z_k^2 是以 $(2,4)$ 为参数的 sub-exponential 随机变量, Y 是以 $(2\sqrt{n}, 4)$ 为参数的 sub-exponential 随机变量. 由前述内容可知

$$\mathbb{P}\left[\left|\frac{1}{n}\sum_{k=1}^{n} Z_k^2 - 1\right| \ge t\right] \le 2e^{-nt^2/8}, \quad \forall t \in (0,1).$$

下述 Johnson-Lindenstrauss 引理表明高维空间中随机投影在欧式距离度量下具有近似保距离的性质.

引理 4.1: Johnson-Lindenstrauss 引理

给定 p 维空间中 N 个互异点 $\{u_i\}_{i=1}^N \subset \mathbb{R}^p$. 存在投影 $F: \mathbb{R}^p \to \mathbb{R}^d$, 取 $\delta \in (0,1)$, 当 $d \ge \frac{8}{\delta^2}\log\frac{N^2}{\epsilon}$ 时,

$$\forall (u_i, u_j), i \ne j, (1-\delta)\|u_i - u_j\|^2 \le \|Fu_i - Fu_j\|^2 \le (1+\delta)\|u_i - u_j\|^2$$

至少以 $1-\epsilon$ 成立.

证明. 设 $P \in \mathbb{R}^{d\times p}$ 为随机矩阵, 其中每一个元素 $p_{ij} \sim \mathcal{N}(0,1)$ 且相互独立. 记 p_i 表示矩阵 P 第 i 行.

对于任意向量 $v \in \mathbb{R}^p$, $\langle p_i, \frac{v}{\|v\|} \rangle \sim N(0,1)$. 因此

$$Y := \frac{\|Pv\|^2}{\|v\|^2} = \sum_{i=1}^{d} \langle p_i, \frac{v}{\|v\|} \rangle^2$$

为自由度为 d 的 χ^2 变量.

给定 $u_i, u_j, i \neq j$, 由 χ^2 变量的集中不等式, 有

$$\mathbb{P}\left[\left|\frac{1}{d}\frac{\|Pu_i - Pu_j\|^2}{\|u_i - u_j\|^2} - 1\right| \geq \delta\right] \leq 2e^{-d\delta^2/8}.$$

故

$$\begin{aligned}\mathbb{P}\left[\exists (i,j), i \neq j : \left|\frac{1}{d}\frac{\|Pu_i - Pu_j\|^2}{\|u_i - u_j\|^2} - 1\right| \geq \delta\right] &\leq \sum_{i \neq j} \mathbb{P}\left[\left|\frac{1}{d}\frac{\|Pu_i - Pu_j\|^2}{\|u_i - u_j\|^2} - 1\right| \geq \delta\right] \\ &\leq \binom{N}{2} 2e^{-d\delta^2/8} \leq N^2 e^{-d\delta^2/8}\end{aligned}$$

令 $N^2 e^{-d\delta^2/8} \leq \epsilon$, 解得 $d \geq \frac{8}{\delta^2} \log \frac{N^2}{\epsilon}$, 此时

$$\mathbb{P}\left[\forall (i,j), i \neq j : \left|\frac{1}{d}\frac{\|Pu_i - Pu_j\|^2}{\|u_i - u_j\|^2} - 1\right| \leq \delta\right] \geq 1 - \epsilon.$$

定义随机投影 $F : u \in \mathbb{R}^p \mapsto \frac{Pu}{\sqrt{d}} \in \mathbb{R}^d$, 得证. $\square$

第六讲

王伟文　暨南大学

1　有界差不等式

我们称函数 $\mathbb{R}^d \to \mathbb{R}$ 满足以 $(L_1, L_2, \cdots, L_d)$ 为参数的有界差不等式, 若对于任意坐标 $k \in [d]$, 存在参数 $L_k > 0$ 使得

$$|f(\boldsymbol{x}) - f(\boldsymbol{x}^{\setminus k})| \le L_k \quad \forall \boldsymbol{x} \in \mathbb{R}^d, \forall \boldsymbol{x}^{\setminus k} \in \{(x_1, x_2, \cdots, \underbrace{x'}_{k}, \cdots, x_d) : x' \in \mathbb{R}\}$$

引理 1.1

若 f 满足以 $(L_1, L_2, \cdots, L_d)$ 为参数的有界差分不等式, 随机向量 $X = (X_1, X_2, \cdots, X_d)$ 各分量相互独立, 则

$$\mathbb{P}\left[|f(X) - \mathbb{E}\left[f(X)\right]| \ge t\right] \le 2e^{-\frac{2t^2}{\sum\limits_{i=1}^{d} L_i^2}} \quad \forall t \ge 0.$$

例 1.1. 设 $X_i \in [a, b]$ 且相互独立 $(i = 1, 2, \cdots, n)$, $\mathbb{E}X_i = \mu_i$. 记 $X = (X_1, \ldots, X_n)$, $f(X) = \sum\limits_{i=1}^{n}(X_i - \mu_i)$.

$$\begin{aligned}|f(x_1, \cdots, x_k, \cdots, x_n) - f(x_1, \cdots, x'_k, \cdots, x_n)| &= |(x_k - \mu_k) - (x'_k - \mu_k)| \\ &= |x_k - x'_k| \le b - a \quad \forall k \in [n].\end{aligned}$$

故 f 满足有界差不等式, 因此

$$\mathbb{P}\left[|f(X) - \mathbb{E}\left[f(X)\right]| \ge t\right] = \mathbb{P}\left[\left|\sum_{i=1}^{n}(X_i - \mu_i)\right| \ge t\right] \le 2e^{-\frac{2t^2}{n(b-a)^2}} \quad \forall t \ge 0.$$

例 1.2. 随机图中的圈数. 给定无向图 $G = (V, E)$, 其中 $V = \{1, 2, \ldots, d\}$ 表示图中顶点集合, E 表示图中连边的集合. 图上的圈 C 为顶点集合的子集, 其中任意两个元素存在连边. 图的圈数 $C(G)$ 为图上最大圈的元素个数. $C(G) \in [1, d]$.

在 Erdöds-Rényi 模型中, 随机图由 $m := \binom{d}{2}$ 维的随机向量 $Z = (X_{ij})_{i<j}$ 刻画, $X_{ij} \sim \mathrm{Ber}(p)$ 且相互独立, 指示节点 i 与 j 之间是否存在连边, $C(G)$ 为随机变量. 显然 Z 唯一确定 $C(G)$, 因此 $C(G)$ 可以表示为 Z 的函数 $f : \{0, 1\}^m \to [d]$. 容易确定, 对任意 $k \in [m]$

$$|f(z_1, \cdots, z_k, \cdots, z_m) - f(z_1, \cdots, z'_k, \cdots, z_m)| \le 1.$$

故 f 满足有界差不等式, 由引理 1.1

$$\mathbb{P}\left[\frac{1}{m}|C(G)-\mathbb{E}\left[C(G)\right]|\geq\delta\right]\leq 2e^{-2m\delta^2}\quad\forall\delta\geq 0.$$

例 1.3. Rademacher 复杂度. 设 $\mathcal{A}$ 为 n 维实空间的子集 $\mathcal{A}\subset\mathbb{R}^n$, $\boldsymbol{\epsilon}=(\epsilon_i)_{i\in[n]}$ 为一组相互独立的 Rademacher 随机变量, 定义随机变量

$$Z=\sup_{\boldsymbol{a}\in\mathcal{A}}[\langle\boldsymbol{a},\boldsymbol{\epsilon}\rangle]=\sup_{\boldsymbol{a}\in\mathcal{A}}\sum_{i=1}^{n}a_i\epsilon_i$$

称 $\mathcal{R}(\mathcal{A}):=\mathbb{E}Z$ 为集合 $\mathcal{A}$ 的 Rademacher 复杂度.

记 $Z=f(\epsilon_1,\ldots,\epsilon_n)$.

$$\langle\boldsymbol{a},\boldsymbol{\epsilon}\rangle-\langle\boldsymbol{a},\boldsymbol{\epsilon}^{\backslash k}\rangle=a_k(\epsilon_k-\epsilon_k')$$

故

$$\sup_{\boldsymbol{a}\in\mathcal{A}}\{\langle\boldsymbol{a},\boldsymbol{\epsilon}\rangle-\langle\boldsymbol{a},\boldsymbol{\epsilon}^{\backslash k}\rangle\}=\sup_{\boldsymbol{a}\in\mathcal{A}}a_k(\epsilon_k-\epsilon_k')\leq 2\sup_{\boldsymbol{a}\in\mathcal{A}}|a_k|$$

因为

$$\langle\boldsymbol{a},\boldsymbol{\epsilon}\rangle-\sup_{\boldsymbol{a}'\in\mathcal{A}}\langle\boldsymbol{a}',\boldsymbol{\epsilon}^{\backslash k}\rangle\leq\langle\boldsymbol{a},\boldsymbol{\epsilon}\rangle-\langle\boldsymbol{a},\boldsymbol{\epsilon}^{\backslash k}\rangle$$

$$\sup_{\boldsymbol{a}\in\mathcal{A}}\{\langle\boldsymbol{a},\boldsymbol{\epsilon}\rangle-\sup_{\boldsymbol{a}'\in\mathcal{A}}\langle\boldsymbol{a}',\boldsymbol{\epsilon}^{\backslash k}\rangle\}\leq\sup_{\boldsymbol{a}\in\mathcal{A}}\{\langle\boldsymbol{a},\boldsymbol{\epsilon}\rangle-\langle\boldsymbol{a},\boldsymbol{\epsilon}^{\backslash k}\rangle\}\leq 2\sup_{\boldsymbol{a}\in\mathcal{A}}|a_k|$$

即

$$\sup_{\boldsymbol{a}\in\mathcal{A}}\langle\boldsymbol{a},\boldsymbol{\epsilon}\rangle-\sup_{\boldsymbol{a}'\in\mathcal{A}}\langle\boldsymbol{a}',\boldsymbol{\epsilon}^{\backslash k}\rangle\leq 2\sup_{\boldsymbol{a}\in\mathcal{A}}|a_k|$$

所以

$$f(\epsilon_1,\ldots,\epsilon_k,\ldots\epsilon_n)-f(\epsilon_1,\ldots,\epsilon_k',\ldots,\epsilon_n)\leq 2\sup_{\boldsymbol{a}\in\mathcal{A}}|a_k|$$

同理得到

$$f(\epsilon_1,\ldots,\epsilon_k',\ldots\epsilon_n)-f(\epsilon_1,\ldots,\epsilon_k,\ldots,\epsilon_n)\leq 2\sup_{\boldsymbol{a}\in\mathcal{A}}|a_k|$$

f 满足以 $\left(2\sup_{\boldsymbol{a}\in\mathcal{A}}|a_k|\right)_{k\in[n]}$ 为参数的有界差不等式.

$$\mathbb{P}\left[|Z-\mathbb{E}Z|\geq t\right]\leq 2e^{-\frac{t^2}{2\sum_{k=1}^{n}(a_k^*)^2}}\quad\forall t\geq 0,$$

其中 $a_k^*=\sup_{\boldsymbol{a}\in\mathcal{A}}|a_k|$.

2 高斯变量的 Lipschitz 函数

引理 2.1

设 $f:\mathbb{R}^n\to\mathbb{R}$ 可微, 对于任意凸函数 $\phi:\mathbb{R}\to\mathbb{R}$, 有

$$\mathbb{E}\left[\phi\left(f(X)-\mathbb{E}[f(X)]\right)\right]\le\mathbb{E}\left[\phi\left(\frac{\pi}{2}\langle\nabla f(X),Y\rangle\right)\right],$$

其中 $X,Y\sim\mathcal{N}(\mathbf{0},\boldsymbol{I}_n)$, 且 X 与 Y 独立.

定理 2.1

设 $f:\mathbb{R}^n\to\mathbb{R}$ 可微且 *L-Lipschitz* 连续, $X=(X_1,X_2,\ldots,X_n)$ 为随机向量, 其中元素相互独立且服从标准高斯 (正态) 分布, 则 $f(X)-\mathbb{E}[f(X)]$ 为以 $\frac{\pi L}{2}$ 为参数的 *sub-Gaussian* 变量, 故有

$$\mathbb{P}\left[|f(X)-\mathbb{E}[f(X)]|\ge t\right]\le 2e^{-\frac{2t^2}{\pi^2L^2}}\quad\forall t\ge 0.$$

证明. 对任意 $\lambda\in\mathbb{R}$, 定义 $\phi(\cdot)=\exp(\lambda\cdot)$, ϕ 为凸函数, 由引理 2.1,

$$\mathbb{E}\left[\exp\left(\lambda(f(X)-\mathbb{E}[f(X)])\right)\right]\le\mathbb{E}_{X,Y}\left[\exp\left(\langle\frac{\lambda\pi}{2}\nabla f(X),Y\rangle\right)\right].$$

因为 X 与 Y 相互独立, 且 $Y\sim\mathcal{N}(\mathbf{0},\boldsymbol{I}_n)$,

$$\begin{aligned}\mathbb{E}_{X,Y}\left[\exp\left(\langle\frac{\lambda\pi}{2}\nabla f(X),Y\rangle\right)\right]&=\mathbb{E}_X\mathbb{E}_Y\left[\exp\left(\langle\frac{\lambda\pi}{2}\nabla f(X),Y\rangle\right)\right]\\&=\mathbb{E}_X\left[\frac{1}{(2\pi)^{n/2}}\int_{\mathbb{R}^n}\exp\left(-\frac{1}{2}\boldsymbol{y}^T\boldsymbol{y}+\langle\frac{\lambda\pi}{2}\nabla f(X),y\rangle\right)\mathrm{d}\boldsymbol{y}\right]\\&=\mathbb{E}_X\left[\exp\left(\frac{\lambda^2\pi^2}{8}\|\nabla f(X)\|^2\right)\right]\\&\le\exp\left(\frac{\lambda^2\pi^2}{8}L^2\right)\qquad(L-\text{Lipschitz})\end{aligned}$$

故

$$\mathbb{E}\left[\exp\left(\lambda(f(X)-\mathbb{E}[f(X)])\right)\right]\le\exp\left(\frac{\lambda^2\pi^2}{8}L^2\right)$$

即 $f(X)-\mathbb{E}[f(X)]$ 是以 $\frac{\pi L}{2}$ 为参数的 sub-Gaussian 变量. □

例 2.1. χ^2 集中不等式. 设随机向量 $Z=(Z_k)_{k\in[n]}$ 中元素为相互独立的标准正态分布随机变量, 则 $Y=\|Z\|^2=\sum\limits_{k=1}^{n}Z_k^2$ 服从自由度是 n 的 χ^2 分布.

定义函数 $f:\boldsymbol{v}\in\mathbb{R}^n\mapsto\frac{\|\boldsymbol{v}\|}{\sqrt{n}}$,$f$ 为 $\frac{1}{\sqrt{n}}$-Lipshitz 连续函数, 由定理 2.1

$$\mathbb{P}\left[\frac{\sqrt{Y}}{\sqrt{n}}-\frac{1}{\sqrt{n}}\mathbb{E}[\sqrt{Y}]\ge t\right]\le e^{-\frac{2nt^2}{\pi^2}}\quad\forall t\ge 0.$$

因为 $\frac{1}{\sqrt{n}}\mathbb{E}[\sqrt{Y}] \le \frac{1}{\sqrt{n}}\sqrt{\mathbb{E}[Y]} = 1$, 故有

$$\mathbb{P}\left[\frac{\sqrt{Y}}{\sqrt{n}} - 1 \ge t\right] \le \mathbb{P}\left[\frac{\sqrt{Y}}{\sqrt{n}} - \frac{1}{\sqrt{n}}\mathbb{E}[\sqrt{Y}] \ge t\right] \le e^{-\frac{2nt^2}{\pi^2}} \quad \forall t \ge 0.$$

因此

$$\mathbb{P}\left[Y \ge n(1+t)^2\right] \le e^{-\frac{2nt^2}{\pi^2}} \quad \forall t \ge 0.$$

因为 $(1+t)^2 = 1 + 2t + t^2 \le 1 + 3t, t \in (0,1)$

$$\mathbb{P}\left[Y \ge n(1+3t)\right] \le \mathbb{P}\left[Y \ge n(1+t)^2\right] \quad \forall t \in (0,1).$$

令 $\delta = 3t$, 可整理得到

$$\mathbb{P}\left[Y \ge n(1+\delta)\right] \le e^{-\frac{2n\delta^2}{9\pi^2}} \le e^{-\frac{n\delta^2}{72}} \quad \forall \delta \in (0,3).$$

例 2.2. Gaussian 复杂度. 设随机向量 $\boldsymbol{w} = (w_i)_{i\in[n]}$ 中元素相互独立且服从标准高斯分布, 对于集合 $\mathcal{A} \subset \mathbb{R}^n$, 定义随机变量

$$Z := \sup_{\boldsymbol{a}\in\mathcal{A}} \langle \boldsymbol{a}, \boldsymbol{w} \rangle$$

称 $\mathcal{G}(Z) := \mathbb{E}Z$ 为集合 $\mathcal{A}$ 的 Gaussian 复杂度.

定义函数 $f : \boldsymbol{w} \mapsto \sup\limits_{\boldsymbol{a}\in\mathcal{A}} \langle \boldsymbol{a}, \boldsymbol{w} \rangle$. 由 Cauchy-Schwartz 不等式

$$\sup_{\boldsymbol{a}\in\mathcal{A}} \langle \boldsymbol{a}, \boldsymbol{w} - \boldsymbol{w}' \rangle \le (\sup_{\boldsymbol{a}\in\mathcal{A}} \|\boldsymbol{a}\|) \cdot \|\boldsymbol{w} - \boldsymbol{w}'\|.$$

又因为

$$f(\boldsymbol{w}) - f(\boldsymbol{w}') = \sup_{\boldsymbol{a}\in\mathcal{A}} \langle \boldsymbol{a}, \boldsymbol{w} \rangle - \sup_{\boldsymbol{a}'\in\mathcal{A}} \langle \boldsymbol{a}', \boldsymbol{w}' \rangle \le \sup_{\boldsymbol{a}\in\mathcal{A}} \langle \boldsymbol{a}, \boldsymbol{w} - \boldsymbol{w}' \rangle$$

故

$$f(\boldsymbol{w}) - f(\boldsymbol{w}') \le (\sup_{\boldsymbol{a}\in\mathcal{A}} \|\boldsymbol{a}\|) \cdot \|\boldsymbol{w} - \boldsymbol{w}'\|$$

同理

$$f(\boldsymbol{w}) - f(\boldsymbol{w}) \le (\sup_{\boldsymbol{a}\in\mathcal{A}} \|\boldsymbol{a}\|) \cdot \|\boldsymbol{w} - \boldsymbol{w}'\|$$

记 $D(\mathcal{A}) = \sup\limits_{\boldsymbol{a}\in\mathcal{A}} \|\boldsymbol{a}\|$, 函数 f 为 $D(\mathcal{A})$-Lipschitz 连续. 由定理 2.1

$$\mathbb{P}\left[|Z - \mathbb{E}Z| \ge t\right] \le 2e^{-\frac{2t^2}{\pi^2 D^2(\mathcal{A})}} \quad \forall t \ge 0.$$

例 2.3. Gaussian 混沌. 设 $\boldsymbol{w} \in \mathbb{R}^n$ 和 $\tilde{\boldsymbol{w}} \in \mathbb{R}^n$ 为相互独立的标准 Gaussian 变量. 给定对称矩阵 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$, 定义随机变量

$$Z = \boldsymbol{w}^T \boldsymbol{A} \tilde{\boldsymbol{w}}$$

称 Z 为 Gaussian 混沌.

容易知道

- $\mathbb{E}[Z]=0$
- 在给定 $\tilde{\boldsymbol{w}}$ 条件下, Z 为均值为 0, 方差为 $\|\boldsymbol{A}\tilde{\boldsymbol{w}}\|^2$ 的 Gaussian 随机变量, 因此

$$\mathbb{P}[|Z|\geq t|\tilde{\boldsymbol{w}}]\leq \exp\left(-\frac{t^2}{2\|\boldsymbol{A}\tilde{\boldsymbol{w}}\|^2}\right)\quad \forall t\geq 0.$$

定义随机变量 $Y:=\|\boldsymbol{A}\tilde{\boldsymbol{w}}\|$, 记 $Y=f(\tilde{\boldsymbol{w}})$, 则函数是 $\|\boldsymbol{A}\|_2$-Lipschitz 连续. 由定理 2.1 有

$$\mathbb{P}\left[Y-\mathbb{E}[Y]\geq\delta\right]\leq \exp\left(-\frac{2\delta^2}{\pi^2\|\boldsymbol{A}\|_2^2}\right)\quad \forall\delta\geq 0.$$

注意到 $\mathbb{E}[Y^2]=\mathbb{E}\left[\tilde{\boldsymbol{w}}^T\boldsymbol{A}^T\boldsymbol{A}\tilde{\boldsymbol{w}}\right]=\text{trace}(\boldsymbol{A}^T\boldsymbol{A})=\|\boldsymbol{A}\|_F^2$, 由 Jensen 不等式

$$\mathbb{E}[Y]=\mathbb{E}[\sqrt{Y^2}]\leq\sqrt{\mathbb{E}[Y^2]}=\|\boldsymbol{A}\|_F$$

故

$$\mathbb{P}\left[Y-\|\boldsymbol{A}\|_F\geq\delta\right]\leq\mathbb{P}\left[Y-\mathbb{E}[Y]\geq\delta\right]\leq\exp\left(-\frac{2\delta^2}{\pi^2\|\boldsymbol{A}\|_2^2}\right)\quad\forall\delta\geq 0.$$

$$\mathbb{P}\left[Y^2\geq(\delta+\|\boldsymbol{A}\|_F)^2\right]\leq\exp\left(-\frac{2\delta^2}{\pi^2\|\boldsymbol{A}\|_2^2}\right)\quad\forall\delta\geq 0.$$

因为 $(\delta+\|\boldsymbol{A}\|_F)^2\leq 2\delta^2+2\|\boldsymbol{A}\|_F^2$,

$$\mathbb{P}\left[Y^2\geq 2\delta^2+2\|\boldsymbol{A}\|_F^2\right]\leq\mathbb{P}\left[Y^2\geq(\delta+\|\boldsymbol{A}\|_F)^2\right]\leq\exp\left(-\frac{2\delta^2}{\pi^2\|\boldsymbol{A}\|_2^2}\right)\quad\forall\delta\geq 0.$$

令 $\delta^2=t\|\boldsymbol{A}\|_2$,

$$\mathbb{P}\left[Y^2\geq 2t\|\boldsymbol{A}\|_2+2\|\boldsymbol{A}\|_F^2\right]\leq\exp\left(-\frac{2t}{\pi^2\|\boldsymbol{A}\|_2}\right)\quad\forall t\geq 0.$$

综上

$$\begin{aligned}\mathbb{P}[|Z|\geq t]&\leq 2\exp\left(-\frac{t^2}{4t\|\boldsymbol{A}\|_2+4\|\boldsymbol{A}\|_F^2}\right)+\exp\left(-\frac{2t}{\pi^2\|\boldsymbol{A}\|_2}\right)\\&\leq 4\exp\left(-\frac{t^2}{8t\|\boldsymbol{A}\|_2+8\|\boldsymbol{A}\|_F^2}\right)\quad\forall t\geq 0.\end{aligned}$$

第七讲

王伟文　暨南大学

1　累积分布函数一致收敛性

给定服从某一分布的随机变量 X, 其累积分布函数 $(Cumulative\,Distribution\,Function, CDF)$ 表示为

$$F(t) := \mathbb{P}[X \le t] \quad \forall t \in \mathbb{R}.$$

设 $\{X_i\}_{i\in[n]}$ 为一组与 X 同分布且相互独立的样本, X 的一个经验 CDF 估计可以是

$$\widehat{F}_n(t) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{I}_{(-\infty,t]}[X_i].$$

因为

$$\begin{aligned} F(t) = \mathbb{P}[X \le t] &= \int_{-\infty}^{t} p(x)\mathrm{d}x \\ &= \int_{-\infty}^{+\infty} \mathbb{I}_{(-\infty,t]}[x]p(x)\mathrm{d}x \\ &= \mathbb{E}[\mathbb{I}_{(-\infty,t]}[X]] \end{aligned}$$

故 $\mathbb{E}[\widehat{F}_n(t)] = F(t)$.

给定定义域为 $\mathbb{R}$ 的函数 f 和 g, 记两个函数间的距离为

$$\|f-g\|_\infty := \sup_{t\in\mathbb{R}} |f(t)-g(t)|.$$

定理 1.1: Glivenko-Cantelli 定理

对任意分布, $\widehat{F}_n(t)$ 是 $F(t)$ 的强一致估计, 即

$$\|\widehat{F}_n - F\|_\infty \xrightarrow{a.s.} 0,$$

换言之,

$$\mathbb{P}\left(\lim_{n\to\infty} \|\widehat{F}_n - F\|_\infty = 0\right) = 1.$$

2 一般函数类的一致收敛性

考虑定义域为 $\mathcal{X}$ 的可积实值函数类 $\mathscr{F}$, $\{X_i\}_{i\in[d]}$ 为相互独立的样本, 源自以 $\mathcal{X}$ 为支撑集的分布 $\mathbb{P}$, 定义随机变量

$$\|\mathbb{P}_n - \mathbb{P}\|_{\mathscr{F}} := \sup_{f\in\mathscr{F}} \left| \frac{1}{n}\sum_{i=1}^{n} f(X_i) - \mathbb{E}[f(X)] \right|$$

累积概率密度函数. 取

$$\mathscr{F} = \{\mathbb{I}_{(-\infty,t]}(\cdot) : t \in \mathbb{R}\}$$

此时

$$\|\mathbb{P}_n - \mathbb{P}\|_{\mathscr{F}} = \|\widehat{F}_n - F\|_\infty$$

经验风险最小化. 考虑一簇分布 $\{\mathbb{P}_\theta : \theta \in \Omega\}$. 给定一组独立同分布样本 $\{X_i\}_{i\in[n]}$, 产生于某一未知分布 $\mathbb{P}_{\theta^*}(\theta^* \in \Omega)$. 经验风险最小化从最小化如下经验风险估计未知参数 θ^*.

经验风险 (Empirical Risk)

$$\widehat{R}_n(\theta, \theta^*) = \frac{1}{n}\sum_{i=1}^{n} \mathcal{L}_\theta(X_i)$$

经验风险最小化对未知参数 θ^* 的估计

$$\hat{\theta} \in \arg\min_{\theta\in\Omega} \widehat{R}_n(\theta, \theta^*),$$

其中 $\mathcal{L}_\theta$ 表示损失函数.

对任意 θ, 其总体风险 (Population Risk) 定义为

$$R(\theta, \theta^*) = \mathbb{E}\left[\widehat{R}_n(\theta, \theta^*)\right] = \mathbb{E}_{\theta^*}\left[\mathcal{L}_\theta(X)\right]$$

实际上, θ^* 是否属于参数空间 Ω 往往是未知的, 此时一个关键问题是如何控制 $\hat{\theta}$ 的超额风险.

超额风险 (Excess Risk)

$$\mathcal{E}(\hat{\theta}, \theta^*) := R(\hat{\theta}, \theta^*) - \inf_{\theta\in\Omega} R(\theta, \theta^*)$$

例 2.1. (极大似然估计) 记分布簇 $\{\mathbb{P}_\theta : \theta \in \Omega\}$ 每一个元素对应概率密度函数 p_θ, 定义损失函数

$$\mathcal{L}(x) := \log \frac{p_{\theta^*}(x)}{p_\theta(x)}$$

参数 θ^* 经验风险最小化估计为

$$\begin{aligned}\hat{\theta} \in \arg\min_{\theta\in\Omega} \frac{1}{n}\sum_{i=1}^{n} \log \frac{p_{\theta^*}(X_i)}{p_\theta(X_i)} &= \arg\min_{\theta\in\Omega} \frac{1}{n}\sum_{i=1}^{n} \log \frac{1}{p_\theta(X_i)} \\ &= \arg\max_{\theta\in\Omega} \frac{1}{n}\sum_{i=1}^{n} \log p_\theta(X_i)\end{aligned}$$

为了控制超额风险 $\mathcal{E}_n(\hat{\theta}, \theta^*)$, 需要对其进行分解. 假设存在 θ_0 使得 $R(\theta_0, \theta^*) = \inf_{\theta\in\Omega} R(\theta, \theta^*)$.

$$\mathcal{E}_n(\hat{\theta},\theta^*) = \underbrace{R(\hat{\theta},\theta^*) - \hat{R}_n(\hat{\theta},\theta^*)}_{T_1} + \underbrace{\hat{R}_n(\hat{\theta},\theta^*) - \hat{R}_n(\theta_0,\theta^*)}_{T_2} + \underbrace{\hat{R}_n(\theta_0,\theta^*) - R(\theta_0,\theta^*)}_{T_3}$$

1. 由 $\hat{\theta}$ 的最优性, $\hat{R}_n(\hat{\theta},\theta^*) \le \hat{R}_n(\theta_0,\theta^*)$, 故 $T_2 \le 0$,

2.

$$\begin{aligned} T_1 = R(\hat{\theta},\theta^*) - \hat{R}_n(\hat{\theta},\theta^*) &\le \left| \mathbb{E}_{\theta^*}[\mathcal{L}_{\hat{\theta}}(X)] - \frac{1}{n}\sum_{i=1}^n \mathcal{L}_{\hat{\theta}}(X_i) \right| \\ &\le \sup_{\theta\in\Omega} \left| \frac{1}{n}\sum_{i=1}^n \mathcal{L}_\theta(X_i) - \mathbb{E}[\mathcal{L}_\theta(X)] \right|. \end{aligned}$$

3. 类似 **2**

$$T_3 = \hat{R}_n(\theta_0,\theta^*) - R(\theta_0,\theta^*) \le \sup_{\theta\in\Omega} \left| \frac{1}{n}\sum_{i=1}^n \mathcal{L}_\theta(X_i) - \mathbb{E}[\mathcal{L}_\theta(X)] \right|,$$

综上,

$$\mathcal{E}_n(\hat{\theta},\theta^*) \le 2\sup_{\theta\in\Omega} \left| \frac{1}{n}\sum_{i=1}^n \mathcal{L}_\theta(X_i) - \mathbb{E}[\mathcal{L}_\theta(X)] \right| = 2\|\mathbb{P}_n - \mathbb{P}\|_{\mathcal{L}(\Omega)}.$$

其中

$$\mathcal{L}(\Omega) \triangleq \{\mathcal{L}_\theta : \theta \in \Omega\}$$

3 基于 Rademacher 复杂度的统一律

定义 3.1: 函数类 $\mathscr{F}$ 的 Rademacher 复杂度

给定分布 $\mathcal{P}$ 独立产生的 n 个数据点 $(x_i)_{i\in[n]}$, 则函数类 $\mathscr{F}$ 关于这 n 个数据点的经验 *Rademacher* 复杂度定义为

$$\widehat{\mathcal{R}}_n(\mathscr{F}) = \mathbb{E}_\epsilon \sup_{f\in\mathscr{F}} \left| \frac{1}{n}\sum_{i=1}^n \epsilon_i f(x_i) \right|,$$

将数据点替换为 n 个独立同分布的随机变量 $X = (X_i)_{i\in[n]}$, 并关于 X 求期望, 得到函数类 $\mathscr{F}$ 的 *Rademacher* 复杂度

$$\mathcal{R}_n(\mathscr{F}) = \mathbb{E}_X \left[\mathbb{E}_\epsilon \sup_{f\in\mathscr{F}} \left| \frac{1}{n}\sum_{i=1}^n \epsilon_i f(X_i) \right| \right]$$

定理 3.1

设存在 $c \ge 0$, 对于任意 $f \in \mathscr{F}$, 有 $\|f\|_\infty \le c$. 对任意 $n \ge 1$ 及 $\delta \ge 0$, 不等式

$$\|\mathbb{P}_n - \mathbb{P}\|_{\mathscr{F}} \le 2\mathcal{R}_n(\mathscr{F}) + \delta$$

至少以概率 $1 - \exp(-\frac{n\delta^2}{2c^2})$ 成立.

证明. 1. 有界差不等式控制 $\|\mathbb{P}_n - \mathbb{P}\|_{\mathscr{F}}$.

定义函数

$$g(x) = \sup_{f\in\mathscr{F}} \left| \frac{1}{n}\sum_{i=1}^{n} f(x_i) - \mathbb{E}[f(X)] \right|, \quad x = (x_1, x_2, \ldots, x_n).$$

因为 $\|f\|_\infty \le c$, 即 $\sup\limits_x |f(x)| \le c$, 故

$$\begin{aligned}
g(x) - g(x^{\setminus k}) &= \sup_{f\in\mathscr{F}} \left| \frac{1}{n}\sum_{i\neq k}^{n} f(x_i) + \frac{1}{n} f(x_k) - \mathbb{E}[f(X)] \right| - \sup_{f\in\mathscr{F}} \left| \frac{1}{n}\sum_{i\neq k}^{n} f(x_i) + \frac{1}{n} f(x'_k) - \mathbb{E}[f(X)] \right| \\
&\le \sup_{f\in\mathscr{F}} \left\{ \left| \frac{1}{n}\sum_{i\neq k}^{n} f(x_i) + \frac{1}{n} f(x_k) - \mathbb{E}[f(X)] \right| - \left| \frac{1}{n}\sum_{i\neq k}^{n} f(x_i) + \frac{1}{n} f(x'_k) - \mathbb{E}[f(X)] \right| \right\} \\
&\le \sup_{f\in\mathscr{F}} \left| \frac{1}{n} f(x_k) - \frac{1}{n} f(x'_k) \right| \\
&\le \frac{2c}{n}.
\end{aligned}$$

同理, $g(x^{\setminus k}) - g(x) \le \frac{2c}{n}$. 因此 $g(x)$ 满足以 $\frac{2n}{c}$ 为参数的有界差不等式.

$$\mathbb{P}\left[\|\mathbb{P}_n - \mathbb{P}\|_{\mathscr{F}} - \mathbb{E}\|\mathbb{P}_n - \mathbb{P}\|_{\mathscr{F}} \ge \delta\right] \le e^{-\frac{n\delta^2}{2c^2}} \quad \forall \delta \ge 0.$$

因此不等式

$$\|\mathbb{P}_n - \mathbb{P}\|_{\mathscr{F}} \le \mathbb{E}\|\mathbb{P}_n - \mathbb{P}\|_{\mathscr{F}} + \delta$$

至少以概率 $1 - e^{-\frac{n\delta^2}{2c^2}}$ 成立.

2. Rademacher 复杂度控制 $\mathbb{E}\|\mathbb{P}_n - \mathbb{P}\|_{\mathscr{F}}$

此过程应用对称化技巧 (symmetrization trick), 记 $X = (X_1, X_2, \ldots, X_n)$, X' 为 X 的独立副

本.

$$
\begin{aligned}
\mathbb{E}\|\mathbb{P}_n - \mathbb{P}\|_{\mathscr{F}} &= \mathbb{E}_X \sup_{f\in\mathscr{F}} \left| \frac{1}{n}\sum_{i=1}^n f(X_i) - \mathbb{E}[f(X)] \right| \\
&= \mathbb{E}_X \sup_{f\in\mathscr{F}} \left| \frac{1}{n}\sum_{i=1}^n f(X_i) - \mathbb{E}_{X'}\left[\frac{1}{n}\sum_{i=1}^n f(X_i')\right] \right| \\
&= \mathbb{E}_X \sup_{f\in\mathscr{F}} \left| \mathbb{E}_{X'}\left[\frac{1}{n}\sum_{i=1}^n (f(X_i) - f(X_i'))\right] \right| \\
&\le \mathbb{E}_X \sup_{f\in\mathscr{F}} \mathbb{E}_{X'} \left| \frac{1}{n}\sum_{i=1}^n (f(X_i) - f(X_i')) \right| \quad \text{(Jensen 不等式)} \\
&\le \mathbb{E}_{X,X'} \sup_{f\in\mathscr{F}} \left| \frac{1}{n}\sum_{i=1}^n (f(X_i) - f(X_i')) \right| \quad (\mathbb{E}h(X) \le \mathbb{E}\sup_{h\in\mathscr{H}} h(X),\ \forall h\in\mathscr{H}) \\
&= \mathbb{E}_{X,X'}\mathbb{E}_\epsilon \sup_{f\in\mathscr{F}} \left| \frac{1}{n}\sum_{i=1}^n \epsilon_i (f(X_i) - f(X_i')) \right| \\
&\le \mathbb{E}_{X,X'}\mathbb{E}_\epsilon \sup_{f\in\mathscr{F}} \left| \frac{1}{n}\sum_{i=1}^n \epsilon_i f(X_i) \right| + \mathbb{E}_{X,X'}\mathbb{E}_\epsilon \sup_{f\in\mathscr{F}} \left| \frac{1}{n}\sum_{i=1}^n \epsilon_i f(X_i') \right| \\
&= 2\mathcal{R}_n(\mathscr{F})
\end{aligned}
$$

3. 综合上述结论, 有

$$
\begin{aligned}
\mathbb{P}\left[\|\mathbb{P}_n - \mathbb{P}\|_{\mathscr{F}} \le 2\mathcal{R}_n(\mathscr{F}) + \delta\right] &\ge \mathbb{P}\left[\|\mathbb{P}_n - \mathbb{P}\|_{\mathscr{F}} \le \mathbb{E}\|\mathbb{P}_n - \mathbb{P}\|_{\mathscr{F}} + \delta\right] \\
&\ge 1 - e^{-\frac{n\delta^2}{2c^2}}.
\end{aligned}
$$

□

第八讲

王伟文　暨南大学

1　Rademacher 复杂度上界

给定 n 个样本点 $x_1^n = (x_1, x_2, \ldots, x_n) \subset \mathbb{R}^d$, 考虑函数类 $\mathcal{F} \triangleq \{f \in \mathcal{F} | f : \mathbb{R}^d \to \mathbb{R}\}$, 集合 $\mathcal{F}(x_1^n) = \{(f(x)_1, \ldots, f(x_n)) : f \in \mathcal{F}\} \subset \mathbb{R}^n$ 的元素个数衡量了函数类 $\mathcal{F}$ 样本依赖 (sample-dependent) 的复杂度.

例 1.1. 考虑函数类 $\mathcal{F} \triangleq \{\mathtt{sgn}\left(w^T x + b\right) : w \in \mathbb{R}^d, b \in \mathbb{R}\}$, $F(x_1^n)$ 的元素个数至多为 2^n.

定义 1.1: 多项式判别 (Polynomial Discrimination)

称定义域 $\mathcal{X}$ 上的函数类 $\mathcal{F}$ 具有 $\nu(\geq 1)$ 阶多项式判别, 若对任意 $n \geq 1$ 及任意样本容量为 n 的数据点 $x_1^n = (x_1, \ldots, x_n)$ 均有

$$\mathtt{card}\left(\mathcal{F}(x_1^n)\right) \leq (n+1)^\nu.$$

其中 $\mathtt{card}(\cdot)$ 表示集合元素个数.

评论. 满足多项式判别的函数类样本依赖复杂度随着样本容量多项式增长.

定理 1.1

设函数类 $\mathcal{F}$ 满足 ν 阶多项式判别且 $\mathcal{F} \neq \{0\}$, 则对任意 $n \geq 1$ 及任意样本容量为 n 的数据点 $x_1^n = (x_1, \ldots, x_n)$ 均有

$$\mathbb{E}_\epsilon \left[\sup_{f \in \mathcal{F}} \left| \frac{1}{n} \sum_{i=1}^n \epsilon_i f(x_i) \right| \right] \leq 2\mathcal{D}(x_1^n) \sqrt{\frac{\nu \log(n+1)}{n}},$$

其中 $\mathcal{D}(x_1^n) \triangleq \sup_{f \in \mathcal{F}} \sqrt{\frac{\sum_{i=1}^n (f(x_i))^2}{n}}$, ϵ_i 为相互独立的 Rademacher 变量.

为证明上述定理, 我们需要利用 sub-Gaussian 变量最大值的上界引理.

引理 1.1: sub-Gaussian 变量最大值的上界

设 $\{X_i\}_{i\in[n]}$ 为一组均值为 0, 以 σ 为参数的 sub-Gaussian 变量, 则

$$\mathbb{E}[\max_{i\in[n]} X_i] \le \sqrt{2\sigma^2 \log n} \quad \forall n \ge 1.$$

且

$$\mathbb{E}[\max_{i\in[n]} |X_i|] \le \sqrt{2\sigma^2 \log(2n)} \le 2\sqrt{\sigma^2 \log n} \quad \forall n \ge 2.$$

定理 1.1 的证明. 因为 ϵ_i 是以 1 为参数、相互独立的 sub-Gaussian 变量, 故

- $\frac{1}{n} f(x_i)\epsilon$ 是以 $\frac{f(x_i)}{n}$ 为参数且均值为 0 的 sub-Gaussian 变量
- $\sum\limits_{i=1}^{n} \frac{f(x_i)\epsilon_i}{n}$ 是以 $\sqrt{\sum\limits_{i=1}^{n} \frac{(f(x_i))^2}{n^2}}$ 为参数且均值为 0 的 sub-Gaussian 变量.

定义集合

$$\mathcal{S} \triangleq \left\{ \sum_{i=1}^{n} \frac{f(x_i)\epsilon_i}{n} : f \in \mathcal{F} \right\}$$

由引理 1.1

$$\begin{aligned}
\mathbb{E}_\epsilon \left[\sup_{f\in\mathcal{F}} \left| \frac{1}{n} \sum_{i=1}^{n} \epsilon_i f(x_i) \right| \right] &= \mathbb{E} \left[\sup_{X\in\mathcal{S}} |X| \right] \\
&\le 2\sqrt{\sum_{i=1}^{n} \frac{(f(x_i))^2}{n^2}} \sqrt{\log \mathtt{card}(\mathcal{S})}.
\end{aligned}$$

又因为存在映射 $M : \mathcal{F}(x_1^n) \to \mathcal{S}$, 故有 $\mathtt{card}(\mathcal{S}) \le \mathtt{card}(\mathcal{F}(x_1^n))$. 综上

$$\begin{aligned}
\mathbb{E}_\epsilon \left[\sup_{f\in\mathcal{F}} \left| \frac{1}{n} \sum_{i=1}^{n} \epsilon_i f(x_i) \right| \right] &\le 2\sqrt{\sum_{i=1}^{n} \frac{(f(x_i))^2}{n^2}} \sqrt{\log \mathtt{card}(\mathcal{F}(x_1^n))} \\
&\le 2\sqrt{\sum_{i=1}^{n} \frac{(f(x_i))^2}{n^2}} \sqrt{\nu \log(n+1)} \\
&= 2\mathcal{D}(x_1^n)\sqrt{\frac{\nu \log(n+1)}{n}}.
\end{aligned}$$

□

评论. 若 $\forall f \in \mathcal{F}$ 有 $\|f\|_\infty \le b$, 则有

$$\mathcal{R}(\mathcal{F}(x_1^n)) = \mathbb{E}_\epsilon \left[\sup_{f\in\mathcal{F}} \left| \frac{1}{n} \sum_{i=1}^{n} \epsilon_i f(x_i) \right| \right] \le 2b\sqrt{\frac{\nu \log(n+1)}{n}}.$$

定理 1.2: 经典 Glivenko-Cantelli 定理

随机变量 X 的累积分布函数 $F(t)=\mathbb{P}[X\le t]$, $\hat{F}_n(t)$ 表示样本容量为 n 的 $F(t)$ 的经验估计量, 其样本 $X_i(i\in[n])$ 相互独立, 则

$$\mathbb{P}\left[\|\hat{F}_n-F\|_\infty\ge 4\sqrt{\frac{\log(n+1)}{n}}+\delta\right]\le e^{-\frac{n\delta^2}{2}}\quad \forall\delta\ge 0.$$

因此 $\|\hat{F}_n-F\|_\infty\xrightarrow{a.s.}0$.

证明. 证明思路

- 考虑函数类 $\mathcal{F}=\{\mathbb{I}_{(-\infty,t]}(\cdot):t\in\mathbb{R}\}$, 该函数类为 1 一一致有界, 即 $\forall f\in\mathcal{F}$, $\|f\|_\infty\le 1$.
- $\|\hat{F}_n-F\|_\infty\le 2\mathcal{R}(\mathcal{F}(X_1^n))+\delta$ 至少以概率 $1-\exp(-\frac{n\delta^2}{2})$ 成立.
- $\mathcal{R}(\mathcal{F}(X_1^n))\le 2\sqrt{\frac{\nu\log(n+1)}{n}}$, 若 $\mathcal{F}$ 为 ν-阶多项式判别.
- 需要确定 ν 的值

接下来我们将证明

$$\texttt{card}(\mathcal{F}(x_1^n))\le(n+1)\quad \forall n\ge 1及\forall\{x_i\}_{i\in[n]}\subset\mathbb{R}.$$

根据以上定义有

$$\mathcal{F}(x_1^n)\triangleq\{(\mathbb{I}_{(-\infty,t]}(x_1),\mathbb{I}_{(-\infty,t]}(x_2),\dots,\mathbb{I}_{(-\infty,t]}(x_n))\in\mathbb{R}^n:t\in\mathbb{R}\}$$

不失一般性, 假设 $x_1\le x_2\le\cdots\le x_n$(排序不改变元素数量), 对任意数据点 $\{x_i\}_{i\in[n]}$, 容易计算得到

$$\texttt{card}(F(x_1^n))\le n+1$$

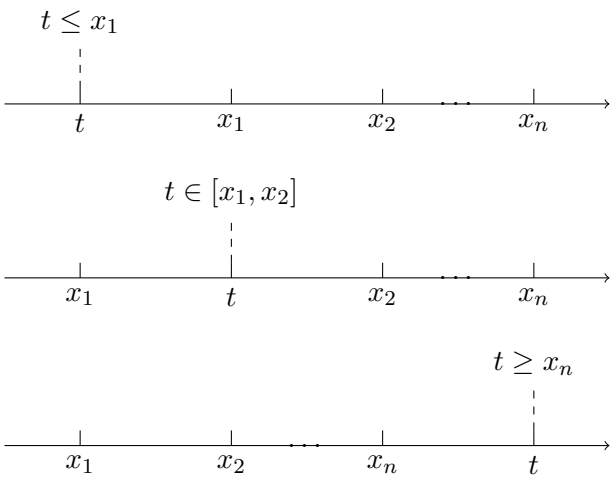

故 $\mathcal{F}$ 为 1-阶多项式判别. □

2 Vapnik-Chervonenkis(VC) 维

在本节中我们仅考虑二元函数类, 这类函数类的元素个数可以由人们所熟知的 Vapnik-Chervonenkis(VC) 维控制.

定义 2.1: 打散 (Shattering)

考虑二值函数类 $\mathcal{F}$, 给定 n 个数据点集 $x_1^n = (x_1, \ldots, x_n)$, 称它们被 $\mathcal{F}$ 打散若

$$\mathtt{card}(\mathcal{F}(x_1^n)) = 2^n$$

成立.

定义 2.2: Vapnik-Chervonenkis(VC) 维

二值函数类型 $\mathcal{F}$ 的 Vapnik-Chervonenkis(VC) 维是 $\mathcal{F}$ 能打散的最大的数据点数量, 记为 $\nu(F)$. 换言之, 存在 $\nu(\mathcal{F})$ 个数据点 $x_1^{\nu(\mathcal{F})}$ 能够被 $\mathcal{F}$ 打散, 对于任意 $\nu(\mathcal{F})+1$ 个数据点, 均不能被 $\mathcal{F}$ 打散.

- 若 $\mathcal{F}$ 为有限值, 则称二值函数类 $\mathcal{F}$ 为 VC 类.

例 2.1. 函数类 $\mathcal{F} \triangleq \{\mathbb{I}_{(-\infty,a)}(\cdot) : a \in \mathbb{R}\}$, 给定一个数据点 x_1, $\mathtt{card}(F(x_1)) = 2$, 对任意给定的两个数据点的集合 $x_1^2 = (x_1, x_2)$, 不妨设 $x_1 < x_2$, 此时 $\mathtt{card}(F(x_1^2)) = 3 < 2^2$. 因此 $\nu(\mathcal{F}) = 1$.

例 2.2. 函数类 $\mathcal{F} \triangleq \{\mathbb{I}_{(a,b]}(\cdot) : a, b \in \mathbb{R}$ 且 $a < b\}$, 任意给定的两个数据点的集合 $x_1^2 = (x_1, x_2)$, $\mathtt{card}(\mathcal{F}(x_1^2)) = 4$, 对于任意 3 个数据点集合 $x_1^3 = (x_1, x_2, x_3)$, 不妨设 $x_1 < x_2 < x_3$, 容易知道 $(1, 0, 1) \notin \mathcal{F}(x_1^3)$, 故 $\mathtt{card}(\mathcal{F}(x_1^3)) < 2^3$, 因此 $\nu(\mathcal{F}) = 2$.

命题 2.1

若二值函数类 $\mathcal{F}_1 \subset \mathcal{F}_2$, 则 $\nu(\mathcal{F}_1) \le \nu(\mathcal{F}_2)$.

引理 2.1: Sauer-Shelah 引理

若二值函数类 $\mathcal{F}$ 有 $\nu(\mathcal{F}) < \infty$, 对于任意样本容量为 n 的数据点 $P = (x_1, x_2, \ldots, x_n)$ 满足 $n \ge \nu(\mathcal{F})$, 有

$$\mathtt{card}(\mathcal{F}(P)) \le \sum_{i=0}^{\nu(\mathcal{F})} \binom{n}{i} \le (n+1)^{\nu(\mathcal{F})}.$$

3 控制 VC 维

定理 3.1

设 $\mathscr{G}$ 为函数 $g:\mathbb{R}^d \to \mathbb{R}$ 的向量空间, 满足 $\mathtt{dim}(\mathscr{G}) < \infty$. 定义集合

$$\mathcal{S}(\mathscr{G}) \triangleq \{\{x \in \mathbb{R}^d : g(x) \le 0\} : g \in \mathscr{G}\},$$

则函数类

$$\mathcal{F} \triangleq \{\mathbb{I}_{\mathtt{S}}(\cdot) : \mathtt{S} \in \mathcal{S}(\mathscr{G})\}$$

的 VC 维至多是 $\mathtt{dim}(\mathscr{G})$.

证明. 这里我们只要证明 $\mathcal{F}$ 不能打散任意 $n := \mathtt{dim}(\mathscr{G}) + 1$ 个数据点.

因为 $\mathscr{G}$ 为函数向量空间, 故对任意函数 $g \in \mathscr{G}$, 存在 $\mathtt{dim}(\mathscr{G})$ 个基函数 $\{\varphi_k\}$ 及向量 $c \in \mathbb{R}^{\mathtt{dim}(\mathscr{G})}$ 使得

$$g = \sum_{k=1}^{\mathtt{dim}(\mathscr{G})} c_k \varphi_k$$

给定任意 n 个数据点集合 $x_1^n = (x_1, x_2, \ldots, x_n)$, 定义矩阵 $\Phi = [\varphi_k(x_i)]_{ik} \in \mathbb{R}^{n \times \mathtt{dim}(\mathscr{G})}$.

因为 $\mathtt{dim}(\mathscr{G}) = n - 1$, 故 $\mathtt{rank}(\Phi) \le n - 1$, 因此存在非零向量 $\gamma \in \mathbb{R}^n$ 使得

$$\Phi^T \gamma = 0$$

又因为

$$\gamma^T \Phi c = \langle \gamma, (g(x_i)) \rangle = 0 \quad \forall g \in \mathscr{G}.$$

不失一般性, 不妨假设 γ 至少存在一个分量大于 0, 则上式可改写为

$$\sum_{i:\gamma_i \le 0} -\gamma_i g(x_i) = \sum_{i:\gamma_i > 0} \gamma_i g(x_i) \quad \forall g \in \mathscr{G}.$$

此恒等式表明 $\forall g \in \mathscr{G}$,

$$\mathtt{sgn}(r_i) = \mathtt{sgn}(g(x_i)) \quad \forall i = 1, 2, \ldots, n$$

不成立.

定义向量 v

$$v_i = \begin{cases} 1, \gamma_i \le 0 \\ 0, \gamma_i > 0 \end{cases}$$

综上所述 $v \notin \mathcal{F}(x_1^n)$.

故 $\mathtt{card}(\mathcal{F}(x_1^n)) < 2^n$, 因此 $\mathcal{F}$ 不能打散任意 n 个数据点. □

例 3.1. 线性函数. 定义线性函数类 $\mathscr{L} \triangleq \{a^T x + b : a \in \mathbb{R}^d, b \in \mathbb{R}\}$, $\texttt{dim}(\mathscr{L}) = d+1$. 给定 (a,b) 定义半空间 $\mathcal{H}_{a,b} = \{x \in \mathbb{R}^d : a^T x + b \le 0\}$, 对于函数类

$$\mathcal{F} \triangleq \{\mathbb{I}_{\mathcal{H}_{a,b}}(\cdot) : a \in \mathbb{R}^d, b \in \mathbb{R}\}.$$

由定理 3.1, $\nu(F) \le d+1$.

例 3.2. $\mathbb{R}^d$ 中的球体. 考虑球体 $\mathcal{S}_{a,b} = \{x \in \mathbb{R}^d : \|x-a\| \le b\}$, 其中 $(a,b) \in \mathbb{R}^d \times \mathbb{R}$. 设

$$f_{a,b}(x) = \|x\|^2 - 2\sum_{i=1}^{d} a_i x_i + \|a\|^2 - b^2$$

故 $\mathcal{S}_{a,b} = \{x \in \mathbb{R}^d : f_{a,b}(x) \le 0\}$

又因为 $f_{a,b}$ 可以改写为

$$f_{a,b}(x) = (1, x_1, x_2, \ldots, x_d, \|x\|^2) \cdot (\|a\|^2 - b^2, a_1, a_2, \ldots, a_d, 1)^T$$

故 $\mathscr{S} = \{f_{a,b} : a \in \mathbb{R}^d, b \in \mathbb{R}\} \subset \mathscr{L} = \{\langle c, \cdot \rangle : c \in \mathbb{R}^{d+2}\}$, 记 $\mathcal{S}_c = \{x \in \mathbb{R}^{d+2} : \langle c, x \rangle \le 0\}$.

定义函数类

$$\mathcal{F} \triangleq \{\mathbb{I}_{\mathcal{S}_{a,b}}(\cdot) : a \in \mathbb{R}^d, b \in \mathbb{R}\}.$$

$$\mathcal{L} \triangleq \{\mathbb{I}_{\mathcal{S}_c}(\cdot) : c \in \mathbb{R}^{d+2}\}$$

由定理 3.2, $\nu(\mathcal{F}) \le \nu(\mathcal{L}) \le \texttt{dim}(\mathscr{L}) = d+2$.

第九讲

王伟文　暨南大学

1　度量空间

度量空间 $(\mathcal{T},\rho)$ 由非空集合 $\mathcal{T}$ 及度量 $\rho:\mathcal{T}\times\mathcal{T}\to\mathbb{R}$ 组成, 其中度量 ρ 满足

- 非负性: $\forall(\theta,\tilde{\theta})\in\mathcal{T}\times\mathcal{T},\rho(\theta,\tilde{\theta})\geq 0$. $\rho(\theta,\tilde{\theta})=0$ 当且仅当 $\theta=\tilde{\theta}$.
- 对称性: $\forall(\theta,\tilde{\theta})\in\mathcal{T}\times\mathcal{T},\rho(\theta,\tilde{\theta})=\rho(\tilde{\theta},\theta)$.
- 三角不等式: $\forall(\theta,\tilde{\theta},\hat{\theta})\in\mathcal{T}^3$

$$\rho(\theta,\tilde{\theta})\leq\rho(\theta,\hat{\theta})+\rho(\hat{\theta},\tilde{\theta}).$$

例 1.1. $(\mathbb{R}^d,\rho)$, 欧氏距离 $\rho(\theta,\tilde{\theta})=\sqrt{\sum_{i=1}^{d}(\theta_i-\tilde{\theta}_i)^2}$.

例 1.2. $(\{0,1\}^d,\rho)$, 汉明 (Hamming) 距离 $\rho(\theta,\tilde{\theta})=\frac{1}{d}\sum_{i=1}^{d}\mathbb{I}_{\{\theta_i=\tilde{\theta}_i\}}$

例 1.3. $(C[0,1],\rho)$, 其中 $C[0,1]$ 表示所有在 $[0,1]$ 上连续的函数的集合

$$\rho(f,g)=\sup_{x\in[0,1]}|f(x)-g(x)|$$

接下来我们将回答如何"测量"一个度量空间的"大小".

定义 1.1: 覆盖数 $\mathscr{N}(\delta;\mathcal{T},\rho)$

给定集合 $\mathcal{C}=\{\theta^1,\theta^2,\ldots,\theta^n\}\subset\mathcal{T}$ 及常数 $\delta>0$. 若 $\forall\theta\in\mathcal{T}$, $\exists i\in[n]$ 使得

$$\rho(\theta,\theta^i)\leq\delta,$$

则称 $\mathcal{C}$ 为集合 $\mathcal{T}$ 在度量 ρ 下的 δ-覆盖. 集合 $\mathcal{T}$ 的 δ-覆盖数 $\mathscr{N}(\delta;\mathcal{T},\rho)$ 即为 $\mathcal{T}$ 的最小 δ-覆盖的元素个数, 其中"最小"指元素个数最少.

评论. 若 $\mathcal{C}=\{\theta^1,\theta^2,\ldots,\theta^n\}$ 为 $\mathcal{T}$ 的 δ-覆盖, 则

$$\mathcal{T}\subseteq\bigcup_{i\in[n]}\mathcal{B}_\rho(\theta^i;\delta)$$

其中 $\mathcal{B}_\rho(\theta^i;\delta)$ 为在度量 ρ 下以 δ 为半径, θ^i 为中心的球.

例 1.4. 考虑闭区间 $\mathcal{T}=[-1,1]$, 定义度量 $\rho(\theta,\tilde{\theta})=|\theta-\tilde{\theta}|$, 则

$$\mathscr{N}(\delta;\mathcal{T},\rho)\leq 2+\frac{1}{\delta}.$$

定义集合 $\mathcal{C}=\{-1,-1+2\delta,-1+4\delta,\cdots,-1+2n\delta,1\}\subset\mathcal{T}$, 其中 $n=\lfloor\frac{1}{\delta}\rfloor$, 容易知道 $\mathcal{C}$ 为 $[-1,1]$ 上的 δ-覆盖.

$$\texttt{card}(C)=\lfloor\frac{1}{\delta}\rfloor+2\leq\frac{1}{\delta}+2,$$

因此

$$\mathscr{N}(\delta;\mathcal{T},\rho)\leq 2+\frac{1}{\delta}.$$

推广至 d-维空间,

$$\mathscr{N}(\delta;[-1,1]^d,\|\cdot\|_\infty)\leq\left(2+\frac{1}{\delta}\right)^d.$$

定义 1.2: 填充数 (Packing number)$\mathscr{M}(\delta;\mathcal{T},\rho)$

给定集合 $\mathcal{P}=\{\theta^1,\theta^2,\ldots,\theta^m\}\subset\mathcal{T}$ 及常数 $\delta>0$, 若对任意 $i,j\in[m]$ 且 $i\neq j$ 有

$$\rho(\theta^i,\theta^j)>\delta$$

则称 $\mathcal{P}$ 为度量 ρ 下集合 $\mathcal{T}$ 的 δ-填充 (packing). 集合 $\mathcal{T}$ 的填充数 $\mathscr{M}(\delta;\mathcal{T},\rho)$ 为最大 δ-填充的元素个数, 其中"最大"指元素个数最多.

引理 1.1

给定度量空间 $(\mathcal{T},\rho)$, 对任意 $\delta>0$,

$$\mathscr{M}(2\delta;\mathcal{T},\rho)\overset{(a)}{\leq}\mathscr{N}(\delta;\mathcal{T},\rho)\overset{(b)}{\leq}\mathscr{M}(\delta;\mathcal{T},\rho)$$

证明. ***b.*** 这里只需证明 $\mathcal{T}$ 的最大 δ-填充同时也是 δ-覆盖.

记 $\mathcal{P}=\{\theta^1,\theta^2,\ldots,\theta^m\}\subset\mathcal{T}$ 为 $\mathcal{T}$ 的一个最大 δ-填充, 其中 $m=\mathscr{M}(\delta;\mathcal{T},\rho)$.

若 $\mathcal{P}$ 不是集合 $\mathcal{T}$ 的 δ-覆盖, 则存在 $\tilde{\theta}\in\mathcal{T}$ 使得

$$\rho(\tilde{\theta},\theta^i)>\delta\quad\forall i\in[m].$$

故 $\mathcal{P}\bigcup\{\tilde{\theta}\}$ 是 $\mathcal{T}$ 的一个 δ-填充, 与 $\mathcal{P}$ 为最大 δ-填充矛盾.

a. 这里需要证明任意 2δ-填充的元素个数总是不超过任意 δ-覆盖的元素个数.

记 $\mathcal{P}=\{\theta^1,\theta^2,\ldots,\theta^m\}\subset\mathcal{T}$ 为 $\mathcal{T}$ 的 2δ-填充, $\mathcal{C}=\{\tilde{\theta}^1,\tilde{\theta}^2,\ldots,\tilde{\theta}^n\}\subset\mathcal{T}$ 为 $\mathcal{T}$ 的 δ-覆盖.

因为 $\mathcal{P}\subset\mathcal{T}$, $\mathcal{T}$ 为 δ-覆盖, 故 $\forall\theta^i\in\mathcal{P}$, $\exists\tilde{\theta}^j\in\mathcal{C}$ 使得

$$\rho(\theta^i,\tilde{\theta}^j)\leq\delta.$$

同时, 若 $\forall \theta^k \in \mathcal{P}$ 且 $\theta^k \neq \theta^i$, 有 $\rho(\theta^k, \tilde{\theta}^j) > \delta$, 否则

$$\rho(\theta^i, \theta^k) \leq \rho(\theta^i, \tilde{\theta}^j) + \rho(\theta^k, \tilde{\theta}^j) \leq 2\delta$$

与 $\mathcal{P}$ 为 2δ-填充矛盾.

上述关系表明, 对于任意 $\theta^i \in \mathcal{P}$, 存在唯一 $\tilde{\theta}^j \in \mathcal{C}$ 满足

$$\rho(\theta^i, \tilde{\theta}^j) \leq \delta$$

由鸽巢原理知

$$\texttt{card}(\mathcal{P}) \leq \texttt{card}(\mathcal{C})$$

因此

$$\mathscr{M}(2\delta; \mathcal{T}, \rho) \leq \mathscr{N}(\delta; \mathcal{T}, \rho)$$

□

例 1.5. 回顾例 1. 4. 考虑闭区间 $\mathcal{T} = [-1, 1]$, 度量 $\rho(\theta, \tilde{\theta}) = |\theta - \tilde{\theta}|$. 定义集合 $\mathcal{P} = \{-1, -1 + 2(1+\epsilon)\delta, -1 + 4(1+\epsilon)\delta, \cdots, -1 + 2(n-1)(1+\epsilon)\delta\} \subset \mathcal{T}$, 其中 $n = \lfloor \frac{1}{\delta} \rfloor$, $\delta < 1$, $0 < \epsilon < \frac{\delta}{1-\delta}$, 容易知道 $\mathcal{P}$ 为 $[-1, 1]$ 上的 2δ-填充.

$$-1 + 2(n-1)(1+\epsilon)\delta < -1 + 2(\frac{1}{\delta} - 1)(1 + \frac{\delta}{1-\delta})\delta = 1$$

$$\rho(\theta^i, \theta^j) \geq 2(1+\epsilon)\delta > 2\delta \quad \forall \theta^i, \theta^j \in \mathcal{P}.$$

由引理 1.1 知

$$\lfloor \frac{1}{\delta} \rfloor \leq \mathscr{M}(2\delta; \mathcal{T}, \rho) \leq \mathscr{N}(\delta; \mathcal{T}, \rho) \leq \lfloor \frac{1}{\delta} \rfloor + 2.$$

若 δ 充分小

$$\log \mathscr{N}(\delta; \mathcal{T}, \rho) \asymp \log(\frac{1}{\delta})$$

推广至 d 维空间

$$\log \mathscr{N}(\delta; [-1, 1]^d, \|\cdot\|_\infty) \asymp d \log(\frac{1}{\delta})$$

集合的 Minkowski 和

$$\mathcal{A} + \mathcal{B} = \{\boldsymbol{x} + \boldsymbol{y} : \boldsymbol{x} \in \mathcal{A}, \boldsymbol{y} \in \mathcal{B}\}$$

定理 1.1

考虑 $\mathbb{R}^d$ 上的两个范数 $\|\cdot\|$ 及 $\|\cdot\|'$, 定义 $\mathcal{B}=\{\boldsymbol{x}\in\mathbb{R}^d:\|\boldsymbol{x}\|\le 1\}$ 及 $\mathcal{B}'=\{\boldsymbol{x}\in\mathbb{R}^d:\|\boldsymbol{x}\|'\le 1\}$, 在度量 $\|\cdot\|'$ 下 $\mathcal{B}$ 的 δ-覆盖数满足

$$\left(\frac{1}{\delta}\right)^d\frac{\mathtt{vol}(\mathcal{B})}{\mathtt{vol}(\mathcal{B}')}\overset{(a)}{\le}\mathscr{N}(\delta;\mathcal{B},\|\cdot\|')\overset{(b)}{\le}\frac{\mathtt{vol}(\frac{2}{\delta}\mathcal{B}+\mathcal{B}')}{\mathtt{vol}(\mathcal{B}')}$$

证明. ***a***. 设 $\mathcal{C}=\{\theta^1,\cdots,\theta^n\}\subseteq\mathcal{B}$ 为 $\mathcal{B}$ 在 $\|\cdot\|'$ 下的 δ-覆盖, 故 $\forall\theta\in\mathcal{B}$, $\exists\theta^i\in\mathcal{C}$, 使得

$$\|\theta-\theta^i\|'\le\delta,$$

从而 $\theta-\theta^i\in\delta\mathcal{B}'$, $\theta\in\theta^i+\delta\mathcal{B}'$, 因此

$$\mathcal{B}\subseteq\bigcup_{i\in[n]}\{\theta^i+\delta\mathcal{B}'\}$$

故有

$$\mathtt{vol}(\mathcal{B})\le\sum_{i=1}^n\mathtt{vol}(\theta^i+\delta\mathcal{B}')=n\mathtt{vol}(\delta\mathcal{B}')=n\delta^d\mathtt{vol}(\mathcal{B}')$$

即

$$\left(\frac{1}{\delta}\right)^d\frac{\mathtt{vol}(\mathcal{B})}{\mathtt{vol}(\mathcal{B}')}\le n$$

上式对任意 δ-覆盖均成立, 故

$$\left(\frac{1}{\delta}\right)^d\frac{\mathtt{vol}(\mathcal{B})}{\mathtt{vol}(\mathcal{B}')}\le\mathscr{N}(\delta;\mathcal{B},\|\cdot\|')$$

b. 设 $\mathcal{P}=\{\tilde{\theta}^1,\tilde{\theta}^2,\ldots,\tilde{\theta}^m\}$ 为 $\mathcal{B}$ 在 $\|\cdot\|'$ 下的最大 δ-填充, , 定义 $\mathcal{B}_{\|\cdot\|'}(\tilde{\theta}^i,\delta)$, $i\in[m]$, 因为

$$\|\tilde{\theta}^i-\tilde{\theta}^j\|>\delta,$$

所以

$$\mathcal{B}_{\|\cdot\|'}(\tilde{\theta}^i,\delta)\bigcap\mathcal{B}_{\|\cdot\|'}(\tilde{\theta}^j,\delta)\quad\forall\tilde{\theta}^i,\tilde{\theta}^j\in\mathcal{P}.$$

接下来证明 $\bigcup\limits_{i\in[m]}\mathcal{B}_{\|\cdot\|'}(\tilde{\theta}^i,\delta)\subseteq\mathcal{B}+\frac{\delta}{2}\mathcal{B}'$.

$\forall\theta\in\bigcup\limits_{i\in[m]}\mathcal{B}_{\|\cdot\|'}(\tilde{\theta}^i,\delta)$, $\exists\tilde{\theta}^i\in\mathcal{P}$ 使得

$$\theta\in\mathcal{B}_{\|\cdot\|'}(\tilde{\theta}^i,\delta)\Longrightarrow\|\theta-\tilde{\theta}^i\|'\le\frac{\delta}{2}$$

同 (***a***) 的证明, $\theta\in\tilde{\theta}^i+\frac{\delta}{2}\mathcal{B}'$, 又因为 $\tilde{\theta}^i\in\mathcal{B}$, 故 $\theta\in\mathcal{B}+\frac{\delta}{2}\mathcal{B}'$.

因此

$$\begin{aligned}\texttt{vol}(\bigcup_{i\in[m]}\mathcal{B}_{\|\cdot\|'}(\tilde{\theta}^i,\delta)) &= \sum_{i=1}^{m}\texttt{vol}(\mathcal{B}_{\|\cdot\|'}(\tilde{\theta}^i,\delta))) \\ &= m\texttt{vol}(\frac{\delta}{2}\mathcal{B}') \\ &\le \texttt{vol}(\mathcal{B}+\frac{\delta}{2}\mathcal{B}')\end{aligned}$$

整理得到

$$m \le \frac{\texttt{vol}(\mathcal{B}+\frac{\delta}{2}\mathcal{B}')}{\texttt{vol}(\frac{\delta}{2}\mathcal{B}')} = \frac{\texttt{vol}\left(\frac{2}{\delta}\mathcal{B}+\mathcal{B}'\right)}{\texttt{vol}(\mathcal{B}')}$$

由引理 1.1

$$\mathscr{N}(\delta;\mathcal{B},\|\cdot\|') \le m \le \frac{\texttt{vol}\left(\frac{2}{\delta}\mathcal{B}+\mathcal{B}'\right)}{\texttt{vol}(\mathcal{B}')}.$$

□

例 1.6. 取 $\|\cdot\| = \|\cdot\|' = \|\cdot\|_\infty$, 此时 $\mathcal{B} = \mathcal{B}'$, 对于度量空间 $(\mathcal{B}_{\|\cdot\|_\infty}(\mathbf{0},1),\|\cdot\|_\infty)$, 注意到 $\mathcal{B}_{\|\cdot\|_\infty}(\mathbf{0},1) = [-1,1]^d$, 应用定理 1.1 可得到

$$\left(\frac{1}{\delta}\right)^d \le \mathscr{N}(\delta;[-1,1]^d,\|\cdot\|_\infty) \le \left(\frac{2}{\delta}+1\right)^d$$

$$d\log\frac{1}{\delta} \le \log\mathscr{N}(\delta;[-1,1]^d,\|\cdot\|_\infty) \le d\log(\frac{2}{\delta}+1)$$

2 Gaussian 复杂度和 Rademacher 复杂度

给定集合 $\mathcal{T}\subseteq\mathbb{R}^d$, 定义典则 Gaussian 过程

$$G_\theta = \langle\theta,\boldsymbol{w}\rangle \quad \forall\theta\in\mathcal{T}, w_i \overset{i.i.d.}{\sim} \mathcal{N}(0,1),$$

称

$$\mathscr{G}(\mathcal{T}) = \mathbb{E}_{\boldsymbol{w}}[\sup_{\theta\in\mathcal{T}}\langle\theta,\boldsymbol{w}\rangle]$$

为集合 $\mathcal{T}$ 的 Gaussian 复杂度.

类似地, 定义 Rademacher 过程

$$R_\theta = \langle\theta,\boldsymbol{\epsilon}\rangle \quad \forall\theta\in\mathcal{T},$$

其中 $\boldsymbol{\epsilon} = (\epsilon_i)_{i\in[d]}$ 各元素为相互独立的 Rademacher 变量.

称

$$\mathscr{R}(\mathcal{T}) = \mathbb{E}_{\boldsymbol{\epsilon}}[\sup_{\theta\in\mathcal{T}}\langle\theta,\boldsymbol{\epsilon}\rangle]$$

为集合 $\mathcal{T}$ 的 Rademacher 复杂度.

例 2.1. 考虑集合 $\mathcal{B}_2^d(1)=\{\theta\in\mathbb{R}^d:\|\theta\|_2\le 1\}$, 计算 $\mathscr{R}(\mathcal{B}_2(1))$ 和 $\mathscr{G}(\mathcal{B}_2^d(1))$.

$$\begin{aligned}\mathscr{R}(\mathcal{B}_2^d(1)) &= \mathbb{E}_{\boldsymbol{\epsilon}}[\sup_{\theta\in\mathcal{B}_2^d(1)}\langle\theta,\boldsymbol{\epsilon}\rangle]\\ &= \mathbb{E}_{\boldsymbol{\epsilon}}[\left\langle\frac{\boldsymbol{\epsilon}}{\|\boldsymbol{\epsilon}\|_2},\boldsymbol{\epsilon}\right\rangle]\\ &= \mathbb{E}_{\boldsymbol{\epsilon}}\|\boldsymbol{\epsilon}\|_2\\ &= \mathbb{E}\sqrt{\sum_{i=1}^d\epsilon_i^2}=\sqrt{d}\end{aligned}$$

类似地,

$$\mathscr{G}(\mathcal{B}_2^d(1))=\mathbb{E}\|\boldsymbol{w}\|_2=\mathbb{E}\sqrt{\sum_{i=1}^d w_i^2}\le\sqrt{\sum_{i=1}^d\mathbb{E}w_i^2}=\sqrt{d}$$

例 2.2. 考虑一致 b-有界函数类 $\mathcal{F}$, 即 $\forall f\in\mathcal{F}$, $\|f\|_\infty\le b$. 给定 n 个数据点 $x_1^n=(x_i)_{\{i\in[n]\}}$, 定义集合

$$\mathcal{F}(x_1^n)/n=\{(f(x_1),f(x_2),\cdots,f(x_n))/n:f\in\mathcal{F}\},$$

计算 $\mathscr{G}(\mathcal{F}(x_1^n)/n)$.

$$\begin{aligned}\mathscr{G}(\mathcal{F}(x_1^n)/n) &= \mathbb{E}_{\boldsymbol{w}}[\sup_{f\in\mathcal{F}}\langle f(x_1^n)/n,\boldsymbol{w}\rangle]\\ &= \mathbb{E}_{\boldsymbol{w}}\left[\sup_{f\in\mathcal{F}}\sum_{i=1}^n\frac{f(x_i)w_i}{n}\right]\\ &\le \mathbb{E}_{\boldsymbol{w}}\left[\sup_{f\in\mathcal{F}}\frac{1}{n}\sqrt{\sum_i^n(f(x_i))^2}\|\boldsymbol{w}\|_2\right]\\ &\le \mathbb{E}_{\boldsymbol{w}}\frac{b}{\sqrt{n}}\|\boldsymbol{w}\|_2\le\frac{b}{\sqrt{n}}\sqrt{n}=b.\end{aligned}$$

引理 2.1

对任意 $\mathcal{T}\subseteq\mathbb{R}^d$

(1) $\mathscr{R}(\mathcal{T})\le\sqrt{\frac{\pi}{2}}\mathscr{G}(\mathcal{T})$,

(2) $\mathscr{G}(\mathcal{T})\le 2\sqrt{\log d}\mathscr{R}(\mathcal{T})$.

第十讲

王伟文　暨南大学

1　sub-Gaussian 过程

定义 1.1

一组随机变量 $\{X_\theta : \theta \in \mathcal{T}\}$, 其中 $\mathbb{E}[X_\theta] = 0, \forall \theta \in \mathcal{T}$, 若满足

$$\mathbb{E}[e^{\lambda(X_\theta - X_{\bar\theta})}] \le e^{\lambda^2 \rho^2(\theta,\bar\theta)/2} \quad \forall \theta, \bar\theta \in \mathcal{T}, \forall \lambda \in \mathbb{R},$$

其中 ρ 为定义在 $\mathcal{T}$ 上的度量, 则称 $\{X_\theta : \theta \in \mathcal{T}\}$ 为 sub-Gaussian 过程.

由上述定义, 给定 θ 及 $\bar\theta$, $(X_\theta - X_{\bar\theta})$ 是均值为 0、以 $\rho(\theta,\bar\theta)$ 为参数的 sub-Gaussian 随机变量, 故

$$\mathbb{P}[|X_\theta - X_{\bar\theta}| \ge \delta] \le 2e^{-\frac{\delta^2}{2\rho^2(\theta,\bar\theta)}} \quad \forall \delta \ge 0.$$

2　单步离散化上界

定理 2.1

设 $\{X_\theta : \theta \in \mathcal{T}\}$ 是均值为 0、在度量 ρ 下的 sub-Gaussian 过程. 记 $D := \sup\limits_{\theta,\bar\theta\in\mathcal{T}} \rho(\theta,\bar\theta)$. 对任意 $\delta \in [0, D]$ 使得 $\mathcal{N}(\delta;\mathcal{T},\rho) \ge 0$, 有

$$\mathbb{E}\left[\sup_{\theta,\bar\theta\in\mathcal{T}} (X_\theta - X_{\bar\theta})\right] \le 2\left[\sup_{\substack{\gamma,\gamma'\in\mathcal{T}\\ \rho(\gamma,\gamma')\le\delta}} (X_\gamma - X_{\gamma'})\right] + 4\sqrt{D^2 \log \mathcal{N}(\delta;\mathcal{T},\rho)}$$

成立.

定理 2.1 提供了 $\mathbb{E}[\sup\limits_{\theta\in\mathcal{T}} X_\theta]$ 的上界:

$$\mathbb{E}[\sup_{\theta\in\mathcal{T}} X_\theta] = \mathbb{E}[\sup_{\theta\in\mathcal{T}}(X_\theta - \mathbb{E}[X_{\theta_0}])] = \mathbb{E}[\sup_{\theta\in\mathcal{T}}(X_\theta - X_{\theta_0})] \le \mathbb{E}\left[\sup_{\theta,\bar\theta\in\mathcal{T}} (X_\theta - X_{\bar\theta})\right]$$

例 2.1. 考虑单位球 $\mathcal{B}_2 = \{\theta \in \mathbb{R}^d : \|\theta\|_2 \le 1\}$, 已知其 δ-覆盖数 $\mathcal{N}(\delta;\mathcal{B}_2,\|\cdot\|_2) \le d\log(1+\frac{2}{\delta})$, $D := \sup\limits_{\theta,\bar\theta\in\mathcal{B}_2} \rho(\theta,\bar\theta) = 2$.

定义随机变量 $X_\theta = \langle \theta, \boldsymbol{w} \rangle$, 其中 $w_i \overset{i.i.d.}{\sim} \mathcal{N}(0,1)$, 则

$$\begin{aligned}
\sup_{\substack{\gamma,\gamma' \in \mathcal{B}_2 \\ \|\gamma-\gamma'\|_2 \le \delta}} (X_\gamma - X_{\gamma'}) &= \sup_{\substack{\gamma,\gamma' \in \mathcal{B}_2 \\ \|\gamma-\gamma'\|_2 \le \delta}} \langle \gamma - \gamma', \boldsymbol{w} \rangle \\
&\le \sup_{\substack{\gamma,\gamma' \in \mathcal{B}_2 \\ \|\gamma-\gamma'\|_2 \le \delta}} \|\boldsymbol{w}\|_2 \|\gamma - \gamma'\|_2 \\
&\le \delta \|\boldsymbol{w}\|_2
\end{aligned}$$

故

$$\mathbb{E}\left[\sup_{\substack{\gamma,\gamma' \in \mathcal{B}_2 \\ \|\gamma-\gamma'\|_2 \le \delta}} (X_\gamma - X_{\gamma'})\right] \le \mathbb{E}\left[\delta \|\boldsymbol{w}\|_2\right] \le \sqrt{d}\delta$$

由定理 2.1, 欧氏单位球的 Gaussian 复杂度

$$\mathscr{G}(\mathcal{B}_2) = \mathbb{E}[\sup_{\theta \in \mathcal{B}_2} X_\theta] \le 2\sqrt{d}\left(\delta + 2\sqrt{2\log(1+\frac{2}{\delta})}\right) \quad \forall \delta \in (0,2].$$

不等式右边关于 $\delta \in (0,2]$ 最小化得到欧氏单位球的 Gaussian 复杂度上界.

3 定理 2.1 证明

证明. 给定 $\delta > 0$, 记 $N = \mathscr{N}(\delta; \mathcal{T}, \rho)$, 设 $\{\theta^1, \cdots, \theta^N\}$ 为 $\mathcal{T}$ 的 δ-覆盖. 故 $\forall \theta \in \mathcal{T}$, $\exists \theta^i$ 使得 $\rho(\theta, \theta^i) \le \delta$.

$$\begin{aligned}
X_\theta - X_{\theta^1} &= X_\theta - X_{\theta^i} + X_{\theta^i} - X_{\theta^1} \\
&\le \sup_{\substack{\gamma,\gamma' \in \mathcal{T} \\ \rho(\gamma,\gamma') \le \delta}} (X_\gamma - X_{\gamma'}) + \max_{i=1,\dots,N} |X_{\theta^i} - X_{\theta^1}|
\end{aligned}$$

类似地

$$X_{\theta^1} - X_{\bar{\theta}} \le \sup_{\substack{\gamma,\gamma' \in \mathcal{T} \\ \rho(\gamma,\gamma') \le \delta}} (X_\gamma - X_{\gamma'}) + \max_{i=1,\dots,N} |X_{\theta^i} - X_{\theta^1}|$$

因此

$$X_\theta - X_{\bar{\theta}} \le 2 \sup_{\substack{\gamma,\gamma' \in \mathcal{T} \\ \rho(\gamma,\gamma') \le \delta}} (X_\gamma - X_{\gamma'}) + 2 \max_{i=1,\dots,N} |X_{\theta^i} - X_{\theta^1}|$$

另一方面, $X_{\theta^i} - X_{\theta^1}$ 是以 $\rho(\theta^i, \theta^1)$ 为参数的、均值为 0 的 sub-Gaussian 变量, 故对任意 $i \in [N]$, $X_{\theta^i} - X_{\theta^1}$ 是以 D 为参数的 sub-Gaussian, 因此

$$\mathbb{E} \max_{i=1,\dots,N} |X_{\theta^i} - X_{\theta^1}| \le 2\sqrt{D^2 \log N} \quad N \ge 3.$$

□

4 Dudley's 积分不等式

定理 4.1: Dudley's 积分不等式

设 $\{X_\theta : \theta \in \mathcal{T}\}$ 是均值为 0、在度量 ρ 下的 sub-Gaussian 过程, 记 $D := \sup_{\theta,\bar{\theta}\in\mathcal{T}} \rho(\theta,\bar{\theta})$, 则

$$\mathbb{E}\sup_{\theta\in\mathcal{T}} X_\theta \le \overset{16}{\cancel{8}} D \int_0^\infty \sqrt{\log \mathscr{N}(\epsilon;\mathcal{T},\rho)}\mathrm{d}\epsilon$$

证明. 不失一般性假设 $D = 1$, $\mathcal{T}$ 为有限集 (无限集不等式右端为无穷), 定义

$$\epsilon = 2^{-k}, \quad k \in \mathbb{Z}.$$

选择 $\mathcal{T}$ 的一个 ϵ_k-覆盖 $\mathcal{T}_k$, 满足

$$\mathtt{card}(\mathcal{T}_k) = \mathscr{N}(\epsilon_k;\mathcal{T},\rho).$$

因为 $\mathcal{T}$ 为有限集, 故存在 $\kappa \in \mathbb{Z}$ 使得, 有 $\theta_0 \in \mathcal{T}$ 满足

$$T_\kappa = \{\theta_0\};$$

存在 $K \in \mathbb{Z}$, 使得

$$T_K = T.$$

$\forall\theta \in \mathcal{T}$, 定义

$$\pi_k(\theta) = \arg\min_{\tilde{\theta}\in\mathcal{T}_k} \rho(\theta,\tilde{\theta}) \quad \forall k \in \mathbb{Z}.$$

又因为 $\mathcal{T}_k$ 为 $\mathcal{T}$ 的一个 ϵ_k-覆盖, 故

$$\rho(\theta,\pi_k(\theta)) \le \epsilon_k$$

$X_\theta - X_{\theta_0}$ 可展开为有限项的和

$$X_\theta - X_{\theta_0} = (X_{\pi_\kappa(\theta)} - X_{\theta_0}) + (X_{\pi_{\kappa+1}(\theta)} - X_{\pi_\kappa(\theta)}) + \cdots + (X_\theta - X_{\pi_K(\theta)})$$

因为 $\mathcal{T}_K = \mathcal{T}$,

$$\pi_K(\theta) = \arg\min_{\tilde{\theta}\in\mathcal{T}_K} \rho(\theta,\tilde{\theta}) = \theta$$

$\mathcal{T}_\kappa = \{\theta_0\}$,

$$\pi_\kappa(\theta) = \arg\min_{\tilde{\theta}\in\mathcal{T}_K} \rho(\theta,\tilde{\theta}) = \theta_0$$

故 $X_{\pi_\kappa(\theta)} - X_{\theta_0} = 0$, $X_\theta - X_{\pi_K(\theta)} = 0$.

$$X_\theta - X_{\theta_0} = \sum_{k=\kappa+1}^{K} \left(X_{\pi_k(\theta)} - X_{\pi_{k-1}(\theta)}\right)$$

因此

$$\mathbb{E}\sup_{\theta\in\mathcal{T}}(X_\theta - X_{\theta_0}) \le \sum_{k=\kappa+1}^{K} \mathbb{E}\sup_{\theta\in\mathcal{T}}\left(X_{\pi_k(\theta)} - X_{\pi_{k-1}(\theta)}\right)$$

接下来, 需要控制不等式右端求和各项.

因为 $\{X_\theta : \theta \in \mathcal{T}\}$ 为 sub-Gaussian 过程, 故 $X_{\pi_k(\theta)} - X_{\pi_{k-1}(\theta)}$ 是以 $\rho(\pi_k(\theta), \pi_{k-1}(\theta))$ 为参数的 sub-Gaussian 变量.

由三角不等式

$$\begin{aligned}\rho(\pi_k(\theta), \pi_{k-1}(\theta)) &\le \rho(\pi_k(\theta), \theta) + \rho(\theta, \pi_{k-1}(\theta)) \\ &\le \epsilon_k + \epsilon_{k-1} \\ &\le 2\epsilon_{k-1}\end{aligned}$$

另一方面,

$$\mathtt{card}\left(\{X_{\pi_k(\theta)} - X_{\pi_{k-1}(\theta)} : \theta \in \mathcal{T}\}\right) = \mathtt{card}(\mathcal{T}_k)\cdot\mathtt{card}(\mathcal{T}_{k-1}) \le \mathtt{card}(\mathcal{T}_k)^2$$

由 sub-Gaussian 最大值知

$$\mathbb{E}\sup_{\theta\in\mathcal{T}}\left(X_{\pi_k(\theta)} - X_{\pi_{k-1}(\theta)}\right) \le \overset{4}{\cancel{2}}\epsilon_{k-1}\sqrt{\log \mathtt{card}(T_k)}$$

将 ϵ_{k-1} 及 $\mathtt{card}(\mathcal{T}_k)$ 的值代入得到

$$\mathbb{E}\sup_{\theta\in\mathcal{T}}(X_\theta - X_{\theta_0}) \le \overset{8}{\cancel{4}} \sum_{k=\kappa+1}^{K} 2^{-k}\sqrt{\log \mathscr{N}(2^{-k}; \mathcal{T}, \rho)}$$

又因为 $2^{-k} = 2\int_{2^{-k-1}}^{2^{-k}} \mathrm{d}\epsilon$; 若 $\epsilon \le 2^{-k}$, $\mathscr{N}(\epsilon; \mathcal{T}, \rho) \ge \mathscr{N}(2^{-k}; \mathcal{T}, \rho)$.

故

$$\begin{aligned}\mathbb{E}\sup_{\theta\in\mathcal{T}}(X_\theta - X_{\theta_0}) &\le \overset{8}{\cancel{4}} \sum_{k=\kappa+1}^{K} 2^{-k}\sqrt{\log \mathscr{N}(2^{-k}; \mathcal{T}, \rho)} \\ &\le \overset{16}{\cancel{8}} \sum_{k=\kappa+1}^{K} \int_{2^{-k-1}}^{2^{-k}} \sqrt{\log \mathscr{N}(\epsilon; \mathcal{T}, \rho)}\mathrm{d}\epsilon \\ &\le \overset{16}{\cancel{8}} \int_0^\infty \sqrt{\log \mathscr{N}(\epsilon; \mathcal{T}, \rho)}\mathrm{d}\epsilon\end{aligned}$$

又因为 $\mathbb{E}X_{\theta_0} = 0$,

$$\mathbb{E}\sup_{\theta\in\mathcal{T}} X_\theta = \mathbb{E}\sup_{\theta\in\mathcal{T}}(X_\theta - \mathbb{E}X_{\theta_0}) = \mathbb{E}\sup_{\theta\in\mathcal{T}}(X_\theta - X_{\theta_0}),$$

结论得证. □

例 4.1. 考虑集合 $\mathcal{B}_2^d(1) = \{\theta \in \mathbb{R}^d : \|\theta\|_2 \le 1\}$, 计算 $\mathscr{G}(\mathcal{B}_2^d(1))$.

$$\mathscr{G}(\mathcal{B}_2^d(1)) = \mathbb{E} \sup_{\theta \in \mathcal{B}_2^d(1)} \langle \theta, \boldsymbol{w} \rangle = \mathbb{E}\|\boldsymbol{w}\|_2 = \mathbb{E}\sqrt{\sum_{i=1}^d w_i^2} \le \sqrt{\sum_{i=1}^d \mathbb{E} w_i^2} = \sqrt{d}$$

由体积比例定理, $\mathscr{N}(\epsilon; \mathcal{B}_2^d(1), \|\cdot\|_2) \le (1+\frac{2}{\epsilon})^d \le (\frac{3}{\epsilon})^d, \forall \epsilon \in (0,1]$.

若 $\epsilon > 1, \mathscr{N}(\epsilon; \mathcal{B}_2^d(1), \|\cdot\|_2) = 1$, 有 Dudley 积分不等式

$$\mathscr{G}(\mathcal{B}_2^d(1)) = \mathbb{E} \sup_{\theta \in \mathcal{B}_2^d(1)} \le 16 \int_0^1 \sqrt{d \log \frac{3}{\epsilon}} \mathrm{d}\epsilon \le C\sqrt{d}.$$

5 Dudley 积分不等式应用: Lipschitz 连续函数的 Monte-Carlo 法

考虑积分

$$\int_0^1 f(x)\mathrm{d}x = \mathbb{E}_{X \sim \mathtt{Unif}[0,1]}[f(X)] \approx \frac{1}{n}\sum_{i=1}^n f(X_i)$$

定理 5.1

设函数类

$$\mathcal{F} \triangleq \{f : [0,1] \to \mathbb{R} \text{且} f \text{为} L - \text{Lipschitz 连续}\},$$

若 $X, X_1, X_2, \ldots, X_n$ 为取值处于区间 $[0,1]$ 的独立同分布样本, 则存在常数 $C > 0$, 使得

$$\mathbb{E} \sup_{f \in \mathcal{F}} \left| \frac{1}{n}\sum_{i=1}^n f(X_i) - \mathbb{E}[f(X)] \right| \le \frac{CL}{\sqrt{n}}.$$

应用 Dudley 积分不等式的定理 5.1 证明思路.

- 定义随机过程

$$X_f = \frac{1}{2\sqrt{n}} \sum_{i=1}^n \left(f(X_i) - \mathbb{E}[f(X)]\right), \quad f \in \mathcal{F}.$$

- 证明随机过程 $\{X_f : f \in \mathcal{F}\}$ 是度量 $\|\cdot\|_\infty$ 下的 sub-Gaussian 过程, 其中

$$\|f - g\|_\infty = \sup_{x \in [0,1]} |f(x) - g(x)| \quad \forall f, g \in \mathcal{F}.$$

- 计算度量空间 $(\mathcal{F}, \|\cdot\|_\infty)$ 的度量熵:

$$\log \mathscr{N}(\epsilon; \mathcal{F}, \|\cdot\|_\infty) \quad \forall \epsilon > 0.$$

为简化定理 5.1 的证明过程, 考虑简单函数类

$$\mathcal{F}_{0,1} \triangleq \{f : [0,1] \to \mathbb{R}, f(0) = 0, \text{且} f \text{为} 1 - \text{Lipschitz 连续}\},$$

引理 5.1

随机过程 $\{X_f : f \in \mathcal{F}_{0,1}\}$ 是度量 $\|\cdot\|_\infty$ 下的 sub-Gaussian 过程.

证明. 只需证明 $\forall f, g \in \mathcal{F}_{0,1}$, 随机变量

$$X_{f,i} - X_{g,i} = \frac{1}{2\sqrt{n}} \left(f(X_i) - \mathbb{E}[f(X_i)] - (g(X_i) - \mathbb{E}[g(X_i)])\right)$$

有界.

因为

$$\begin{aligned} |X_{f,i} - X_{g,i}| &= \frac{1}{2\sqrt{n}} \left(f(X_i) - \mathbb{E}[f(X_i)] - (g(X_i) - \mathbb{E}[g(X_i)])\right) \\ &\leq \frac{1}{\sqrt{n}} \|f - g\|_\infty \end{aligned}$$

故 $X_{f,i} - X_{g,i}$ 是以 $\frac{1}{\sqrt{n}}\|f - g\|_\infty$ 为参数的 sub-Gaussian 随机变量.

由 $\{X_i\}$ 相互独立, $\{X_{f,i} - X_{g,i}\}$ 为相互独立的 sub-Gaussian 随机变量. 故

$$\begin{aligned} X_f - X_g &= \frac{1}{2\sqrt{n}} \sum_{i=1}^{n} (f(X_i) - \mathbb{E}[f(X)]) - \frac{1}{2\sqrt{n}} \sum_{i=1}^{n} (g(X_i) - \mathbb{E}[g(X)]) \\ &= \sum_{i=1}^{n} (X_{f,i} - X_{g,i}) \end{aligned}$$

是以

$$\sqrt{\sum_{i=1}^{n} \frac{1}{n} \|f - g\|_\infty^2} = \|f - g\|_\infty$$

为参数的 sub-Gaussian 变量.

因此 $\{X_f : f \in \mathcal{F}\}$ 为度量 $\|\cdot\|_\infty$ 下的 sub-Gaussian 过程.

□

下面引理 5.2 给出度量空间 $(\mathcal{F}_{0,1}, \|\cdot\|_\infty)$ 的 ϵ-覆盖数上界估计.

引理 5.2

存在常数 $c > 0$, 使得

$$\mathscr{N}(\epsilon; \mathcal{F}_{0,1}, \|\cdot\|_\infty) \begin{cases} \leq e^{c/\epsilon}, & \epsilon \in [0,1]; \\ = 1, & \epsilon > 1. \end{cases}$$

证明. 若 $\epsilon > 1$. 取常数函数 $h(x) = 0, \forall x \in (0,1]$, 则

$$\|f - h\|_\infty = \sup_{x \in [0,1]} |f(x)| = \sup_{x \in [0,1]} |f(x) - f(0)| \leq \sup_{x \in [0,1]} |x| = 1 < \epsilon.$$

此时 $\{h\}$ 为 $\mathcal{F}_{0,1}$ 的一个最小 ϵ-覆盖, 故

$$\mathscr{N}(\epsilon; \mathcal{F}_{0,1}, \|\cdot\|_\infty) = 1.$$

若 $0<\epsilon\le 1$, 定义函数类

$$\begin{aligned}\mathcal{F}_{0,1}^{\epsilon} \triangleq \{f\text{为分片线性函数}: f(0)=0, f(1/\epsilon)\in\{\pm 1/\epsilon, 0\},\\ f(2/\epsilon)\in f(1/\epsilon)+\{\pm 1/\epsilon,0\},\\ \cdots,\\ f(n/\epsilon)\in f((n-1)/\epsilon)+\{\pm 1/\epsilon,0\},\\ f(1)\in f(n/\epsilon)+\{\pm 1/\epsilon,0\}\}\end{aligned}$$

其中 $n=\lfloor 1/\epsilon\rfloor$.

有 $\mathcal{F}_{0,1}^{\epsilon}\subseteq\mathcal{F}_{0,1}$, 且 $\mathcal{F}_{0,1}^{\epsilon}$ 为 $\mathcal{F}_{0,1}$ 的一个 ϵ-覆盖. 由 1-Lipschitz 连续性, 对任意 $f\in\mathcal{F}_{0,1}$, 存在 $g\in\mathcal{F}_{0,1}^{\epsilon}$, 使得

$$|f(x)-g(x)|\le\epsilon\quad\forall x\in\bigcup_{i\in\{0,n-1\}}[\frac{i}{\epsilon},\frac{i+1}{\epsilon}]\bigcup[\frac{n}{\epsilon},1],$$

即

$$\|f-g\|_\infty=\sup_{x\in[0,1]}|f(x)-g(x)|\le\epsilon.$$

因此, 存在 $c>0$ 使得

$$\mathscr{N}(\epsilon;\mathcal{F}_{0,1},\|\cdot\|_\infty)\le\mathtt{card}(\mathcal{F}_{0,1}^{\epsilon})=3^{n+1}\le e^{c/\epsilon}.$$

□

定理 5.1 **证明**

Step 1 由引理 5.2, 随机过程 $\{X_f: f\in\mathcal{F}_{0,1}\}$ 是以 0 为均值的 sub-Gaussian 过程.

Step 2 由引理 5.2, 存在 $c>0$

$$\log\mathscr{N}(\epsilon;\mathcal{F}_{0,1}^{\epsilon},\|\cdot\|_\infty)\le\frac{c}{\epsilon}\quad\epsilon\in(0,1].$$

Step 3

$$\begin{aligned}D:=\sup_{f,g\in\mathcal{F}_{0,1}}\|f-g\|_\infty&=\sup_{f,g\in\mathcal{F}_{0,1}}\sup_{x\in[0,1]}|f(x)-g(x)|\\&\le\sup_{f,g\in\mathcal{F}_{0,1}}\left(\sup_{x\in[0,1]}|f(x)-f(0)|+\sup_{x\in[0,1]}|g(x)-g(0)|\right)\\&\le 2\cdot 1.\end{aligned}$$

应用 Dudley 积分不等式,

$$\mathbb{E}\sup_{f\in\mathcal{F}_{0,1}}\left[\left|\frac{1}{2\sqrt{n}}\sum_{i=1}^{n}(f(X_i)-\mathbb{E}[f(X)])\right|\right]\le C_1\cdot 1\int_0^1\sqrt{c/\epsilon}\mathtt{d}\epsilon\triangleq\frac{C\cdot 1.}{2}$$

上式可改写为

$$\mathbb{E}\sup_{f\in\mathcal{F}_{0,1}}\left[\left|\frac{1}{n}\sum_{i=1}^{n}f(X_i)-\mathbb{E}[f(X)]\right|\right]\le\frac{C\cdot 1}{\sqrt{n}}$$

6 Monte-Carlo 法在 d-维空间推广

考虑函数类

$$\mathcal{F}^d \triangleq \{f:[0,1]^d \to \mathbb{R}\text{且}f\text{为}L-\text{Lipschitz 连续}\},$$

引理 6.1

存在常数 $c>0$, 使得

$$\mathscr{N}(\epsilon;\mathcal{F}^d,\|\cdot\|_\infty)\begin{cases}\le e^{(c/\epsilon)^d}, & \epsilon\in[0,1];\\ =1, & \epsilon>1.\end{cases}$$

若 $d\ge 2$, 奇异积分

$$\int_0^1\sqrt{(c/\epsilon)^d}=\infty,$$

此时 Dudley 积分不等式不再适用.

分析 Dudley 积分不等式的证明过程, 可通过设定一个稍微大一点的 $\delta>0$ 作为 Chaining 的分解点, 避免出现较小的 ϵ, 即, 取 $f_0\in\mathcal{F}^d$

$$\begin{aligned}\mathbb{E}\sup_{f\in\mathcal{F}^d}|X_f-X_{f_0}| &\lesssim L\int_\delta^\infty\sqrt{\log\mathscr{N}(\epsilon;\mathcal{F}^d,\|\cdot\|_\infty)}+\mathbb{E}\sup_{\substack{f,g\in\mathcal{F}\\ \|f-g\|_\infty\le\delta}}|X_f-X_g|\\ &\lesssim Lc^d\delta^{-d/2+1}+\sqrt{1}\sqrt{n}\delta\end{aligned}$$

其中"$\lesssim$" 表示省略无关常数.

故

$$\begin{aligned}\mathbb{E}\sup_{f\in\mathcal{F}^d}|2\sqrt{n}X_f| &\le \mathbb{E}\sup_{f\in\mathcal{F}^d}|2\sqrt{n}(X_f-\mathbb{E}[X_{f_0}])|\\ &\le 2\sqrt{n}\mathbb{E}\sup_{f\in\mathcal{F}^d}|X_f-X_{f_0}|\\ &\lesssim Lc^d\delta^{-d/2+1}\frac{1}{\sqrt{n}}+\delta\end{aligned}$$

不等式右端关于 δ 最小化, 最优 $\delta^*=\frac{c^2L^{2/d}}{n^{1/d}}(d/2-1)^{1/d}$, 代入原式得到

$$\mathbb{E}\sup_{f\in\mathcal{F}^d}|2\sqrt{n}X_f|\lesssim\left(\frac{L^2}{n}\right)^{1/d}$$

因此, 存在 $C>0$, 使得

$$\mathbb{E}\sup_{f\in\mathcal{F}_{0,1}}\left[\left|\frac{1}{n}\sum_{i=1}^n f(X_i)-\mathbb{E}[f(X)]\right|\right]\le C\left(\frac{L^2}{n}\right)^{1/d}$$

令 $C\left(\frac{L^2}{n}\right)^{1/d} \leq \Delta$, 解得

$$n \geq \frac{1}{L^2}\left(\frac{C}{\Delta}\right)^d \quad \forall d \geq 2.$$

这表明要使用 Monte-Carlo 方法要得到“较好”的近似, 样本量随着维度指数增长, 此时即“维数灾难”(Curse of Dimensionality).

第十一讲

王伟文　暨南大学

1　线性代数回顾

定理 1.1: 对称实矩阵谱分解

任意 n 阶实矩阵 $\boldsymbol{A}$ 可以表示为

$$\boldsymbol{A} = \sum_{i=1}^{n} \lambda_i \boldsymbol{u}_i \boldsymbol{u}_i^T,$$

其中 $(\lambda_i, \boldsymbol{u}_i)$ 为矩阵 $\boldsymbol{A}$ 的特征值及相应的正交化单位特征向量, $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n$.

令 $\boldsymbol{U} = [\boldsymbol{u}_1, \boldsymbol{u}_2, \ldots, \boldsymbol{u}_r] \in \mathbb{R}^{n\times r}$, $\Lambda = \mathtt{diag}(\lambda_1, \lambda_2, \ldots, \lambda_r)$, 则

$$\boldsymbol{A} = \boldsymbol{U}\Lambda\boldsymbol{U}^T.$$

从优化的视角看特征值

$$\lambda_1 = \langle \boldsymbol{A}\boldsymbol{u}_1, \boldsymbol{u}_1\rangle = \max_{\|\boldsymbol{x}\|=1} \boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}, \quad \boldsymbol{u}_1 = \arg\max_{\|\boldsymbol{x}\|=1} \boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}$$

$$\lambda_2 = \langle \boldsymbol{A}\boldsymbol{u}_2, \boldsymbol{u}_2\rangle = \max_{\substack{\boldsymbol{x}\perp\boldsymbol{u}_1\\ \|\boldsymbol{x}\|=1}} \boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}, \quad \boldsymbol{u}_2 = \arg\max_{\substack{\boldsymbol{x}\perp\boldsymbol{u}_1\\ \|\boldsymbol{x}\|=1}} \boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}$$

$$\lambda_3 = \langle \boldsymbol{A}\boldsymbol{u}_3, \boldsymbol{u}_3\rangle = \max_{\substack{\boldsymbol{x}\perp\{\boldsymbol{u}_1,\boldsymbol{u}_2\}\\ \|\boldsymbol{x}\|=1}} \boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}, \quad \boldsymbol{u}_3 = \arg\max_{\substack{\boldsymbol{x}\perp\{\boldsymbol{u}_1,\boldsymbol{u}_2\}\\ \|\boldsymbol{x}\|=1}} \boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}$$

$$\cdots$$

$$\lambda_n = \langle \boldsymbol{A}\boldsymbol{u}_n, \boldsymbol{u}_n\rangle = \min_{\|\boldsymbol{x}\|=1} \boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}, \quad \boldsymbol{u}_n = \arg\min_{\|\boldsymbol{x}\|=1} \boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}$$

命题 1.1

对任意 n-阶对称矩阵 $\boldsymbol{A}$, 有

$$\lambda_1 = \langle \boldsymbol{A}\boldsymbol{u}_1, \boldsymbol{u}_1\rangle = \max_{\|\boldsymbol{x}\|=1} \boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}, \quad \boldsymbol{u}_1 = \arg\max_{\|\boldsymbol{x}\|=1} \boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}$$

$$\lambda_n = \langle \boldsymbol{A}\boldsymbol{u}_n, \boldsymbol{u}_n\rangle = \min_{\|\boldsymbol{x}\|=1} \boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}, \quad \boldsymbol{u}_n = \arg\min_{\|\boldsymbol{x}\|=1} \boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}$$

证明. 由定理 1.1 知, 矩阵 $\boldsymbol{A}$ 可表示谱分解的形式 $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Lambda}\boldsymbol{U}^T$, 故

$$\begin{aligned}\max_{\|\boldsymbol{x}\|=1}\boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}&=\max_{\|\boldsymbol{x}\|=1}\boldsymbol{x}^T\boldsymbol{U}\boldsymbol{\Lambda}\boldsymbol{U}^T\boldsymbol{x}\\&=\max_{\|\boldsymbol{y}\|^2=1}\boldsymbol{y}^T\boldsymbol{\Lambda}\boldsymbol{y}=\max_{\|\boldsymbol{y}\|^2=1}\sum_{i=1}^n y_i^2\lambda_i\quad(\boldsymbol{y}=\boldsymbol{U}^T\boldsymbol{x})\\&=\max_{\boldsymbol{\xi}\in\Delta_n}\sum_{i=1}^n\xi_i\lambda_i=\lambda_1\quad(y_i^2=\xi)\end{aligned}$$

余下结论显然成立. □

定理 1.2: 奇异值分解 (Singular Value Decomposition)

$\forall\boldsymbol{A}\in\mathbb{R}^{m\times n}$, 可以表示为

$$\boldsymbol{A}=\sum_{i=1}^r\sigma_i\boldsymbol{u}_i\boldsymbol{v}_i^T$$

其中 $\sigma_1\geq\sigma_2\geq\cdots\geq\sigma_r>0$ 为奇异值, $\boldsymbol{u}_i$ 为左奇异向量, $\boldsymbol{v}_i$ 为右奇异向量, 满足

$$\sigma_i=\sqrt{\lambda_i(\boldsymbol{A}\boldsymbol{A}^T)}=\sqrt{\lambda_i(\boldsymbol{A}^T\boldsymbol{A})};$$

$$\{\boldsymbol{u}_i\}\text{为矩阵}\boldsymbol{A}\boldsymbol{A}^T\text{的正交化特征向量};$$

$$\{\boldsymbol{v}_i\}\text{为矩阵}\boldsymbol{A}^T\boldsymbol{A}\text{的正交化特征向量}.$$

且 $r=\mathtt{rank}(\boldsymbol{A})$.

奇异值分解的矩阵形式

$$\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^T,$$

其中 $\boldsymbol{U}\in\mathbb{R}^{m\times n}$, $\boldsymbol{V}\in\mathbb{R}^{n\times n}$ 为正交矩阵, 分别为矩阵 $\boldsymbol{A}\boldsymbol{A}^T$ 和 $\boldsymbol{A}^T\boldsymbol{A}$ 的正交化特征向量构成的列矩阵, $\boldsymbol{\Sigma}\in\mathbb{R}^{m\times n}$ 的对角元为奇异值 $(\sigma_1,\sigma_2,\ldots,\sigma_r)$, 其他位置为 0.

紧凑形式

$$\boldsymbol{A}=\boldsymbol{U}_r\boldsymbol{\Sigma}_r\boldsymbol{V}_r^T,$$

其中 $\boldsymbol{U}_r\in\mathbb{R}^{m\times r}$ 和 $\boldsymbol{V}_r\in\mathbb{R}^{n\times r}$ 分别为 $\boldsymbol{U}$ 和 $\boldsymbol{V}$ 的前 r 列, 满足 $\boldsymbol{U}_r^T\boldsymbol{U}_r=\boldsymbol{V}_r^T\boldsymbol{V}_r=\boldsymbol{I}_r$, $\boldsymbol{\Sigma}_r=\mathtt{diag}(\sigma_1,\sigma_2,\ldots,\sigma_r)$.

从优化的视角看奇异值

$$\sigma_1 = \max_{\|\boldsymbol{x}\|=1} \|\boldsymbol{A}\boldsymbol{x}\|_2, \quad \boldsymbol{v}_1 = \arg\max_{\|\boldsymbol{x}\|=1} \|\boldsymbol{A}\boldsymbol{x}\|_2$$

$$\sigma_2 = \max_{\substack{\boldsymbol{x}\perp\boldsymbol{v}_1 \\ \|\boldsymbol{x}\|=1}} \|\boldsymbol{A}\boldsymbol{x}\|_2, \quad \boldsymbol{v}_2 = \arg\max_{\substack{\boldsymbol{x}\perp\boldsymbol{v}_1 \\ \|\boldsymbol{x}\|=1}} \|\boldsymbol{A}\boldsymbol{x}\|_2$$

$$\sigma_3 = \max_{\substack{\boldsymbol{x}\perp\{\boldsymbol{v}_1,\boldsymbol{v}_2\} \\ \|\boldsymbol{x}\|=1}} \|\boldsymbol{A}\boldsymbol{x}\|_2, \quad \boldsymbol{v}_3 = \arg\max_{\substack{\boldsymbol{x}\perp\{\boldsymbol{v}_1,\boldsymbol{v}_2\} \\ \|\boldsymbol{x}\|=1}} \|\boldsymbol{A}\boldsymbol{x}\|_2$$

$$\cdots$$

$$\sigma_n = \min_{\|\boldsymbol{x}\|=1} \|\boldsymbol{A}\boldsymbol{x}\|_2, \quad \boldsymbol{v}_n = \arg\min_{\|\boldsymbol{x}\|=1} \|\boldsymbol{A}\boldsymbol{x}\|_2$$

命题 1.2

设 $\boldsymbol{A}$ 为 n-阶对称实矩阵, 则有

$$\sigma_1(\boldsymbol{A}) = \max_{\|\boldsymbol{x}\|=1} |\boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}| = \max_{i\in[n]} |\lambda_i(\boldsymbol{A})|.$$

2 矩阵范数

考虑矩阵 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$, Frobenius 范数

$$\|\boldsymbol{A}\|_F = \sqrt{\sum_{i,j} A_{i,j}^2}$$

矩阵内积

$$\langle \boldsymbol{A}, \boldsymbol{B}\rangle = \mathtt{trace}(\boldsymbol{B}^T\boldsymbol{A})$$

$$\|\boldsymbol{A}\|_F^2 = \langle \boldsymbol{A}, \boldsymbol{A}\rangle$$

命题 2.1: $\|\cdot\|_F$ 的正交不变性

对任意正交矩阵 $\boldsymbol{U} \in \mathbb{R}^{m\times m}$ 或 $\boldsymbol{V} \in \mathbb{R}^{n\times n}$, 有

$$\|\boldsymbol{U}\boldsymbol{A}\|_F = \|\boldsymbol{A}\boldsymbol{V}\|_F = \|\boldsymbol{A}\|_F$$

证明. $\|\boldsymbol{U}\boldsymbol{A}\|_F = \sqrt{\langle \boldsymbol{U}\boldsymbol{A}, \boldsymbol{U}\boldsymbol{A}\rangle} = \sqrt{\mathtt{trace}(\boldsymbol{A}^T\boldsymbol{U}^T\boldsymbol{U}\boldsymbol{A})} = \sqrt{\mathtt{trace}(\boldsymbol{A}^T\boldsymbol{A})} = \|\boldsymbol{A}\|_F.$ □

命题 2.2

$\|\boldsymbol{A}\|_F^2 = \sum \sigma_i^2(\boldsymbol{A})$.

证明. 将矩阵 $\boldsymbol{A}$ 表示为 SVD 分解的形式, $\boldsymbol{A}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^T$.

$$\|\boldsymbol{A}\|_F^2=\|\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^T\|\overset{(i)}{=}\|\boldsymbol{\Sigma}\|_F^2=\mathtt{trace}(\boldsymbol{\Sigma}^T\boldsymbol{\Sigma})=\sum\sigma_i^2(\boldsymbol{A}),$$

其中 (i) 由 Frobenius 范数的正交不变性得到. □

定义 2.1: 矩阵谱范数

$$\|\boldsymbol{A}\|=\max_{\|\boldsymbol{x}\|_2=1}\|\boldsymbol{A}\boldsymbol{x}\|_2=\max_{\|\boldsymbol{x}\|_2\le 1}\|\boldsymbol{A}\boldsymbol{x}\|_2=\max_{\boldsymbol{x}}\frac{\|\boldsymbol{A}\boldsymbol{x}\|_2}{\|\boldsymbol{x}\|_2}$$

关于矩阵谱范数有

(a) 对任意正交矩阵 $\boldsymbol{U}\in\mathbb{R}^{m\times m}$ 或 $\boldsymbol{V}\in\mathbb{R}^{n\times n}$, $\|\boldsymbol{U}\boldsymbol{A}\|=\|\boldsymbol{A}\boldsymbol{V}\|=\|\boldsymbol{A}\|$;

(b) 若矩阵 $\boldsymbol{A}$ 可逆, $\|\boldsymbol{A}^{-1}\|=\frac{1}{\sigma_n(\boldsymbol{A})}$

(c) $\|\boldsymbol{A}+\boldsymbol{B}\|\le\|\boldsymbol{A}\|+\|\boldsymbol{B}\|$

(d) $\|\boldsymbol{A}\boldsymbol{B}\|\le\|\boldsymbol{A}\|\|\boldsymbol{B}\|$ $\quad(\|\boldsymbol{A}\boldsymbol{B}\boldsymbol{x}\|_2\le\|\boldsymbol{A}\|\|\boldsymbol{B}\boldsymbol{x}\|_2\le\|\boldsymbol{A}\|\|\boldsymbol{B}\|)$

(e) $\|\boldsymbol{A}\|\le\|\boldsymbol{A}\|_F\le\sqrt{r}\|\boldsymbol{A}\|$ $\quad(\|\boldsymbol{A}\|=\sigma_1(\boldsymbol{A})\le\sqrt{\sum_{i=1}^r\sigma_i^2(\boldsymbol{A})}=\|\boldsymbol{A}\|_F\le\sqrt{r\sigma_1^2(\boldsymbol{A})}=\sqrt{r}\|\boldsymbol{A}\|)$

这里 $r=\mathtt{rank}(\boldsymbol{A})$.

(f) $\|\boldsymbol{A}\|=\max\limits_{\|\boldsymbol{x}\|=1\text{且}\|\boldsymbol{y}\|=1}\boldsymbol{y}^T\boldsymbol{A}\boldsymbol{x}$

$(\|\boldsymbol{z}\|_2=\max\limits_{\|\boldsymbol{y}\|_2=1}\boldsymbol{y}^T\boldsymbol{z},\ \max\limits_{\|\boldsymbol{x}\|=1\text{且}\|\boldsymbol{y}\|=1}\boldsymbol{y}^T\boldsymbol{A}\boldsymbol{x}=\max\limits_{\|\boldsymbol{x}\|=1}\max\limits_{\|y\|_2=1}\boldsymbol{y}^T\boldsymbol{A}\boldsymbol{x}=\max\limits_{\|\boldsymbol{x}\|_2=1}\|\boldsymbol{A}\boldsymbol{x}\|_2=\sigma_1(\boldsymbol{A})=\|\boldsymbol{A}\|)$

3 随机向量

设 X 为一个 d-维随机向量, 其均值为 $\mathbb{E}X=\boldsymbol{\mu}$.

协方差矩阵为

$$\mathtt{cov}(X)=\mathbb{E}(X-\boldsymbol{\mu})(X-\boldsymbol{\mu})^T=\mathbb{E}[XX^T]-\boldsymbol{\mu}\boldsymbol{\mu}^T$$

- $(\mathtt{cov}(X))_{i,j}=\mathbb{E}(X_i-\boldsymbol{\mu}_i)(X_j-\boldsymbol{\mu}_j)=\mathtt{cov}(X_i,X_j)$
- $(\mathtt{cov}(X))_{i,i}=\mathtt{var}(X_i)$

命题 3.1

$\mathtt{cov}(X)$ 是一个正半定矩阵.

4 主成分分析 (Principal Component Analysis, PCA)

设 $X \in \mathbb{R}^d$ 是以 0 为均值的随机向量, 协方法为 $\mathtt{cov}(X) = \mathbf{\Sigma}$. 要找一个单位向量将 X 投影到 1 维空间中, 并使得方差最大, 即

$$\max_{\|\boldsymbol{v}\|_2=1} \mathbb{E}[(\langle X, \boldsymbol{v}\rangle)^2] = \max_{\|\boldsymbol{v}\|_2=1} \boldsymbol{v}^T \mathbf{\Sigma} \boldsymbol{v}$$

由矩阵特征值性质知, 最优的投影变换为 $\mathbf{\Sigma}$ 的最大特征对应的单位化特征向量 $\boldsymbol{v}_1(\mathbf{\Sigma})$, 此时

$$\lambda_1(\mathbf{\Sigma}) = \max_{\|\boldsymbol{v}\|_2=1} \boldsymbol{v}^T \mathbf{\Sigma} \boldsymbol{v}.$$

接下来寻找第二个"最佳投影方向", 满足

$$\max_{\substack{\boldsymbol{v}\perp\boldsymbol{v}_1 \\ \|\boldsymbol{v}\|_2=1}} \boldsymbol{v}^T \mathbf{\Sigma} \boldsymbol{v}.$$

得到最优的投影变换为 $\mathbf{\Sigma}$ 的最二大特征对应的单位化特征向量 $\boldsymbol{v}_2(\mathbf{\Sigma})$, 此时

$$\lambda_2(\mathbf{\Sigma}) = \max_{\substack{\boldsymbol{v}\perp\boldsymbol{v}_1 \\ \|\boldsymbol{v}\|_2=1}} \boldsymbol{v}^T \mathbf{\Sigma} \boldsymbol{v}.$$

依次类推, 协方差 $\mathbf{\Sigma}$ 的前 k 个特征值对应的单位正交化特征向量构成主成分分析的"主成分", 即随机变量 X 投影到 k-为空间的线性变换.

称比率

$$\frac{\sum_{i=1}^{k} \lambda_i(\mathbf{\Sigma})}{\sum_{j=1}^{d} \lambda_j(\mathbf{\Sigma})}$$

为这 k 个主成分的累积解释度.

然而在实践中, 随机变量 $X \in \mathbb{R}^d$ 的协方差往往是未知的. 给定 n 个来自与 X 同一总体的样本 $X_1, X_2, \ldots, X_n$, 样本协方差为

$$\mathbf{\Sigma}_n = \frac{1}{n} \sum_{i=1}^{n} X_i X_i^T.$$

此时, 主成分分析建立在 $\mathbf{\Sigma}_n$ 上.

一个自然的问题是, $PCA(\mathbf{\Sigma}_n)$ 在多大程度上近似 $PCA(\mathbf{\Sigma})$, 即能否确保

$$\lambda_i(\mathbf{\Sigma}_n) \approx \lambda_i(\mathbf{\Sigma}) \quad \text{且} \quad \boldsymbol{v}_i(\mathbf{\Sigma}_n) \approx \boldsymbol{v}_i(\mathbf{\Sigma}),$$

相应的样本量应该是多少?

我们首先来看看能否在谱范数的度量下控制 $\boldsymbol{\Sigma}$ 与 $\boldsymbol{\Sigma}_n$ 的差别. 由谱范数性质

$$\begin{aligned}\|\boldsymbol{\Sigma}_n - \boldsymbol{\Sigma}\| &= \max_{\boldsymbol{v}\in\mathcal{S}^{d-1}} \left|\boldsymbol{v}^T(\boldsymbol{\Sigma}_n - \boldsymbol{\Sigma})\boldsymbol{v}\right| \\ &= \max_{\boldsymbol{v}\in\mathcal{S}^{d-1}} \left|\boldsymbol{v}^T\boldsymbol{\Sigma}_n\boldsymbol{v} - \boldsymbol{v}^T\boldsymbol{\Sigma}\boldsymbol{v}\right| \\ &= \max_{\boldsymbol{v}\in\mathcal{S}^{d-1}} \left|\frac{1}{n}\sum_{i=1}^{n}\langle X_i, \boldsymbol{v}\rangle^2 - \mathbb{E}[\langle X, \boldsymbol{v}\rangle^2]\right|\end{aligned}$$

其中 $\mathcal{S}^{d-1} \triangleq \{\boldsymbol{x} \in \mathbb{R}^d : \|x\|_2 = 1\}$

定义随机变量

$$Z(\boldsymbol{v}) = \frac{1}{n}\sum_{i=1}^{n}\langle X_i, \boldsymbol{v}\rangle^2 - \mathbb{E}[\langle X, \boldsymbol{v}\rangle^2],$$

此时

$$\|\boldsymbol{\Sigma}_n - \boldsymbol{\Sigma}\| = \max_{\boldsymbol{v}\in\mathcal{S}^{d-1}} |Z(\boldsymbol{v})|$$

命题 4.1: 谱范数与球面上的 ϵ-覆盖

对于矩阵 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$, 设 $\mathscr{N}$ 为单位球面 $\mathcal{S}^{n-1}$ 的一个 ϵ-覆盖, 则

$$\|\boldsymbol{A}\| \le \frac{1}{1-\epsilon}\max_{\boldsymbol{x}\in\mathscr{N}}\|\boldsymbol{A}\boldsymbol{x}\| \quad \forall\epsilon > 0.$$

证明. 由 ϵ-覆盖定义, $\forall\boldsymbol{v} \in \mathcal{S}^{n-1}$, $\exists\boldsymbol{x} \in \mathscr{N}$, 满足

$$\|\boldsymbol{v} - \boldsymbol{x}\|_2 \le \epsilon$$

由三角不等式及谱范数定义

$$\|\boldsymbol{A}\boldsymbol{v}\|_2 - \|\boldsymbol{A}\boldsymbol{x}\|_2 \le \|\boldsymbol{A}\boldsymbol{v} - \boldsymbol{A}\boldsymbol{x}\|_2 \le \|\boldsymbol{A}\|\|\boldsymbol{v} - \boldsymbol{x}\|_2 \le \|\boldsymbol{A}\|\epsilon$$

即对任意 $\boldsymbol{v} \in \mathcal{S}^{d-1}$, 存在 $\boldsymbol{x} \in \mathscr{N}$, 使得

$$\|\boldsymbol{A}\boldsymbol{v}\|_2 \le \|\boldsymbol{A}\|\epsilon + \|\boldsymbol{A}\boldsymbol{x}\|_2$$

因此

$$\max_{\boldsymbol{v}\in\mathcal{S}^{n-1}}\|\boldsymbol{A}\boldsymbol{v}\|_2 \le \|\boldsymbol{A}\|\epsilon + \max_{\boldsymbol{x}\in\mathscr{N}}\|\boldsymbol{A}\boldsymbol{x}\|_2$$

即

$$\|\boldsymbol{A}\| \le \epsilon\|\boldsymbol{A}\| + \max_{\boldsymbol{x}\in\mathscr{N}}\|\boldsymbol{A}\boldsymbol{x}\|_2$$

移项得到

$$\|\boldsymbol{A}\| \le \frac{1}{1-\epsilon}\max_{\boldsymbol{x}\in\mathscr{N}}\|\boldsymbol{A}\boldsymbol{x}\|$$

□

命题 4.2: 对称矩阵谱范数与球面上的 ϵ 覆盖

设 $\boldsymbol{A}$ 为 n-阶对称实矩阵, $\mathscr{N}$ 为单位球面 $\mathcal{S}^{n-1}$ 上的一个 ϵ-覆盖, 则

$$\|\boldsymbol{A}\| \leq \frac{1}{1-2\epsilon} \max_{\boldsymbol{x}\in\mathscr{N}} |\boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}| \quad \forall \epsilon \in (0, \frac{1}{2}).$$

证明. $\forall \boldsymbol{x} \in \mathcal{S}^{n-1}$, $\exists \boldsymbol{u} \in \mathscr{N}$, 满足 $\|\boldsymbol{x}-\boldsymbol{u}\|_2 \leq \epsilon$.

$$\begin{aligned}
\left|\boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x} - \boldsymbol{u}^T\boldsymbol{A}\boldsymbol{u}\right| &= \left|\boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x} - \boldsymbol{x}^T\boldsymbol{A}\boldsymbol{u} + \boldsymbol{x}^T\boldsymbol{A}\boldsymbol{u} - \boldsymbol{u}^T\boldsymbol{A}\boldsymbol{u}\right| \\
&\leq |\langle \boldsymbol{A}\boldsymbol{x}, \boldsymbol{x}-\boldsymbol{u}\rangle| + |\langle \boldsymbol{A}\boldsymbol{u}, \boldsymbol{u}-\boldsymbol{x}\rangle| \\
&\leq \|\boldsymbol{x}-\boldsymbol{u}\|_2\|\boldsymbol{A}\boldsymbol{x}\|_2 + \|\boldsymbol{x}-\boldsymbol{u}\|_2\|\boldsymbol{A}\boldsymbol{u}\|_2 \\
&\leq \epsilon\|\boldsymbol{A}\boldsymbol{x}\|_2 + \epsilon\|\boldsymbol{A}\boldsymbol{u}\|_2
\end{aligned}$$

故有

$$\begin{aligned}
\left|\boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}\right| &\leq \epsilon\|\boldsymbol{A}\boldsymbol{x}\|_2 + \epsilon\|\boldsymbol{A}\boldsymbol{u}\|_2 + \left|\boldsymbol{u}^T\boldsymbol{A}\boldsymbol{u}\right| \\
&\leq \epsilon\|\boldsymbol{A}\boldsymbol{x}\|_2 + \epsilon \max_{\boldsymbol{u}\in\mathscr{N}} \|\boldsymbol{A}\boldsymbol{u}\|_2 + \max_{\boldsymbol{u}\in\mathscr{N}} \left|\boldsymbol{u}^T\boldsymbol{A}\boldsymbol{u}\right| \\
&\leq \epsilon\|\boldsymbol{A}\boldsymbol{x}\|_2 + \epsilon \max_{\boldsymbol{u}\in\mathcal{S}^{n-1}} \|\boldsymbol{A}\boldsymbol{u}\|_2 + \max_{\boldsymbol{u}\in\mathscr{N}} \left|\boldsymbol{u}^T\boldsymbol{A}\boldsymbol{u}\right|
\end{aligned}$$

上述不等式关于 $\boldsymbol{x}$ 最大化

$$\max_{\boldsymbol{x}\in\mathcal{S}^{n-1}} \left|\boldsymbol{x}^T\boldsymbol{A}\boldsymbol{x}\right| \leq \epsilon \max_{\boldsymbol{x}\in\mathcal{S}^{n-1}} \|\boldsymbol{A}\boldsymbol{x}\|_2 + \epsilon \max_{\boldsymbol{u}\in\mathcal{S}^{n-1}} \|\boldsymbol{A}\boldsymbol{u}\|_2 + \max_{\boldsymbol{u}\in\mathscr{N}} \left|\boldsymbol{u}^T\boldsymbol{A}\boldsymbol{u}\right|$$

即

$$\|\boldsymbol{A}\| \leq 2\epsilon\|\boldsymbol{A}\| + \max_{\boldsymbol{u}\in\mathscr{N}} \left|\boldsymbol{u}^T\boldsymbol{A}\boldsymbol{u}\right|.$$

□

命题 4.3: 单位球面的最小覆盖数

$\forall \epsilon > 0$, 在 $\|\cdot\|_2$ 度量下有

$$\mathscr{N}(\epsilon; \mathcal{S}^{d-1}, \|\cdot\|_2) \leq \left(\frac{2}{\epsilon}+1\right)^d$$

4.1 协方差一致收敛性分析

定理 4.1: Bernstein 不等式

设 $X_1, X_2, \cdots, X_N$ 为相互独立、均值为 $\mathbb{E}[X_i] = \mu_i$ 的 sub-exponential 随机变量, 相应的参数为 (ν_i, α_i), 则有

$$\mathbb{P}\left[\sum_{i=1}^{N}(X_i - \mu_i) \geq t\right] \leq \exp\left(-\frac{1}{2}\min\left(\frac{t^2}{\tilde{\nu}^2}, \frac{t}{\tilde{\alpha}}\right)\right) \quad \forall t > 0,$$

其中 $\tilde{\nu}^2 = \sum_{i=1}^{N} \tilde{\nu}_i^2$, $\tilde{\alpha} = \max_{i=1,\ldots,N} \alpha_i$.

特别地, 若 X_i 独立同分布, Bernstein 不等式可改写为

$$\mathbb{P}\left[\frac{1}{N}\sum_{i=1}^{N} X_i - \mathbb{E}[X] \geq \delta\right] \leq \exp\left(-\frac{n}{2}\min\left(\frac{\delta^2}{\nu^2}, \frac{\delta}{\alpha}\right)\right) \quad \forall t > 0,$$

定理 4.2: 协方差估计

设 $X_i \sim N(\mathbf{0}, \mathbf{\Sigma})$, 若 $n \geq \frac{128d\log 3}{\delta^2}$ 且 $0 < \delta < 2$, 则

$$\|\mathbf{\Sigma}_n - \mathbf{\Sigma}\| \leq \delta\|\mathbf{\Sigma}\|$$

至少以概率 $1 - 2\exp(-\frac{n\delta^2}{64})$ 成立.

证明. 不失一般性, 设 $\|\mathbf{\Sigma}\| = 1$.

(**尾界**)

取任一固定 $\boldsymbol{v} \in \mathcal{S}^{d-1}$, 则 $\langle X, \boldsymbol{v}\rangle$ 是以零为均值的 Gaussian 随机变量, 其方差为

$$\sigma^2 = \mathbb{E}[\langle X, \boldsymbol{v}\rangle^2] = \mathbb{E}[\boldsymbol{v}^T X X^T \boldsymbol{v}] = \boldsymbol{v}^T \mathbf{\Sigma} \boldsymbol{v} \leq \|\mathbf{\Sigma}\| = 1$$

故 $\langle X, \boldsymbol{v}\rangle/\sigma \sim N(0,1)$ 且 $\langle X, \boldsymbol{v}\rangle^2/\sigma^2$ 是以 $(2,4)$ 为参数的 sub-exponential 随机变量.

因为 $\sigma \leq 1$, 故

$$\frac{1}{n}\left|\sum_{i=1}^{n}\frac{\langle X_i, \boldsymbol{v}\rangle^2}{\sigma^2} - \frac{\mathbb{E}[\langle X, \boldsymbol{v}\rangle^2]}{\sigma^2}\right| \geq \frac{1}{n}\left|\sum_{i=1}^{n}\langle X_i, \boldsymbol{v}\rangle^2 - \mathbb{E}[\langle X, \boldsymbol{v}\rangle^2]\right|$$

因此有

$$\begin{aligned}\mathbb{P}\left[\frac{1}{n}\left|\sum_{i=1}^{n}\langle X_i, \boldsymbol{v}\rangle^2 - \mathbb{E}[\langle X, \boldsymbol{v}\rangle^2]\right| \geq \delta\right] &\leq \mathbb{P}\left[\frac{1}{n}\left|\sum_{i=1}^{n}\frac{\langle X_i, \boldsymbol{v}\rangle^2}{\sigma^2} - \frac{\mathbb{E}[\langle X, \boldsymbol{v}\rangle^2]}{\sigma^2}\right| \geq \delta\right] \\ &\leq 2\exp\left(-\frac{n\delta^2}{8}\right) \quad \forall \delta \in (0,1).\end{aligned}$$

(**离散化**)

由命题 4.2,

$$\|\mathbf{\Sigma}_n - \mathbf{\Sigma}\| \geq \delta \Rightarrow \frac{1}{1-2\epsilon}\max_{\boldsymbol{v}\in\mathcal{N}}|Z(\boldsymbol{v})| \geq \delta$$

取 $\epsilon = \frac{1}{4}$,

$$\begin{aligned}\mathbb{P}\left[\|\boldsymbol{\Sigma}_n - \boldsymbol{\Sigma}\| \geq \delta\right] &\leq \mathbb{P}\left[2\max_{\boldsymbol{v}\in\mathscr{N}}|Z(\boldsymbol{v})| \geq \delta\right] \\ &= \mathbb{P}\left[\max_{\boldsymbol{v}\in\mathscr{N}}|Z(\boldsymbol{v})| \geq \frac{\delta}{2}\right]\end{aligned}$$

(**联合界**)

$$\begin{aligned}\mathbb{P}\left[\max_{\boldsymbol{v}\in\mathscr{N}}|Z(\boldsymbol{v})| \geq \frac{\delta}{2}\right] &= \mathbb{P}\left[\bigcup_{\boldsymbol{v}\in\mathscr{N}}\left\{|Z(\boldsymbol{v})| \geq \frac{\delta}{2}\right\}\right] \\ &\leq \sum_{\boldsymbol{v}\in\mathscr{N}}\mathbb{P}\left[Z(\boldsymbol{v}) \geq \frac{\delta}{2}\right] \\ &\leq |\mathscr{N}|\mathbb{P}\left[Z(\boldsymbol{v}) \geq \frac{\delta}{2}\right] \\ &\leq 9^d \cdot 2\exp\left(-\frac{n\delta^2}{32}\right) \quad \forall\delta \in (0,2).\end{aligned}$$

若 $n \geq \frac{128d\log 3}{\delta^2}$

$$\mathbb{P}\left[\|\boldsymbol{\Sigma}_n - \boldsymbol{\Sigma}\| \geq \delta\right] \leq \mathbb{P}\left[\max_{\boldsymbol{v}\in\mathscr{N}}|Z(\boldsymbol{v})| \geq \frac{\delta}{2}\right] \leq 2\exp(-\frac{n\delta^2}{64}).$$

此时

$$\|\boldsymbol{\Sigma}_n - \boldsymbol{\Sigma}\| \leq \delta$$

至少以概率 $1 - 2\exp(-\frac{n\delta^2}{64})$ 成立. □

4.2 扰动理论

定理 4.3: Weyl 不等式

任意 n-阶级对称矩阵 $\boldsymbol{S}$ 和 $\boldsymbol{T}$, 有

$$\max_i |\lambda_i(\boldsymbol{S}) - \lambda_i(\boldsymbol{T})| \leq \|\boldsymbol{S} - \boldsymbol{T}\|$$

定理 4.4: Davis-Kahan 不等式

设有任意 n-阶级对称矩阵 $\boldsymbol{S}$ 和 $\boldsymbol{T}$, $\lambda_i(\boldsymbol{S})$ 为 $\boldsymbol{S}$ 的特征值从大到小排列次序为 i 的特征值, 记 $\lambda_i(\boldsymbol{S})$ 与余下特征值的间隙为

$$\Delta_i \triangleq \min_{j:j\neq i}|\lambda_i(\boldsymbol{S}) - \lambda_j(\boldsymbol{S})| > 0,$$

则存在 $\theta \in \{-1, +1\}$, 使得 $\boldsymbol{S}$ 和 $\boldsymbol{T}$ 中次序为 i 的特征值对应的单位化特征向量 $\boldsymbol{v}_i(\boldsymbol{S})$ 和 $\boldsymbol{v}_i(\boldsymbol{T})$ 满足

$$\|\boldsymbol{v}_i(\boldsymbol{S}) - \theta\boldsymbol{v}_i(\boldsymbol{T})\|_2 \leq \frac{2\sqrt{2}\|\boldsymbol{S} - \boldsymbol{T}\|}{\Delta_i}$$

总结: PCA 有较好的拟合效果要求

- $n = \mathcal{O}(d)$;
- $\mathbf{\Sigma}_n$ 有较好分离度的特征值间隙.

第十二讲

王伟文　暨南大学

1　矩阵计算

定义 1.1: 矩阵函数

$A \in \mathbb{R}^{n\times n}$ 为对称矩阵，其谱分解为

$$A = \sum_{i=1}^{n} \lambda_i \boldsymbol{u}_i \boldsymbol{u}_i^T,$$

若有函数 $f : \mathbb{R} \to \mathbb{R}$, 则

$$f(A) \triangleq \sum_{i=1}^{n} f(\lambda_i) \boldsymbol{u}_i \boldsymbol{u}_i^T \in \mathbb{R}^{n\times n}.$$

例 1.1.

$$\begin{aligned} e^A &= \sum_{i=1}^{n} e^{\lambda_i} \boldsymbol{u}_i \boldsymbol{u}_i^T \\ &= \sum_{i=1}^{n} \sum_{k=0}^{\infty} \frac{\lambda_i^k}{k!} \boldsymbol{u}_i \boldsymbol{u}_i^T \\ &= \sum_{k=0}^{\infty} \sum_{i=1}^{n} \frac{\lambda_i^k}{k!} \boldsymbol{u}_i \boldsymbol{u}_i^T \\ &= I + \sum_{k=1}^{\infty} \frac{A^k}{k!} \end{aligned}$$

定义 1.2: 正半定矩阵 (Positive-Semidefinite, PSD)

称矩阵 $A \in \mathbb{R}^{n\times n}$ 为正定矩阵当且仅当对任意向量 $\boldsymbol{u} \in \mathbb{R}^n$ 有 $\boldsymbol{u}^T A \boldsymbol{u} \geq 0$, 等价于 $\lambda_i(A) \geq 0, \forall i \in [n]$.

定义 1.3: Löwner 秩

矩阵 A 为 PSD, 则 $A \succeq 0$. 若 $X - Y \succeq 0$, 则 $X \succeq Y$, $Y \preceq X$.

评论. Löwner 秩非完全秩, 即存在两个矩阵不能判断它们之间的 Löwner 秩.

命题 1.1: Löwner 秩的性质

(a) 若 $X \succeq Y$, $A \in R^{n\times n}$ 为任意 n 阶矩阵, 则 $A^TXA \succeq A^TYA$.

(b) 若 $X \preceq Y$, 则 $\lambda_i(X) \le \lambda(Y), \forall i \in [n]$; 进一步若 X 与 Y 可交换, 则逆命题成立.

(c) 设 $f : \mathbb{R} \to \mathbb{R}$ 为单调递增函数, 若 $X \preceq Y$, 则 $\texttt{trace} f(X) \le \texttt{trace} f(Y)$.

证明. (a) 给定 n 阶矩阵 A, 因为 $X - Y \succeq 0$ 为 PSD, 故对任意向量 $\boldsymbol{u} \in \mathbb{R}^n$ 有

$$(A\boldsymbol{u})^T(X-Y)(A\boldsymbol{u}) \ge 0,$$

即 $u^T(A^TXA - A^TYA)\boldsymbol{u} \ge 0 \Rightarrow A^TXA - A^TYA \succeq 0$. 故 $A^TXA \succeq A^TYA$.

(b) 设 $\mathbb{S}$ 为 $\mathbb{R}^n$ 的子空间, 由 Courant-Fisher 最小最大定理

$$\lambda_i(X) = \max_{\texttt{dim}\ \mathbb{S}=i} \min_{\substack{\boldsymbol{u}\in\mathbb{S} \\ \|\boldsymbol{u}\|=1}} \boldsymbol{u}^TX\boldsymbol{u}$$

可直接得到结论.

(c) $\texttt{trace}(X) = \sum\limits_{i=1}^{n} \lambda_i(X)$ 结合 (b) 得到. □

命题 1.2

若 X 可逆且 $0 \preceq X \preceq Y$, 则 Y 可逆且 $X^{-1} \succeq Y^{-1} \succeq 0$.

证明. 因为 X 可逆, 故 $\lambda_i \ge 0, \forall i \in [n]$. 又因为 $Y \succeq X$, 故 $\lambda_i(Y) \ge \lambda_i(X) > 0, \forall i \in [n]$. 故 Y 可逆.

若 $Y = I$, 即 $I \succeq X$, 故有 $X^{-\frac{1}{2}}IX^{-\frac{1}{2}} \succeq X^{-\frac{1}{2}}IX^{-\frac{1}{2}} \Rightarrow X^{-1} \succeq I$.

若 $Y \succeq X$, $Y^{-\frac{1}{2}}YY^{-\frac{1}{2}} \succeq Y^{-\frac{1}{2}}XY^{-\frac{1}{2}} \Rightarrow I \succeq Y^{-\frac{1}{2}}XY^{-\frac{1}{2}} \Rightarrow \left(Y^{-\frac{1}{2}}XY^{-\frac{1}{2}}\right)^{-1} \succeq I$. 即有

$$Y^{-\frac{1}{2}}X^{-1}Y^{-\frac{1}{2}} \succeq I \Rightarrow X^{-1} \succeq Y^{-1}.$$

□

命题 1.3

若 X 可逆且 $0 \preceq X \preceq Y$, 则 $\log X \preceq \log Y$.

证明. 利用恒等式

$$\log x \equiv \int_0^\infty \left(\frac{1}{1+t} - \frac{1}{x+t}\right) \mathrm{d}t \quad \forall x > 0$$

$$
\begin{aligned}
\log X &= \sum_{i=1}^{n} \int_0^\infty \left(\frac{1}{1+t} - \frac{1}{\lambda_i(X)+t} \right) \mathrm{d}t \cdot \boldsymbol{u}_i \boldsymbol{u}_i^T \\
&= \int_0^\infty \sum_{i=1}^{n} \left(\frac{1}{1+t} \boldsymbol{u}_i \boldsymbol{u}_i^T - \frac{1}{\lambda_i(X)+t} \boldsymbol{u}_i \boldsymbol{u}_i^T \right) \mathrm{d}t \\
&= \int_0^\infty \left((I+tI)^{-1} - (tI+X)^{-1} \right) \mathrm{d}t
\end{aligned}
$$

因为 $0 \preceq X \preceq Y \Rightarrow tI + X \preceq tI + Y$, 故 $(tI+X)^{-1} \succeq (tI+Y)^{-1}, \forall t > 0$.

$$
\begin{aligned}
\log Y - \log X &= \int_0^\infty \left((I+tI)^{-1} - (tI+Y)^{-1} \right) \mathrm{d}t - \int_0^\infty \left((I+tI)^{-1} - (tI+X)^{-1} \right) \mathrm{d}t \\
&= \int_0^\infty \left((tI+X)^{-1} - (tI+Y)^{-1} \right) \mathrm{d}t \\
&\succeq 0,
\end{aligned}
$$

故 $\log Y \succeq \log X$. □

2 矩阵 Hoeffing 不等式

定理 2.1: Hoeffding 不等式

设 ϵ_i 独立等概率地取 ± 1, $a_i \in R$, 则

$$
\mathbb{P}\left[\left| \sum_{i=1}^{n} \epsilon_i a_i \right| \geq t \right] \leq 2 \exp\left(-\frac{t^2}{2\sigma^2} \right) \quad t \geq 0.
$$

其中 $\sigma^2 = \sum_{i=1}^{n} a_i^2$.

证明. 记 $S_n = \sum_{i=1}^{n} \epsilon_i a_i$.

$$
\begin{aligned}
\mathbb{P}\left[S_n \geq t \right] &= \mathbb{P}\left[e^{\lambda S_n} \geq e^{\lambda t} \right] \quad \forall \lambda \geq 0. \\
&\leq e^{-\lambda t} \mathbb{E}\left[e^{\lambda S_n} \right] = e^{-\lambda t} \mathbb{E}\left[e^{\lambda \sum_{i=1}^{n} \epsilon_i a_i} \right] \\
&= e^{-\lambda t} \mathbb{E}\left[\prod_{i=1}^{n} e^{\lambda \epsilon_i a_i} \right] = e^{-\lambda t} \prod_{i=1}^{n} \mathbb{E}[e^{\lambda \epsilon_i a_i}] \\
&= e^{-\lambda t} \prod_{i=1}^{n} \left(\frac{e^{-\lambda a_i}}{2} + \frac{e^{\lambda a_i}}{2} \right) \\
&\leq e^{-\lambda t} \prod_{i=1}^{n} e^{\lambda^2 a_i^2 / 2} = \exp\left(-\lambda t + \frac{\lambda^2}{2} \sum_{i=1}^{n} a_i^2 \right)
\end{aligned}
$$

关于 $\lambda \geq 0$ 最小化不等式右边得到

$$\mathbb{P}\left[S_n \geq t\right] \leq \exp\left(-\frac{t^2}{2\sigma^2}\right) \quad \forall t \geq 0.$$

□

定理 2.2: Lieb 不等式

设 $H \in R^{n\times n}$ 为 n 阶对称矩阵, 定义函数

$$f(X) \triangleq \texttt{trace}\left(\exp(H + \log X)\right),$$

则函数 f 在 $\{X : X \succeq 0\}$ 为凹函数.

推论 2.1

设 $H \in R^{n\times n}$ 为 n 阶对称实矩阵, Z 为 n 阶对称随机矩阵, 则

$$\mathbb{E}\texttt{trace}\left(\exp(H + Z)\right) \leq \texttt{trace}\left(\exp(H + \log \mathbb{E}e^{Z})\right)$$

证明. $Z \triangleq \log e^{Z}$, 结合 Lieb 不等式和 Jensen 不等式得证. □

推论 2.2

设 X_i 为一组相互独立的同阶对称随机矩阵, 则

$$\mathbb{E}\texttt{trace}\exp\left(\sum_{i=1}^{n} X_i\right) \leq \texttt{trace}\exp\left(\sum_{i=1}^{n} \log \mathbb{E}e^{X_i}\right)$$

证明.

$$\begin{aligned}
&\mathbb{E}_{X_i:i\in[n-1]}\left[\mathbb{E}_{X_n}\texttt{trace}\exp\left(\sum_{i=1}^{n-1} X_i + X_n\right)\right] \\
&\leq \mathbb{E}_{X_i:i\in[n-1]}\left[\texttt{trace}\exp\left(\sum_{i=1}^{n-1} X_i + \log \mathbb{E}e^{X_n}\right)\right] \\
&\leq \cdots \\
&\leq \texttt{trace}\exp\left(\sum_{i=1}^{n} \log \mathbb{E}e^{X_i}\right)
\end{aligned}$$

□

定理 2.3: 矩阵 Hoeffing 不等式

设 ϵ_i 独立等概率取 ± 1, A_i 为 d-阶对称矩阵, 则

$$\mathbb{P}\left[\left\|\sum_{i=1}^{n}\epsilon_i A_i\right\| \geq t\right] \leq 2d\cdot\exp\left(-\frac{t^2}{2\sigma^2}\right) \quad \forall t\geq 0,$$

其中 $\sigma^2 = \left\|\sum\limits_{i=1}^{n} A_i^2\right\|$.

证明. 记 $S_n = \sum\limits_{i=1}^{n}\epsilon_i A_i$, $\|S_n\| = \max\left(\lambda_1(S_n), \lambda_1(-S_n)\right)$

对任意 $\lambda \geq 0$,

$$\begin{aligned}
\mathbb{P}\left[\lambda_1(S_n)\geq t\right] &= \mathbb{P}\left[e^{\lambda\cdot\lambda_1(S_n)} \geq e^{\lambda t}\right] \\
&\leq e^{-\lambda t}\mathbb{E}\left[e^{\lambda\cdot\lambda_1(S_n)}\right] \\
&\leq e^{-\lambda t}\mathbb{E}\left[\sum_{i=1}^{n} e^{\lambda\cdot\lambda_i(S_n)}\right] = e^{-\lambda t}\mathbb{E}\,\mathtt{trace}\exp(\lambda S_n) \\
&= e^{-\lambda t}\mathbb{E}\,\mathtt{trace}\exp\left(\sum_{i=1}^{n}\lambda\epsilon_i A_i\right) \\
&\leq e^{-\lambda t}\mathtt{trace}\exp\left(\sum_{i=1}^{n}\log\mathbb{E}e^{\lambda\epsilon_i A_i}\right)
\end{aligned}$$

因为

$$\frac{e^{-A}+e^{A}}{2} \preceq e^{\frac{A^2}{2}}$$

由 log 的单调性, 故有

$$\log\mathbb{E}e^{\lambda\epsilon_i A_i} \preceq \log e^{\frac{\lambda^2 A_i^2}{2}} = \frac{\lambda^2 A_i^2}{2}$$

因此

$$\sum_{i=1}^{n}\log\mathbb{E}e^{\lambda\epsilon_i A_i} \preceq \sum_{i=1}^{n}\frac{\lambda^2 A_i^2}{2}.$$

又因为 $\exp(\cdot)$ 为单调递增函数, 故

$$\mathtt{trace}\exp\left(\sum_{i=1}^{n}\log\mathbb{E}e^{\lambda\epsilon_i A_i}\right) \leq \mathtt{trace}\exp\left(\sum_{i=1}^{n}\frac{\lambda^2 A_i^2}{2}\right)$$

记 $Z = \sum\limits_{i=1}^{n} A_i^2$, $\sigma^2 = \|Z\|$, 则有

$$\begin{aligned}
\mathbb{P}\left[\lambda_1(S_n)\geq t\right] &\leq \exp(-\lambda t)\cdot\mathtt{trace}\exp\left(\frac{\lambda^2}{2}Z\right) \\
&= \exp(-\lambda t)\cdot\sum_{k=1}^{d}\exp\left(\frac{\lambda^2\cdot\lambda_k(Z)}{2}\right) \quad (\lambda_k(Z)\leq\sigma^2) \\
&\leq \exp(-\lambda t)\cdot d\exp\left(\frac{\lambda^2\sigma^2}{2}\right)
\end{aligned}$$

不等式右边关于 $\lambda \geq 0$ 最小化即

$$\mathbb{P}\left[\lambda_1(S_n) \geq t\right] \leq d \exp\left(-\frac{t^2}{2\sigma^2}\right) \quad \forall t \geq 0.$$

□

3 矩阵 Bernstein 不等式

定理 3.1: 矩阵 Bernstein 不等式

设 $X_1, \ldots, X_N$ 为均值为 0, 相互独立的 d 阶对称随机矩阵, 且 $\forall i$

$$\|X_i\| \leq K \quad \text{a.s.},$$

则对任意 $t \geq 0$,

$$\mathbb{P}\left[\left\|\sum_{i=1}^N X_i\right\| \geq t\right] \leq 2d \exp\left(-\frac{t^2/2}{\sigma^2 + Kt/3}\right)$$

这里 $\sigma^2 = \left\|\sum_{i=1}^N \mathbb{E}X_i^2\right\|$.

记号 若存在常数 $C > 0$, 使得 $a \leq Cb$, 则该不等式简记为 $a \lesssim b$.

推论 3.1

在定理 3.1 条件下,

$$\mathbb{E}\left\|\sum_{i=1}^N X_i\right\| \lesssim \left\|\sum_{i=1}^N \mathbb{E}X_i^2\right\|^{1/2} \sqrt{\log(2d)} + K\log(2d).$$

定理 3.2

设 $\{X_i\}_{i=1}^N$ 为与 X 同一分布的独立 $d(d \geq 2)$-维随机样本, 其中 $\mathbb{E}XX^T = \Sigma$. 记 $\Sigma_N = \frac{1}{N}\sum_{i=1}^N X_i X_i^T$. 若存在 $K \geq 1$, 使得

$$\|X\| \leq K(\mathbb{E}\|X\|^2)^{1/2} \quad \text{a.s.},$$

则

$$\mathbb{E}\|\Sigma_N - \Sigma\| \leq C\left(\sqrt{\frac{K^2 d \log d}{N}} + \frac{K^2 d \log d}{N}\right)\|\Sigma\| \quad \forall N \in \mathbb{N}_+$$

证明. $X_i X_i^T - \Sigma$ 相互独立且均值为 0, 由推论 3.1

$$\mathbb{E}\left\|\sum_{i=1}^N (X_i X_i^T - \Sigma)\right\| \lesssim \sigma\sqrt{\log d} + M\log d.$$

其中 $\sigma^2 = \left\| \sum_{i=1}^{N} \mathbb{E}(X_i X_i^T - \Sigma)^2 \right\| = N \left\| \mathbb{E}(XX^T - \Sigma)^2 \right\|$, M 满足

$$\|XX^T - \Sigma\| \leq M \quad \texttt{a.s.}$$

故

$$\mathbb{E}\|\Sigma_N - \Sigma\| = \frac{1}{N}\mathbb{E}\left\| \sum_{i=1}^{N} (X_i X_i^T - \Sigma) \right\| \lesssim \frac{1}{N}\left(\sigma\sqrt{\log d} + M \log d\right)$$

控制 σ 对任意 d 阶对称矩阵 A, 有 $A^2 \equiv A \cdot A$. 故

$$\mathbb{E}(XX^T - \Sigma)^2 = \mathbb{E}(XX^T)^2 - \Sigma^2 \preceq \mathbb{E}(XX^T)^2$$

又因为

$$\begin{aligned}
(XX^T)^2 &\preceq \lambda_{\max}(XX^T) XX^T \\
&= \|X\|^2 XX^T \\
&\leq K^2 \mathbb{E}(\|X\|^2) XX^T \quad \texttt{a.s.}
\end{aligned}$$

即

$$\mathbb{E}(XX^T)^2 \preceq K^2 \mathbb{E}(\|X\|^2)\Sigma.$$

综合上述不等式有

$$\|\mathbb{E}(XX^T - \Sigma)^2\| \leq \|\mathbb{E}(XX^T)^2\| \leq K^2 \mathbb{E}(\|X\|^2)\|\Sigma\|$$

此外

$$\mathbb{E}\|X\|^2 = \mathbb{E}\texttt{trace}(X^T X) = \texttt{trace}(\Sigma) \leq d\|\Sigma\|$$

故

$$\sigma^2 = N\|\mathbb{E}(XX^T - \Sigma)^2\| \leq NK^2 d\|\Sigma\|^2$$

即

$$\sigma \leq K\sqrt{Nd}\|\Sigma\|$$

控制 M

$$\begin{aligned}
\|XX^T - \Sigma\| &\leq \|XX^T\| + \|\Sigma\| \\
&\leq \|X\|^2 + \|\Sigma\| \\
&\leq K^2 \mathbb{E}\|X\|^2 + \|\Sigma\| \\
&\leq 2K^2 d\|\Sigma\| : M \quad \texttt{a.s.} \quad \forall K \geq 1.
\end{aligned}$$

综上所述

$$
\begin{aligned}
\mathbb{E}\|\Sigma_N - \Sigma\| &\lesssim \frac{1}{N}\left(\sigma\sqrt{\log(d)} + M\log(d)\right) \\
&\lesssim \left(\sqrt{\frac{K^2 d\log d}{N}} + \frac{K^2 d\log d}{N}\right)\|\Sigma\|
\end{aligned}
$$

□

评论. $\forall \epsilon \in (0,1)$, $\sqrt{\frac{K^2 d\log d}{N}} + \frac{K^2 d\log d}{N}$ 中 $\sqrt{\frac{K^2 d\log d}{N}}$ 为主项,

$$
\mathbb{E}\|\Sigma_N - \Sigma\| \le \epsilon\|\Sigma\| \Longrightarrow N \asymp \epsilon^{-2} d\log d.
$$